

Project: Αριθμητικές Μέθοδοι στην Επιστήμη των Δεδομένων

Κλασική και Διαστηματική Ανάλυση Χρηματιστηριακών Αποδόσεων (DIA ETF και 15 μετοχές)

Alexandros Tsagkanos — AM: up1125886

12 July 2026

Contents

Περίληψη	3
1 Εισαγωγή και Στόχος της Εργασίας	4
2 Σχετική Βιβλιογραφία	4
3 Λήψη Δεδομένων και Κατασκευή Μεταβλητών	6
3.1 Λήψη Δεδομένων από το Yahoo Finance	6
3.2 Κατασκευή Κλασικών και Διαστηματικών Αποδόσεων	7
3.3 Επισκόπηση της Περιόδου Μελέτης	8
4 Μέρος Α — Κλασική Ανάλυση	10
4.1 A1. Περιγραφική Στατιστική	10
4.1.1 Πίνακας Περιγραφικών Μέτρων	10
4.1.2 Ιστογράμματα	11
4.1.3 Boxplots	13
4.2 A2. Πίνακας Συσχετίσεων και Πολυσυγγραμμικότητα	14
4.2.1 Πίνακας Συσχετίσεων (Heatmap)	14
4.2.2 Variance Inflation Factor (VIF)	15
4.2.3 Ζεύγη με $ r > 0.8$	16
4.3 A3. Παραγοντική Ανάλυση (Factor Analysis)	17
4.3.1 Διαγνωστικοί Έλεγχοι (KMO & Bartlett)	17
4.3.2 Επιλογή Αριθμού Παραγόντων	17
4.3.3 Παραγοντική Ανάλυση με Principal Axis Factoring (PAF) και Varimax	18
4.4 A4. Ανάλυση Κύριων Συνιστωσών (PCA)	20

4.4.1	Scree Plot & Κριτήριο Kaiser	21
4.4.2	Φορτίσεις (Loadings) των πρώτων συνιστωσών	22
4.5	A5. Γραμμική Παλινδρόμηση και Stepwise Επιλογή	23
4.5.1	Πλήρες Μοντέλο	23
4.5.2	Stepwise Επιλογή Μεταβλητών (Both Directions, AIC)	24
4.5.3	Διαγνωστικοί Έλεγχοι του Τελικού Μοντέλου	25
5	Μέρος Β — Διαστηματική Ανάλυση	29
5.1	B1. Περιγραφή Διαστηματικών Δεδομένων	29
5.1.1	Ιστογράμματα mid και rad	29
5.1.2	Boxplots του rad ανά Τομέα	31
5.1.3	Συσχέτιση μεταξύ mid και rad	32
5.2	B2. Διαστηματική Παλινδρόμηση — Μέθοδος των Κέντρων (Billard & Diday, 2000)	33
5.2.1	Γραφική Σύγκριση Παρατηρούμενων–Προβλεπόμενων Διαστημάτων	35
5.2.2	Ακρίβεια Πρόβλεψης Διαστημάτων (RMSE κάτω/άνω ορίου)	36
5.3	B3. Ανάλυση Κύριων Συνιστωσών στα mid (Σύγκριση με την A4)	38
5.3.1	Scree Plot και Σύγκριση Φορτίσεων	38
5.4	B4. Διαστηματική Παραγοντική Ανάλυση — Βιβλιογραφική Συζήτηση	40
5.4.1	Γιατί δεν υπάρχει «εύκολη» Interval Factor Analysis;	40
5.4.2	Οι προτάσεις των Douzal-Chouakria & Diday (2007· 2011)	40
5.4.3	Γιατί η Interval PCA είναι ευκολότερη από την Interval FA;	41
5.4.4	Πορισματικός Σχολιασμός	41
5.5	B5. Δομικά Μοντέλα Εξισώσεων (SEM) — Bonus	41
6	Μέρος Γ — Σύγκριση και Συμπεράσματα	44
6.1	Γ1. Συγκεντρωτικός Πίνακας Σύγκρισης	44
6.2	Γ2. Ερμηνεία Αποτελεσμάτων	44
6.3	Γ3. Κριτική και Περιορισμοί	45
7	Σύνοψη – Συμπεράσματα	46
8	Παράρτημα — Επεκτάσεις πέραν της εκφώνησης	46
8.1	Δ1. Δέντρο Παλινδρόμησης — Σημαντικότητα Μεταβλητών για τον DIA	46
8.2	Δ2. PCA Biplot	48
8.3	Δ3. Διμεταβλητή Ανάλυση DIA–Μετοχής	49
8.4	Δ4. Παραγοντική Ανάλυση σε Βάθος: Πλάγια Περιστροφή, Αξιοπιστία, Παλινδρόμηση Σκορ	51

8.4.1	Πλάγια (oblique) περιστροφή και συσχέτιση παραγόντων	51
8.4.2	Αξιοπιστία (Cronbach's α) ανά παράγοντα	52
8.4.3	Παλινδρόμηση στα factor scores	52
8.5	Δ5. Περιορισμένη Μέθοδος Κέντρου-και-Εύρους (CCRM)	53
8.6	Δ6. Εύρωστη Συμπερασματολογία & Διαγνωστικοί Έλεγχοι Χρονοσειράς	54
8.7	Δ7. Σταθερότητα Εκτός Δείγματος (Out-of-Sample)	56
8.8	Δ8. Πολυπαραγοντικό Δομικό Υπόδειγμα (SEM)	58
8.9	Δ9. Το rad ως Εκτιμητής Αστάθειας: Parkinson και GARCH	59
8.9.1	Δ9.1 Σύγκριση με τον εκτιμητή του Parkinson	59
8.9.2	Δ9.2 GARCH(1,1) και σύγκριση με το rad	60
8.10	Δ10. Χρονική Σταθερότητα: Rolling Window και Υποπερίοδοι	62
8.11	Δ11. Αβεβαιότητα Εκτιμήσεων: Block Bootstrap και Time-Series CV	64
8.12	Παράρτημα Αναπαραγωγιμότητας	65

Βιβλιογραφία	67
---------------------	-----------

Περίληψη

Η εργασία συγκρίνει την κλασική στατιστική ανάλυση (αποδόσεις Close-to-Close) με τη **διαστηματική ανάλυση δεδομένων** (ημερήσια διαστήματα [Low, High], αναπαράσταση mid/rad) για τη σχέση του ETF **DIA** (Dow Jones Industrial Average) με 15 μετοχές από 5 κλάδους του S&P 500, σε 1.253 ευθυγραμμισμένες ημερήσιες παρατηρήσεις της περιόδου 2021–2025. Η κλασική stepwise παλινδρόμηση εξηγεί το 88,4% της διακύμανσης του DIA και το μοντέλο των κέντρων (CRM) το 84,6% — σχεδόν ταυτόσημη εικόνα, όπως αναμένεται θεωρητικά. Η εξίσωση του εύρους (rad) εμφανίζει $R^2 = 0,79$, το οποίο όμως τεκμηριώνεται ότι είναι κατά κύριο λόγο **μηχανικό αποτέλεσμα άθροισης** (το 0,72 προκύπτει από τον απλό μέσο όρο των επιμέρους rad) με στατιστικά άκυρη OLS συμπερασματολογία λόγω αυτοσυσχέτισης· το ορθό συμπέρασμα είναι η ύπαρξη ισχυρού **κοινού παράγοντα ενδοημερήσιας αστάθειας**, μη παρατηρήσιμου από την κλασική ανάλυση. Η ανάλυση συμπληρώνεται με παραγοντική ανάλυση, PCA, SEM, εύρωστη (HC3/HAC) συμπερασματολογία, περιορισμένη CRM (CCRM), έλεγχο εκτός δείγματος και πλήρως αναπαραγώγιμο pipeline.

Abstract. We compare classical (close-to-close) and interval-valued (daily [Low, High], mid/rad representation) statistical analysis of the relation between the DIA ETF and 15 S&P 500 stocks across five sectors, over 1,253 aligned trading days (2021–2025). Classical stepwise regression explains 88.4% of DIA variance and the interval Centre Method 84.6%. The range (rad) equation attains $R^2 = 0.79$, which we show is largely a mechanical aggregation effect (0.72 from the constituent mean alone) with OLS inference invalidated by autocorrelation; the substantive finding is a strong common intraday-volatility factor invisible to close-to-close analysis. Robust (HC3/HAC) inference, constrained CRM, out-of-sample checks and a fully reproducible pipeline complete the study.

Λέξεις-κλειδιά: διαστηματικά δεδομένα· συμβολική ανάλυση δεδομένων· Center-and-Range Method· αποδόσεις μετοχών· ενδοημερήσια αστάθεια· εύρωστη συμπερασματολογία.

Συνεισφορές: (α) συγκριτικό πλαίσιο κλασικής–διαστηματικής παλινδρόμησης στο ίδιο panel με κοινή προεπεξεργασία· (β) πλήρης αξιολόγηση διαστηματικής πρόβλεψης (CRM και CCRM με μετρικές κάλυψης/αποδοτικότητας/εγκυρότητας)· (γ) ειλικρινής ερμηνεία του rad μέσω αποσύνθεσης του μηχανικού μέρους (ταυτότητα άθροισης) και εύρωστης συμπερασματολογίας· (δ) πλήρως αναπαραγώγιμο pipeline (σπόρος = AM, τοπικό στιγμιότυπο δεδομένων, αυτόματη εγκατάσταση εξαρτήσεων).

Σημείωση: οι αριθμοί της περίληψης είναι στατικοί· υπολογίζονται και τεκμηριώνονται δυναμικά στις αντίστοιχες ενότητες (ντετερμινιστικό pipeline: σταθερό *seed* + τοπικά CSV).

1 Εισαγωγή και Στόχος της Εργασίας

Η παρούσα εργασία εκπονείται στο πλαίσιο του μαθήματος «Αριθμητικές Μέθοδοι στην Επιστήμη των Δεδομένων» και αποσκοπεί στη **συγκριτική μελέτη της κλασικής στατιστικής ανάλυσης** (όπου κάθε ημερήσια παρατήρηση είναι ένας πραγματικός αριθμός — η απόδοση Close-to-Close) **έναντι της διαστηματικής (interval) ανάλυσης δεδομένων** (όπου κάθε παρατήρηση είναι ένα διάστημα [Low, High] και αναπαρίσταται από το ζεύγος *mid* και *rad*).

Ως **εξαρτημένη μεταβλητή Y** χρησιμοποιείται ο δείκτης **DIA** (SPDR Dow Jones Industrial Average ETF) και ως **ανεξάρτητες μεταβλητές $X_1, \dots, X_{15}$** έχουν επιλεγεί δεκαπέντε μετοχές κατανεμημένες σε πέντε τομείς της αμερικανικής αγοράς:

Τομέας (Sector ETF)	Μετοχές
Technology (XLK)	NVDA, AAPL, MSFT
Financials (XLF)	BAC, JPM, V
Communications (XLC)	GOOGL, META, NFLX
Consumer Discretionary (XLY)	AMZN, TSLA, HD
Health (XLV)	LLY, JNJ, UNH

Η μελέτη καλύπτει την περίοδο **01-01-2021 έως 31-12-2025** (πέντε ολόκληρα ημερολογιακά έτη), παρέχοντας περισσότερες από 1.250 ευθυγραμμισμένες ημερήσιες παρατηρήσεις (ο ακριβής αριθμός υπολογίζεται και αναφέρεται παρακάτω). Το θεωρητικό πλαίσιο για τη διαστηματική παλινδρόμηση ακολουθεί τη **μέθοδο των κέντρων** των Billard and Diday (2000) (για την ακριβή σχέση με τη Center-and-Range Method των Lima Neto & de Carvalho, βλ. §B2), ενώ για τη συζήτηση της Interval Factor Analysis βασιζόμαστε στην εργασία των Douzal-Chouakria and Diday (2007).

2 Σχετική Βιβλιογραφία

Η **συμβολική ανάλυση δεδομένων** (Symbolic Data Analysis) επεκτείνει την κλασική στατιστική σε παρατηρήσεις που δεν είναι σημεία αλλά σύνολα — διαστήματα, ιστογράμματα, κατανομές. Τα θεμέλια για διαστηματικές μεταβλητές τέθηκαν από τους Bertrand and Goupil (2000) (περιγραφική στατιστική διαστημάτων) και συστηματοποιήθηκαν από τους Billard and Diday (2003), οι οποίοι τοποθέτησαν το πεδίο ως μετάβαση «από τη στατιστική των δεδομένων στη στατιστική της γνώσης». Στην παλινδρόμηση, οι Billard and Diday (2000) πρότειναν την αρχική **Μέθοδο των Κέντρων** (προσαρμογή στο κέντρο του διαστήματος), την οποία οι Lima Neto and Carvalho (2008) γενίκευσαν στη **Center-and-Range Method (CRM)** με χωριστή εξίσωση για το εύρος, και αργότερα (Lima Neto and Carvalho 2010) στην **περιορισμένη CCRM** που εγγυάται μη-αρνητικό προβλεπόμενο εύρος. Για τη μείωση διάστασης, η επέκταση της PCA σε

διαστηματικά δεδομένα μελετήθηκε από τους Douzal-Chouakria and Diday (2007) και Douzal-Chouakria et al. (2011), με τα γνωστά προβλήματα μη-μοναδικότητας της διαστηματικής συνδιακύμανσης που καθιστούν την πλήρη Interval FA δυσεπίλυτη (βλ. §B4).

Παράλληλα, στη χρηματοοικονομική βιβλιογραφία το **ημερήσιο εύρος τιμών** έχει μακρά ιστορία ως εκτιμητής αστάθειας: ο Parkinson (1980) έδειξε ότι το εύρος High–Low παρέχει σημαντικά αποδοτικότερη εκτίμηση της διακύμανσης από τις αποδόσεις κλεισίματος, και οι Garman and Klass (1980) τον βελτίωσαν αξιοποιώντας πλήρη OHLC πληροφορία. Η δυναμική της δεσμευμένης αστάθειας μοντελοποιείται κλασικά με την οικογένεια ARCH/GARCH (Engle 1982; Bollerslev 1986). Το Παράρτημα Δ9 γεφυρώνει ρητά τα δύο ρεύματα: δείχνουμε ότι το rad της διαστηματικής αναπαράστασης ταυτίζεται (ως προς κλίμακα) με τον εκτιμητή του Parkinson και συγκρίνεται με τη δεσμευμένη αστάθεια ενός GARCH(1,1).

Η παρούσα εργασία τοποθετείται στην τομή των δύο ρευμάτων: εφαρμόζει το πλαίσιο CRM/CCRM σε πραγματικά χρηματιστηριακά διαστήματα [Low, High], αξιολογεί την ποιότητα ανακατασκευής των διαστημάτων με τις μετρικές της βιβλιογραφίας (RMSE ορίων, κάλυψη, αποδοτικότητα, εγκυρότητα), και ερμηνεύει το αποτέλεσμα του εύρους υπό το πρίσμα της βιβλιογραφίας range-based volatility — με εύρωστη συμπερασματολογία (White 1980; Newey and West 1987) όπου οι κλασικές υποθέσεις παραβιάζονται.

```
# core πακέτα: δεδομένα, περιγραφικά/FA, γραφήματα, SEM, VIF, πίνακες
library(quantmod); library(psych); library(corrplot); library(ggplot2)
library(lavaan); library(knitr); library(car); library(moments)
library(MASS); library(kableExtra)

# χρησιμοποιούνται στο Παράρτημα (Δ): δέντρο, robust/HAC SE, CCRM, έλεγχοι χρονοσειράς
library(gvlma); library(rpart); library(rpart.plot)
library(lmtest); library(sandwich); library(nnl); library(tseries)

# Μικρός wrapper για τους πίνακες: booktabs + σταθερή θέση. Σε PDF εφαρμόζει
# kableExtra styling, ενώ διαδραστικά (console) επιστρέφει απλό markdown - αλλιώς
# η kable(format="latex") θα τύπωνε ωμό LaTeX. wide=TRUE -> μικρότερη γραμματοσειρά
# (δουλεύει και σε longtables, όπου το scale_down αγνοείται).
ktab <- function(x, caption = NULL, digits = 3, wide = FALSE, ...) {
  k <- knitr::kable(x, caption = caption, booktabs = TRUE,
    digits = digits, linesep = "", ...)
  if (knitr::is_latex_output()) {
    opts <- if (wide) c("HOLD_position", "scale_down") else "HOLD_position"
    k <- kableExtra::kable_styling(k, latex_options = opts,
      font_size = if (wide) 8 else 9)
  }
  k
}

# κοινό θέμα για όλα τα ggplot (συνέπεια) + παλέτα Okabe-Ito (φιλική σε αχρωματοψία)
theme_paper <- function(base = 11) {
  ggplot2::theme_bw(base_size = base) +
  ggplot2::theme(
    panel.grid.minor = ggplot2::element_blank(),
    panel.grid.major = ggplot2::element_line(linewidth = 0.3, colour = "grey88"),
    plot.title = ggplot2::element_text(face = "bold", size = ggplot2::rel(1.0)),
    plot.subtitle = ggplot2::element_text(colour = "grey30", size = ggplot2::rel(0.85)),
    strip.background = ggplot2::element_rect(fill = "grey92", colour = NA),
    strip.text = ggplot2::element_text(face = "bold", size = ggplot2::rel(0.75)),
    axis.title = ggplot2::element_text(size = ggplot2::rel(0.9)),
    legend.position = "none")
}

okabe_ito <- c("#000000", "#E69F00", "#56B4E9", "#009E73",
  "#F0E442", "#0072B2", "#D55E00", "#CC79A7")
sector_pal <- c(Tech = "#0072B2", Fin = "#E69F00", Comm = "#009E73",
```

```

        Cons = "#D55E00", Health = "#CC79A7")

# seed = AM φοιτητή, για αναπαραγωγιμότητα
set.seed(1125886)

```

3 Λήψη Δεδομένων και Κατασκευή Μεταβλητών

3.1 Λήψη Δεδομένων από το Yahoo Finance

```

# Y = DIA (εξαρτημένη), X1..X15 = οι 15 μετοχές, ομαδοποιημένες κατά τομέα
tickers_Y      <- "DIA"
tickers_tech   <- c("NVDA", "AAPL", "MSFT")      # Τεχνολογία
tickers_fin    <- c("BAC", "JPM", "V")           # Χρηματοοικονομικά
tickers_comm   <- c("GOOGL", "META", "NFLX")     # Επικοινωνίες
tickers_cons   <- c("AMZN", "TSLA", "HD")        # Καταναλωτικά
tickers_health <- c("LLY", "JNJ", "UNH")         # Υγεία

# Συγκεντρωτικός πίνακας μετοχών και τομέων (θα χρησιμοποιήσει αργότερα)
sectors_df <- data.frame(
  Ticker = c(tickers_tech, tickers_fin, tickers_comm, tickers_cons, tickers_health),
  Sector = c(rep("Tech", 3),
             rep("Fin", 3),
             rep("Comm", 3),
             rep("Cons", 3),
             rep("Health", 3))
)
all_tickers <- c(tickers_Y, sectors_df$Ticker)

# Ημερομηνίες περιόδου μελέτης
date_from <- "2021-01-01"
date_to   <- "2025-12-31"

# Cache των δεδομένων σε CSV: αν υπάρχει το αρχείο στο data/ το διαβάζουμε,
# αλλιώς το κατεβάζουμε μία φορά από το Yahoo και το σώζουμε. Έτσι το knitr είναι
# ντετερμινιστικό, δεν εξαρτάται από το δίκτυο, και τα δεδομένα ταξιδεύουν με το
# report (αναπαραγωγιμότητα, §3.3).
data_dir <- "data"
dir.create(data_dir, showWarnings = FALSE)

get_one <- function(sym) {
  csv <- file.path(data_dir, paste0(sym, ".csv"))
  if (file.exists(csv)) { # από cache
    df <- read.csv(csv, stringsAsFactors = FALSE)
    x <- xts::xts(as.matrix(df[, -1]), order.by = as.Date(df$Date))
    return(x)
  }
  res <- tryCatch( # αλλιώς κατέβασέ το
    quantmod::getSymbols(sym, src = "yahoo",
                        from = date_from, to = date_to,
                        auto.assign = FALSE),
    error = function(e) NULL
  )
  if (!is.null(res)) {
    write.csv(data.frame(Date = index(res), zoo::coredata(res)),
              csv, row.names = FALSE)
  }
}

```

```

}
res
}

prices_list <- setNames(lapply(all_tickers, get_one), all_tickers)

# Έλεγχος ότι διαβάστηκαν/κατέθηκαν όλα τα σύμβολα
ok <- sapply(prices_list, function(x) !is.null(x) && NROW(x) > 100)
stopifnot("Αποτυχία λήψης/ανάγνωσης για ένα ή περισσότερα tickers." = all(ok))

```

3.2 Κατασκευή Κλασικών και Διαστηματικών Αποδόσεων

Σύμφωνα με την εκφώνηση και το συνοδευτικό υλικό:

- **Κλασική απόδοση (Close-to-Close):** $r_t = \frac{C_t}{C_{t-1}} - 1$
- **Διαστηματική απόδοση:** $R_t = \left[\frac{L_t}{C_{t-1}} - 1, \frac{H_t}{C_{t-1}} - 1 \right]$
- **Κέντρο:** $\text{mid}_t = \frac{L_t + H_t}{2 C_{t-1}} - 1$
- **Ημι-εύρος:** $\text{rad}_t = \frac{H_t - L_t}{2 C_{t-1}}$

```

# ΣΥΝΑΡΤΗΣΗ: Υπολογισμός κλασικής και διαστηματικής απόδοσης
compute_returns <- function(prices_xts) {
  P_prev <- lag(Cl(prices_xts)) # προηγούμενο close
  L      <- Lo(prices_xts)      # ημερήσιο low
  H      <- Hi(prices_xts)      # ημερήσιο high
  Ccur   <- Cl(prices_xts)      # τρέχον close

  classical <- Ccur / P_prev - 1 # κλασική απόδοση Close-to-Close
  mid      <- (L + H) / (2 * P_prev) - 1 # κέντρο διαστήματος
  rad      <- (H - L) / (2 * P_prev) # ημι-εύρος διαστήματος

  out <- merge(classical, mid, rad)
  colnames(out) <- c("classical", "mid", "rad")
  out
}

# Εφαρμογή σε όλες τις σειρές
returns_list <- lapply(prices_list, compute_returns)

# ενώνουμε τα πάντα σε ένα ευθυγραμμισμένο panel: κάθε ticker -> 3 στήλες
# (classical, mid, rad) με πρόθεμα το ticker
build_panel <- function(rlist) {
  zs <- lapply(seq_along(rlist), function(i) {
    z <- rlist[[i]]
    colnames(z) <- paste0(names(rlist)[i], "_", colnames(z))
    z
  })
  out <- Reduce(function(a, b) merge(a, b, join = "inner"), zs)
  out <- na.omit(out)
  as.data.frame(out)
}

```

```

panel <- build_panel(returns_list)

# Διαχωρισμός σε τρία υπο-σύνολα: κλασικά, mid, rad
get_block <- function(suffix) {
  cols <- grep(paste0("_", suffix, "$"), colnames(panel), value = TRUE)
  df <- panel[, cols, drop = FALSE]
  colnames(df) <- sub(paste0("_", suffix, "$"), "", cols)
  df
}

df_classical <- get_block("classical") # απλές αποδόσεις
df_mid <- get_block("mid") # κέντρα διαστημάτων
df_rad <- get_block("rad") # ημι-εύρη διαστημάτων

# Στις τρεις παρακάτω μεταβλητές απομονώνουμε την εξαρτημένη και τις
# ανεξάρτητες, για διευκόλυνση των επόμενων ενοτήτων.
Y_classical <- df_classical$DIA
X_classical <- df_classical[, setdiff(colnames(df_classical), "DIA")]

Y_mid <- df_mid$DIA
X_mid <- df_mid[, setdiff(colnames(df_mid), "DIA")]

Y_rad <- df_rad$DIA
X_rad <- df_rad[, setdiff(colnames(df_rad), "DIA")]

# Συμβολοσειρά διάστασης δείγματος (για ερμηνεία)
n_obs <- nrow(df_classical)

```

```
cat("Αριθμός ευθυγραμμισμένων ημερήσιων παρατηρήσεων: ", n_obs, "\n")
```

Αριθμός ευθυγραμμισμένων ημερήσιων παρατηρήσεων: 1253

```
cat("Αριθμός ανεξάρτητων μεταβλητών : ", ncol(X_classical), "\n")
```

Αριθμός ανεξάρτητων μεταβλητών : 15

```
cat("Περίοδος μελέτης : ", date_from, "έως", date_to, "\n")
```

Περίοδος μελέτης : 2021-01-01 έως 2025-12-31

Σχόλιο: Μετά την ευθυγράμμιση των 16 σειρών και την αφαίρεση των NAs (που οφείλονται κυρίως στη μετατόπιση lag της πρώτης ημέρας), προκύπτει ένα πλήρες ισορροπημένο panel που μας επιτρέπει αδιάβλητη παράλληλη ανάλυση κλασικών και διαστηματικών μεταβλητών χωρίς αλγοριθμικές προκαταλήψεις λόγω missing values.

3.3 Επισκόπηση της Περιόδου Μελέτης


```

# χρονογραμμή αναφοράς: τι "θλέπει" το δείγμα 2021-2025
dia_px <- prices_list$DIA
tl <- rbind(
  data.frame(Date = index(dia_px), value = as.numeric(Cl(dia_px)),
    panel = "Τιμή κλεισίματος DIA ($)"),
  data.frame(Date = as.Date(rownames(df_classical)), value = Y_classical,
    panel = "Ημερήσια απόδοση DIA"))
tl$panel <- factor(tl$panel, levels = unique(tl$panel))
events <- data.frame(
  Date = as.Date(c("2022-01-05", "2023-03-10", "2023-06-01",
    "2024-08-05", "2025-04-02")),
  label = c("έναρξη bear\n(πληθωρισμός)", "SVB", "AI rally",
    "vol spike\nΑυγ 2024", "δασμοί\nΑπρ 2025"))
ggplot(tl, aes(Date, value)) +
  geom_vline(data = events, aes(xintercept = Date),
    linetype = 3, colour = "grey45") +
  geom_line(colour = "#0072B2", linewidth = 0.35) +
  geom_text(data = cbind(events, panel = factor(levels(tl$panel)[1],
    levels = levels(tl$panel))),
    aes(x = Date, y = Inf, label = label),
    vjust = 1.15, size = 2.4, colour = "grey25", lineheight = 0.9) +
  facet_wrap(~ panel, ncol = 1, scales = "free_y") +
  labs(title = "Σχήμα 1 – DIA: τιμή και αποδόσεις, 2021-2025",
    x = NULL, y = NULL) +
  theme_paper()

```

Σχήμα 1 — DIA: τιμή και αποδόσεις, 2021–2025




Figure 1: Σχήμα 1 — Πορεία του DIA στην περίοδο μελέτης: τιμή κλεισίματος (πάνω) και ημερήσια απόδοση (κάτω), με σημειωμένα βασικά γεγονότα αγοράς.

Η πενταετία καλύπτει ένα ασυνήθιστα πλούσιο φάσμα καθεστώτων αγοράς: την ανάκαμψη του 2021, τη bear market του 2022 (πληθωρισμός / επιθετικές αυξήσεις επιτοκίων), το τραπεζικό στρες του Μαρτίου 2023 (SVB), το AI rally του 2023–24, το απότομο vol spike του Αυγούστου 2024 και την αναταραχή των δασμών του Απριλίου 2025. Η ποικιλία αυτή είναι σημαντική για τη μελέτη: τροφοδοτεί τόσο τη διακύμανση των αποδόσεων (Μέρος Α) όσο και τη διακύμανση της **αστάθειας** (Μέρος Β) — και αξιοποιείται ρητά στην ανάλυση υποπεριόδων του Παραρτήματος Δ10.

4 Μέρος Α — Κλασική Ανάλυση

4.1 Α1. Περιγραφική Στατιστική

4.1.1 Πίνακας Περιγραφικών Μέτρων

```

# Υπολογισμός βασικών περιγραφικών μέτρων για κάθε κλασική απόδοση
desc_stats <- function(x) {
  c(
    Mean      = mean(x, na.rm = TRUE),
    Median    = median(x, na.rm = TRUE),
    SD        = sd(x, na.rm = TRUE),
    IQR       = IQR(x, na.rm = TRUE),          # ενδοτεταρτημοριακό εύρος
    Min       = min(x, na.rm = TRUE),
    Max       = max(x, na.rm = TRUE),
    Skewness   = moments::skewness(x, na.rm = TRUE),
    Kurtosis   = moments::kurtosis(x, na.rm = TRUE), # ορισμός Pearson (Normal=3)
    Missing    = 100 * mean(is.na(x))           # ποσοστό ελλειπουσών (%)
  )
}

tab_desc_classical <- t(sapply(df_classical, desc_stats))
ktab(tab_desc_classical, digits = 4, wide = TRUE,
      caption = "Πίνακας A1.1 – Περιγραφικά μέτρα κλασικών ημερήσιων αποδόσεων (Close-to-Close).")

```

Table 1: Πίνακας A1.1 — Περιγραφικά μέτρα κλασικών ημερήσιων αποδόσεων (Close-to-Close).

	Mean	Median	SD	IQR	Min	Max	Skewness	Kurtosis	Missing
DIA	0.0004	0.0006	0.0093	0.0100	-0.0543	0.0786	0.1187	9.0178	0
NVDA	0.0027	0.0030	0.0329	0.0374	-0.1697	0.2437	0.5072	7.4528	0
AAPL	0.0007	0.0010	0.0176	0.0179	-0.0925	0.1533	0.4542	9.5101	0
MSFT	0.0008	0.0007	0.0162	0.0175	-0.0772	0.1013	0.2057	6.2256	0
BAC	0.0006	0.0003	0.0171	0.0189	-0.1106	0.0843	0.0049	6.2624	0
JPM	0.0009	0.0011	0.0153	0.0168	-0.0805	0.1154	0.1088	8.1705	0
V	0.0005	0.0009	0.0143	0.0149	-0.0774	0.1060	0.1313	8.6121	0
GOOGL	0.0012	0.0015	0.0196	0.0210	-0.0951	0.1022	0.0996	6.1303	0
META	0.0011	0.0008	0.0274	0.0254	-0.2639	0.2328	-0.1910	23.8906	0
NFLX	0.0009	0.0008	0.0273	0.0246	-0.3512	0.1685	-1.5009	31.3499	0
AMZN	0.0005	0.0005	0.0221	0.0238	-0.1405	0.1354	0.1434	8.1736	0
TSLA	0.0012	0.0013	0.0383	0.0417	-0.1543	0.2269	0.3615	6.0935	0
HD	0.0003	0.0005	0.0149	0.0173	-0.0885	0.0870	-0.2204	6.0502	0
LLY	0.0017	0.0018	0.0201	0.0195	-0.1414	0.1487	0.4928	12.4834	0
JNJ	0.0003	0.0003	0.0106	0.0112	-0.0759	0.0619	0.0704	8.0249	0
UNH	0.0001	0.0006	0.0187	0.0171	-0.2238	0.1198	-2.0285	29.1846	0

4.1.2 Ιστογράμματα

```

# Ιστογράμματα όλων των κλασικών αποδόσεων - ggplot facet (paper level)
long_cl <- utils::stack(df_classical)
long_cl$ind <- factor(long_cl$ind, levels = colnames(df_classical))
means_cl <- data.frame(ind = factor(colnames(df_classical),
                                   levels = colnames(df_classical)),
                       mu = sapply(df_classical, mean))
ggplot(long_cl, aes(x = values)) +
  geom_histogram(bins = 40, fill = "#0072B2", colour = "white", linewidth = 0.1) +
  geom_vline(data = means_cl, aes(xintercept = mu),
             colour = "#D55E00", linewidth = 0.5) +
  facet_wrap(~ ind, scales = "free", ncol = 4) +
  labs(title = "A1 – Ιστογράμματα κλασικών ημερήσιων αποδόσεων",

```

```
x = "Ημερήσια απόδοση (Close-to-Close)", y = "Συχνότητα") +  
theme_paper()
```




Figure 2: Ιστογράμματα των 16 κλασικών ημερήσιων αποδόσεων (κόκκινη γραμμή: μέσος όρος).

4.1.3 Boxplots

```
long_box <- utils::stack(df_classical)
long_box$ind <- factor(long_box$ind, levels = colnames(df_classical))
grp <- c(DIA = "Δείκτης", setNames(sectors_df$Sector, sectors_df$Ticker))
long_box$grp <- factor(grp[as.character(long_box$ind)],
                      levels = c("Δείκτης", "Tech", "Fin", "Comm", "Cons", "Health"))
ggplot(long_box, aes(x = ind, y = values, fill = grp)) +
  geom_hline(yintercept = 0, linetype = 2, colour = "grey50") +
  geom_boxplot(outlier.alpha = 0.2, outlier.size = 0.4, linewidth = 0.3) +
  scale_fill_manual(values = c("Δείκτης" = "#444444", sector_pal)) +
  labs(title = "A1.2 – Boxplots κλασικών αποδόσεων (DIA + 15 μετοχές)",
       x = NULL, y = "Ημερήσια απόδοση", fill = "Κατηγορία") +
  theme_paper() +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1),
        legend.position = "right")
```




Figure 3: Boxplots κλασικών αποδόσεων ανά μετοχή, χρωματισμένα κατά τομέα.

4.1.3.1 Σχολιασμός A1 Από τον Πίνακα A1.1 και τα παραπάνω διαγράμματα προκύπτουν τα εξής:

- **Μέσοι όροι:** Όλες οι σειρές έχουν μέση ημερήσια απόδοση πολύ κοντά στο μηδέν· η μεγαλύτερη (κατ' απόλυτη τιμή) μέση ημερήσια απόδοση σε όλο το δείγμα είναι μόλις 0.0027. Αυτό συμφωνεί με τη χρηματοοικονομική βιβλιογραφία: η αναμενόμενη μέση ημερήσια απόδοση είναι πρακτικά μη διακριτή από το μηδέν στο επίπεδο του θορύβου.

- **Διασπορά:** Η τυπική απόκλιση του DIA (0.0093) είναι σαφώς μικρότερη από εκείνη των επιμέρους μετοχών — αποτύπωση της **επίδρασης του χαρτοφυλακιακού διαφορισμού** (portfolio diversification). Οι δύο πιο ασταθείς μετοχές του δείγματος είναι η **TSLA** και η **NVDA**. Το ενδοτεταρτημοριακό εύρος (IQR) στον Πίνακα A1.1 επιβεβαιώνει την ίδια διάταξη διασποράς, ανθεκτικά ως προς τις ακραίες τιμές.
- **Πληρότητα δεδομένων:** Μετά την ευθυγράμμιση το panel είναι **πλήρως ισορροπημένο** (0 ελλείπουσες τιμές, δηλαδή 0% σε κάθε σειρά), οπότε δεν απαιτείται imputation — προϋπόθεση που ελέγχεται ρητά στον υποχρεωτικό προ-μοντελικό κατάλογο.
- **Λοξότητα (Skewness):** Μόνο 4 από τις 16 σειρές είναι αρνητικά λοξές· οι **υπόλοιπες 12 (μαζί με τον ίδιο τον DIA) είναι ελαφρά θετικά λοξές**. Έντονη αρνητική λοξότητα εμφανίζεται μόνο σε μεμονωμένες μετοχές μετά από ειδικά γεγονότα (π.χ. NFLX, UNH με απότομες πτώσεις). Δηλαδή στο δείγμα μας **δεν** ισχύει γενικευμένα το «φαινόμενο αρνητικής λοξότητας» — η εικόνα είναι κατά μετοχή, με κυρίαρχη την ελαφριά θετική λοξότητα.
- **Κύρτωση (Kurtosis):** Όλες οι σειρές έχουν *kurtosis* > 3 (εύρος 6.1–31.3, ορισμός Pearson με Normal = 3), δηλαδή **παχιές ουρές (fat tails)** — κεντρικό χαρακτηριστικό των χρηματιστηριακών αποδόσεων που αναιρεί την υπόθεση κανονικότητας και δικαιολογεί τη χρήση robust διαγνωστικών στις επόμενες ενότητες.
- **Boxplots:** Είναι εμφανή τα πολυάριθμα ακραία σημεία (outliers) πέραν των whiskers, ιδίως για τις πιο ασταθείς μετοχές — ένδειξη ημερών έντονης διακύμανσης (π.χ. ανακοινώσεις κερδών, μακρο-σοκ).

Στο σύνολό τους, τα παραπάνω ευρήματα επιβεβαιώνουν τη **μη-κανονικότητα** των αποδόσεων και υποδεικνύουν ότι, για ασφαλέστερα συμπεράσματα, στη συνέχεια θα χρησιμοποιήσουμε διαγνωστικά με ευαισθησία σε ακραίες παρατηρήσεις (residual diagnostics, στην ενότητα A5).


4.2 A2. Πίνακας Συσχετίσεων και Πολυσυγγραμμικότητα

4.2.1 Πίνακας Συσχετίσεων (Heatmap)

```
# Υπολογισμός πίνακα συσχετίσεων Pearson για όλες τις κλασικές αποδόσεις
cor_classical <- cor(df_classical)

corrplot::corrplot(
  cor_classical,
  method      = "color",
  type        = "upper",
  order       = "hclust",
  addCoef.col = "black",
  number.cex  = 0.55,
  tl.cex      = 0.8,
  tl.col      = "black",
  tl.srt      = 45,
  col         = colorRampPalette(c("#2166AC", "white", "#B2182B"))(200),
  title       = "Σχήμα A2.1 – Heatmap συσχετίσεων (Pearson) – κλασικές αποδόσεις",
  mar         = c(0, 0, 2, 0)
)
```

Σχήμα A2.1 — Heatmap συσχετίσεων (Pearson) — κλασικές αποδόσεις



4.2.2 Variance Inflation Factor (VIF)

```
# Υπολόγισε VIF από το πλήρες γραμμικό μοντέλο  $Y \sim X1..X15$ 
df_full <- data.frame(Y = Y_classical, X_classical)
lm_full <- lm(Y ~ ., data = df_full)
vif_vals <- car::vif(lm_full)

ktab(data.frame(Variable = names(vif_vals),
                  VIF      = round(as.numeric(vif_vals), 3)),
      caption = "Πίνακας A2.1 — VIF για όλες τις ανεξάρτητες μεταβλητές.",
      row.names = FALSE)
```

Table 2: Πίνακας A2.1 — VIF για όλες τις ανεξάρτητες μεταβλητές.

Variable	VIF
NVDA	2.082

AAPL	2.228
MSFT	2.734
BAC	3.122
JPM	3.211
V	1.692
GOOGL	2.146
META	1.940
NFLX	1.465
AMZN	2.388
TSLA	1.523
HD	1.490
LLY	1.164
JNJ	1.327
UNH	1.124

4.2.3 Ζεύγη με $|r| > 0.8$

```
# Εντοπισμός υψηλά συσχετισμένων ζευγών (εκτός DIA)
ind_corr <- cor(X_classical)
hi <- which(abs(ind_corr) > 0.8 & upper.tri(ind_corr), arr.ind = TRUE)

# Μεγέθη που τροφοδοτούν τον σχολιασμό
n_hi_pairs <- nrow(hi)
a2_maxvif <- max(vif_vals)
a2_maxr <- max(ind_corr[upper.tri(ind_corr)])
cor_with_dia <- cor(X_classical, df_classical$DIA)[, 1]
a2_dia_max <- names(sort(cor_with_dia, decreasing = TRUE))[1]
a2_dia_min <- names(sort(cor_with_dia))[1]

if (n_hi_pairs > 0) {
  hi_df <- data.frame(
    Var1 = rownames(ind_corr)[hi[, 1]],
    Var2 = colnames(ind_corr)[hi[, 2]],
    r = round(ind_corr[hi], 3)
  )
  hi_df <- hi_df[order(-abs(hi_df$r)), ]
  ktab(hi_df, caption = "Πίνακας A2.2 – Ζεύγη ανεξάρτητων με  $|r| > 0.8$ .",
    row.names = FALSE)
} else {
  cat("Δεν εντοπίστηκαν ζεύγη ανεξάρτητων μετοχών με  $|r| > 0.8$ .\n")
}
```

Table 3: Πίνακας A2.2 — Ζεύγη ανεξάρτητων με $|r| > 0.8$.

Var1	Var2	r
BAC	JPM	0.814

4.2.3.1 Σχολιασμός A2

- Το heatmap δείχνει τις ισχυρότερες θετικές συσχετίσεις **εντός των τομέων** (μετοχές του ίδιου κλάδου μοιράζονται κοινούς παράγοντες κινδύνου). Η μέγιστη συσχέτιση μεταξύ δύο ανεξάρτητων μετοχών στο δείγμα είναι 0.814.

- Όλες οι μετοχές παρουσιάζουν **θετική συσχέτιση με τον DIA**· η ισχυρότερη είναι η **JPM** και η ασθενέστερη η **LLY** (λιγότερο ευθυγραμμισμένη με την price-weighted σύνθεση του δείκτη).
- Από τον Πίνακα A2.1, η **μέγιστη τιμή VIF είναι 3.21** — κάτω από το κρίσιμο όριο 10 (Kutner et al., 2005), οπότε δεν υφίσταται σοβαρή πολυσυγγραμμικότητα στο πλήρες μοντέλο. Εντοπίστηκαν 1 ζεύγη με $|r| > 0.8$, ωστόσο η εντός-τομέα συσχέτιση δικαιολογεί τη χρήση stepwise επιλογής (A5) και παραγοντικής ανάλυσης (A3).

4.3 A3. Παραγοντική Ανάλυση (Factor Analysis)

4.3.1 Διαγνωστικοί Έλεγχοι (KMO & Bartlett)

```
# Ελέγχουμε αν είναι κατάλληλα τα δεδομένα για παραγοντική ανάλυση
kmo_res <- psych::KMO(X_classical)
print(kmo_res)
```

```
Kaiser-Meyer-Olkin factor adequacy
Call: psych::KMO(r = X_classical)
Overall MSA = 0.9
MSA for each item =
  NVDA  AAPL  MSFT   BAC   JPM    V  GOOGL  META  NFLX  AMZN  TSLA   HD   LLY
0.92  0.94  0.92  0.75  0.76  0.95  0.94  0.94  0.95  0.94  0.94  0.94  0.84
  JNJ   UNH
0.66  0.85
```

```
bart_res <- psych::cortest.bartlett(cor(X_classical), n = n_obs)
print(bart_res)
```

```
$chisq
[1] 8014.254
```


```
$p.value
[1] 0
```

```
$df
[1] 105
```

4.3.2 Επιλογή Αριθμού Παραγόντων

```
# Παράλληλη ανάλυση + scree για να εκτιμήσουμε τον βέλτιστο αριθμό παραγόντων
psych::fa.parallel(X_classical, fa = "fa", n.iter = 50,
  show.legend = TRUE, main = "A3.1 – Parallel analysis (FA)")
```

A3.1 — Parallel analysis (FA)



Parallel analysis suggests that the number of factors = 4 and the number of components = NA

4.3.3 Παραγοντική Ανάλυση με Principal Axis Factoring (PAF) και Varimax

```
# Με βάση τα ευρήματα του scree/parallel analysis επιλέγουμε k παράγοντες.
# Παρακάτω χρησιμοποιούμε k = 3, που είναι λογικό για 5 τομείς ομαδοποιήσιμους σε
# ευρύτερες οικογένειες (growth/tech, financials, defensive). Ο αναγνώστης μπορεί
# να αλλάξει το k βάσει του γραφήματος.
fa_model <- psych::fa(X_classical, nfactors = 3, fm = "pa",
                      rotate = "varimax", scores = "regression")
print(fa_model$loadings, cutoff = 0.30, sort = TRUE)
```

```
Loadings:
      PA1    PA2    PA3
NVDA  0.731
AAPL  0.692
MSFT  0.805
GOOGL 0.721
META  0.698
NFLX  0.561
AMZN  0.773
TSLA  0.541
BAC   0.864
JPM   0.833
JNJ   0.741
V     0.422 0.344 0.387
HD    0.376 0.388
LLY   0.359
UNH   0.341
```

	PA1	PA2	PA3
SS loadings	4.341	1.816	1.343
Proportion Var	0.289	0.121	0.090
Cumulative Var	0.289	0.410	0.500

```
# Οπτικοποίηση της παραγοντικής δομής (όπως στο υλικό του μαθήματος)
psych::fa.diagram(fa_model, main = "A3.2 — Δομή Παραγόντων (PAF + Varimax)")
```

A3.2 — Δομή Παραγόντων (PAF + Varimax)




Figure 4: A3.2 — Διάγραμμα παραγόντων (factor diagram, varimax).

```
cat("Πίνακας κοινοτήτων (communalities):\n")
```

Πίνακας κοινοτήτων (communalities):

```
print(round(fa_model$communality, 3))
```

NVDA	AAPL	MSFT	BAC	JPM	V	GOOGL	META	NFLX	AMZN	TSLA	HD	LLY
0.558	0.585	0.698	0.828	0.798	0.446	0.562	0.509	0.331	0.636	0.340	0.353	0.159
JNJ	UNH											
0.564	0.134											

```
cat("\nΠοσοστό συνολικής διακύμανσης που εξηγείται από κάθε παράγοντα:\n")
```

Ποσοστό συνολικής διακύμανσης που εξηγείται από κάθε παράγοντα:

```
print(round(fa_model$Vaccounted, 3))
```

	PA1	PA2	PA3
SS loadings	4.341	1.816	1.343
Proportion Var	0.289	0.121	0.090
Cumulative Var	0.289	0.410	0.500
Proportion Explained	0.579	0.242	0.179
Cumulative Proportion	0.579	0.821	1.000

4.3.3.1 Σχολιασμός A3

- **KMO:** Η συνολική τιμή Kaiser-Meyer-Olkin είναι **0.899** («meritorious»), δηλαδή η αναλογία κοινής προς μοναδική διακύμανση δικαιολογεί απόλυτα την παραγοντική ανάλυση.
- **Bartlett:** Η μηδενική υπόθεση ότι ο πίνακας συσχετίσεων είναι μοναδιαίος απορρίπτεται ισχυρά ($p < 2.2e-16$), επιβεβαιώνοντας σημαντική κοινή διακύμανση μεταξύ των μετοχών.
- **Δομή Παραγόντων:** Με βάση τη μέγιστη φόρτιση κάθε μετοχής (μετά από varimax), οι παράγοντες ομαδοποιούν τις μετοχές ως εξής:

(1) NVDA, AAPL, MSFT, V, GOOGL, META, NFLX, AMZN, TSLA · (2) BAC, JPM · (3) HD, LLY, JNJ, UNH. Όπως φαίνεται από την **πραγματική** αυτή ομαδοποίηση, προκύπτει ένας **ευρύς παράγοντας mega-cap growth** (τεχνολογία, επικοινωνίες και καταναλωτικά μαζί), ένας **στενός τραπεζικός** (BAC, JPM) και ένας **αμυντικός/υγείας**. Αξιοσημείωτο: η συν-κίνηση των αποδόσεων **δεν ταυτίζεται πάντα με τον ονομαστικό κλάδο** — η V (χρηματοοικονομικά) φορτώνει με το growth και η HD (καταναλωτικά) με τις αμυντικές, υπενθύμιση ότι η στατιστική συσχέτιση $\neq$ ταξινόμηση GICS. Οι παράγοντες εξηγούν συνολικά **50%** της συνολικής διακύμανσης.

- **Κοινότητες (communalities):** Είναι υψηλές για τις μετοχές των μεγάλων τομέων· τη χαμηλότερη εμφανίζει η UNH. Σύμφωνα με τον εμπειρικό κανόνα του μαθήματος (communality > 0.4), οι μετοχές **NFLX, TSLA, HD, LLY, UNH** βρίσκονται κάτω από το όριο: ένα μεγάλο μέρος της διακύμανσής τους είναι **ιδιοσυγκρασιακό** και δεν εξηγείται από τους 3 κοινούς παράγοντες — αναμενόμενο για μετοχές με έντονη ειδική συμπεριφορά (π.χ. TSLA, ή αμυντικές με χαμηλό market beta).

4.4 A4. Ανάλυση Κύριων Συνιστωσών (PCA)

```
# PCA στις κλασικές αποδόσεις των 15 ανεξάρτητων μετοχών (όχι του DIA)
pca_classical <- prcomp(X_classical, center = TRUE, scale. = TRUE)
summary(pca_classical)
```

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.4154	1.3262	1.08741	0.93887	0.86115	0.8405	0.81468
Proportion of Variance	0.3889	0.1172	0.07883	0.05876	0.04944	0.0471	0.04425
Cumulative Proportion	0.3889	0.5062	0.58501	0.64378	0.69322	0.7403	0.78456

	PC8	PC9	PC10	PC11	PC12	PC13	PC14
Standard deviation	0.78382	0.74944	0.67627	0.63825	0.61465	0.58982	0.53456
Proportion of Variance	0.04096	0.03744	0.03049	0.02716	0.02519	0.02319	0.01905
Cumulative Proportion	0.82552	0.86297	0.89346	0.92061	0.94580	0.96899	0.98804

	PC15
Standard deviation	0.42353
Proportion of Variance	0.01196
Cumulative Proportion	1.00000

4.4.1 Scree Plot & Κριτήριο Kaiser

```
eig_vals <- (pca_classical$sdev)^2
n_keep <- sum(eig_vals > 1)
lv <- c("Ιδιαιτιές (κριτήριο Kaiser > 1)", "Αθροιστική εξηγημένη διασπορά")
scree_df <- rbind(
  data.frame(PC = seq_along(eig_vals), value = eig_vals, panel = lv[1]),
  data.frame(PC = seq_along(eig_vals),
    value = cumsum(eig_vals) / sum(eig_vals), panel = lv[2]))
scree_df$panel <- factor(scree_df$panel, levels = lv)
href <- data.frame(panel = factor(lv, levels = lv), y = c(1, 0.80))
ggplot(scree_df, aes(PC, value)) +
  geom_hline(data = href, aes(yintercept = y), linetype = 2, colour = "#D55E00") +
  geom_line(colour = "#0072B2", linewidth = 0.6) +
  geom_point(colour = "#0072B2", size = 1.6) +
  facet_wrap(~ panel, scales = "free_y") +
  scale_x_continuous(breaks = seq(1, length(eig_vals), 2)) +
  labs(title = "A4.1 – Scree plot & αθροιστική εξηγημένη διασπορά (PCA)",
    x = "Κύρια συνιστώσα (PC)", y = NULL) +
  theme_paper()
```

A4.1 — Scree plot & αθροιστική εξηγμένη διασπορά (PCA)




Figure 5: Scree plot (ιδιοτιμές, κριτήριο Kaiser>1) και αθροιστική εξηγμένη διασπορά.

```
cat("Κανόνας Kaiser (eigenvalue > 1): διατηρούμε", n_keep, "κύριες συνιστώσες.\n")
```

Κανόνας Kaiser (eigenvalue > 1): διατηρούμε 3 κύριες συνιστώσες.

```
cat("Ποσοστό διακύμανσης που εξηγείται από PC1+PC2+PC3:",  
    round(sum(eig_vals[1:3]) / sum(eig_vals) * 100, 2), "%\n")
```

Ποσοστό διακύμανσης που εξηγείται από PC1+PC2+PC3: 58.5 %

4.4.2 Φορτίσεις (Loadings) των πρώτων συνιστωσών

```
loadings_mat <- pca_classical$rotation[, 1:min(4, ncol(pca_classical$rotation))]  
ktab(loadings_mat, digits = 3,  
      caption = "Πίνακας A4.1 — Φορτίσεις των πρώτων 4 κύριων συνιστωσών.")
```

Table 4: Πίνακας A4.1 — Φορτίσεις των πρώτων 4 κύριων συνιστωσών.

	PC1	PC2	PC3	PC4
NVDA	-0.297	0.240	-0.016	0.001
AAPL	-0.322	0.055	0.099	-0.099
MSFT	-0.333	0.166	0.144	-0.090
BAC	-0.243	-0.356	-0.498	0.128
JPM	-0.250	-0.364	-0.461	0.161
V	-0.273	-0.230	-0.017	-0.023
GOOGL	-0.311	0.155	0.079	-0.090

META	-0.294	0.200	0.082	0.123
NFLX	-0.246	0.184	0.044	0.088
AMZN	-0.325	0.181	0.026	-0.016
TSLA	-0.252	0.129	-0.154	-0.126
HD	-0.243	-0.218	0.094	-0.001
LLY	-0.125	-0.204	0.504	0.549
JNJ	-0.074	-0.495	0.393	0.081
UNH	-0.093	-0.344	0.227	-0.764

4.4.2.1 Σχολιασμός A4

- Με βάση το **κριτήριο του Kaiser** (ιδιοτιμή > 1) διατηρούμε **3** κύριες συνιστώσες. Η πρώτη συνιστώσα εξηγεί **38.9%** και οι τρεις πρώτες **58.5%** της συνολικής διακύμανσης.
- **Kaiser έναντι αθροιστικής διασποράς:** Οι δύο κανόνες δίνουν διαφορετική εικόνα. Με Kaiser κρατάμε 3 συνιστώσες, αλλά αυτές καλύπτουν μόλις 58.5%, **κάτω από τον εμπειρικό κανόνα του 70–80%**· για να φτάσουμε το 70% χρειάζονται **6** συνιστώσες. Η ένταση αυτή είναι αναμενόμενη για ένα θορυβώδες cross-section ημερήσιων αποδόσεων (ισχυρός κοινός παράγοντας αγοράς + πολλές σχεδόν-ισοδύναμες ιδιοσυγκρασιακές διαστάσεις) και υπενθυμίζει ότι ο αριθμός των συνιστωσών εξαρτάται από τον στόχο (ερμηνεία vs ποσοστό διασποράς).
- **PC1 — «Market factor»:** Όλες οι μετοχές φορτώνουν με το ίδιο πρόσημο (το πρόσημο του ιδιοδιανύσματος είναι συμβατικό). Πρόκειται για τον *common market factor* — εξηγεί γιατί όλες οι μετοχές κινούνται σε γενικές γραμμές μαζί (συστηματικός κίνδυνος).
- **PC2 — «Growth/Tech vs. Defensive»:** Συνήθως διαχωρίζει τις growth/tech μετοχές από τις αμυντικές.
- **PC3:** Λεπτομερέστερη διάκριση κλάδων (π.χ. χρηματοοικονομικά έναντι επικοινωνιών).

Η οικονομική ερμηνεία είναι σύμφωνη με την παραγοντική ανάλυση της A3: δύο σχεδόν ισοδύναμες οπτικές γωνίες της ίδιας κοινής δομής διακύμανσης.

4.5 A5. Γραμμική Παλινδρόμηση και Stepwise Επιλογή

4.5.1 Πλήρες Μοντέλο

```
# Πλήρες γραμμικό μοντέλο για την κλασική απόδοση του DIA
df_lm <- data.frame(Y = Y_classical, X_classical)
lm_full <- lm(Y ~ ., data = df_lm)
summary(lm_full)
```

Call:

```
lm(formula = Y ~ ., data = df_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.0152056	-0.0018409	-0.0000405	0.0018494	0.0155024

Coefficients:

```

      Estimate Std. Error t value Pr(>|t|)
(Intercept) -9.227e-05  9.011e-05 -1.024 0.306017
NVDA         1.119e-02  3.922e-03  2.853 0.004408 **
AAPL         6.996e-02  7.606e-03  9.198 < 2e-16 ***
MSFT         7.891e-02  9.125e-03  8.647 < 2e-16 ***
BAC          9.626e-02  9.265e-03 10.390 < 2e-16 ***
JPM          1.380e-01  1.045e-02 13.208 < 2e-16 ***
V            1.111e-01  8.140e-03 13.647 < 2e-16 ***
GOOGL        5.199e-03  6.677e-03  0.779 0.436283
META         1.317e-03  4.555e-03  0.289 0.772581
NFLX         3.944e-03  3.968e-03  0.994 0.320506
AMZN         2.272e-02  6.250e-03  3.636 0.000288 ***
TSLA         2.285e-03  2.884e-03  0.792 0.428312
HD           1.233e-01  7.306e-03 16.873 < 2e-16 ***
LLY          1.591e-02  4.793e-03  3.319 0.000929 ***
JNJ          9.214e-02  9.757e-03  9.444 < 2e-16 ***
UNH          8.413e-02  5.067e-03 16.603 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 0.003165 on 1237 degrees of freedom
Multiple R-squared: 0.8847, Adjusted R-squared: 0.8833
F-statistic: 632.8 on 15 and 1237 DF, p-value: < 2.2e-16

4.5.2 Stepwise Επιλογή Μεταβλητών (Both Directions, AIC)

```

# Χρησιμοποιούμε step() με κριτήριο AIC και κατεύθυνση both, ξεκινώντας από
# το πλήρες μοντέλο. Το trace = FALSE μειώνει τον θόρυβο στην έξοδο.
lm_step <- step(lm_full, direction = "both", trace = FALSE)

```

```
summary(lm_step)
```

Call:

```
lm(formula = Y ~ NVDA + AAPL + MSFT + BAC + JPM + V + AMZN +
    HD + LLY + JNJ + UNH, data = df_lm)
```

Residuals:

```

      Min       1Q   Median       3Q      Max
-0.0152744 -0.0018476 -0.0000583  0.0018686  0.0154558

```

Coefficients:

```

      Estimate Std. Error t value Pr(>|t|)
(Intercept) -8.996e-05  9.001e-05 -1.000 0.317743
NVDA         1.269e-02  3.804e-03  3.336 0.000876 ***
AAPL         7.324e-02  7.246e-03 10.107 < 2e-16 ***
MSFT         8.174e-02  8.711e-03  9.384 < 2e-16 ***
BAC          9.706e-02  9.240e-03 10.505 < 2e-16 ***
JPM          1.384e-01  1.043e-02 13.266 < 2e-16 ***
V            1.120e-01  8.106e-03 13.812 < 2e-16 ***
AMZN         2.620e-02  5.780e-03  4.533 6.39e-06 ***
HD           1.228e-01  7.273e-03 16.885 < 2e-16 ***
LLY          1.599e-02  4.779e-03  3.346 0.000844 ***
JNJ          9.169e-02  9.720e-03  9.433 < 2e-16 ***
UNH          8.394e-02  5.042e-03 16.648 < 2e-16 ***
---

```


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003164 on 1241 degrees of freedom
Multiple R-squared: 0.8844, Adjusted R-squared: 0.8834
F-statistic: 863.5 on 11 and 1241 DF, p-value: < 2.2e-16

```
cat("\nΕπιλεγμένες μεταβλητές μετά το stepwise:\n")
```

Επιλεγμένες μεταβλητές μετά το stepwise:

```
print(setdiff(all.vars(formula(lm_step)), "Y"))
```





```
[1] "NVDA" "AAPL" "MSFT" "BAC" "JPM" "V" "AMZN" "HD" "LLY" "JNJ"  
[11] "UNH"
```

```
cat("\nAIC πλήρους: ", round(AIC(lm_full), 2),  
    "\nAIC stepwise: ", round(AIC(lm_step), 2), "\n")
```

AIC πλήρους: -10849.43
AIC stepwise: -10854.68

4.5.3 Διαγνωστικοί Έλεγχοι του Τελικού Μοντέλου

```
op <- par(mfrow = c(2, 2))  
plot(lm_step, which = 1:4)
```



```
par(op)
```

```
# Έλεγχος κανονικότητας καταλοίπων - Jarque-Bera (κανονικό για χρηματοοικονομικές  
# σειρές: ελέγχει από κοινού λοξότητα & κύρτωση) και Shapiro-Wilk.  
cat("Jarque-Bera test (έλεγχος κανονικότητας - λοξότητα/κύρτωση):\n")
```

Jarque-Bera test (έλεγχος κανονικότητας – λοξότητα/κύρτωση):

```
print(moments::jarque.test(as.numeric(resid(lm_step))))
```

Jarque-Bera Normality Test

```
data: as.numeric(resid(lm_step))
JB = 95.053, p-value < 2.2e-16
alternative hypothesis: greater
```

```
cat("\nShapiro-Wilk επί των residuals (έλεγχος κανονικότητας):\n")
```

Shapiro-Wilk επί των residuals (έλεγχος κανονικότητας):

```
print(shapiro.test(sample(resid(lm_step), min(5000, length(resid(lm_step))))))
```

Shapiro-Wilk normality test

```
data: sample(resid(lm_step), min(5000, length(resid(lm_step))))
W = 0.99021, p-value = 2.08e-07
```

```
cat("\nBreusch-Pagan test (έλεγχος ετεροσκεδαστικότητας):\n")
```

Breusch-Pagan test (έλεγχος ετεροσκεδαστικότητας):

```
print(car::ncvTest(lm_step))
```

Non-constant Variance Score Test

```
Variance formula: ~ fitted.values
Chisquare = 23.90033, Df = 1, p = 1.0145e-06
```

```
cat("\nDurbin-Watson test (έλεγχος αυτοσυσχέτισης):\n")
```

Durbin-Watson test (έλεγχος αυτοσυσχέτισης):

```
print(car::durbinWatsonTest(lm_step))
```

```
lag Autocorrelation D-W Statistic p-value
1 -0.02208884 2.042884 0.442
Alternative hypothesis: rho != 0
```

```
# Συνολικός έλεγχος των υποθέσεων του γραμμικού μοντέλου (όπως στο υλικό
# του μαθήματος: gvlma - Global Validation of Linear Model Assumptions).
print(gvlma::gvlma(lm_step))
```

```
Call:
lm(formula = Y ~ NVDA + AAPL + MSFT + BAC + JPM + V + AMZN +
    HD + LLY + JNJ + UNH, data = df_lm)
```

Coefficients:

(Intercept)	NVDA	AAPL	MSFT	BAC	JPM
-8.996e-05	1.269e-02	7.324e-02	8.174e-02	9.706e-02	1.384e-01
V	AMZN	HD	LLY	JNJ	UNH
1.120e-01	2.620e-02	1.228e-01	1.599e-02	9.169e-02	8.394e-02

ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
 USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
 Level of Significance = 0.05

```
Call:
gvlma::gvlma(x = lm_step)
```

	Value	p-value	Decision
Global Stat	95.187600	0.0000	Assumptions NOT satisfied!
Skewness	0.180284	0.6711	Assumptions acceptable.
Kurtosis	94.872468	0.0000	Assumptions NOT satisfied!
Link Function	0.004708	0.9453	Assumptions acceptable.
Heteroscedasticity	0.130139	0.7183	Assumptions acceptable.

4.5.3.1 Σχολιασμός A5

- **Συντελεστές & p-values:** Το stepwise μοντέλο διατηρεί **11** από τις 15 μεταβλητές: NVDA, AAPL, MSFT, BAC, JPM, V, AMZN, HD, LLY, JNJ, UNH. Πρόκειται κατά κύριο λόγο για μετοχές με μεγάλη «βαρύτητα» στον δείκτη.
- **R² = 0.884 (adj. R² = 0.883):** Υψηλό, καθώς ο δείκτης είναι σε μεγάλο βαθμό **γραμμικός συνδυασμός των συστατικών του**. Ο DJIA που αντιγράφει ο DIA περιλαμβάνει 30 μετοχές· από τις 15 μετοχές μας οι **9** (AAPL, MSFT, JPM, V, UNH, JNJ, HD, AMZN, NVDA) είναι συστατικά του δείκτη κατά την περίοδο μελέτης (οι AMZN και NVDA προστέθηκαν εντός του 2024), ενώ οι υπόλοιπες (BAC, GOOGL, META, NFLX, TSLA, LLY) δεν είναι.
- **AIC:** Μειώνεται από -1.08494×10^4 (πλήρες) σε -1.08547×10^4 (stepwise): η αφαίρεση μη-σημαντικών μεταβλητών βελτιώνει το μοντέλο χωρίς ουσιαστική απώλεια ερμηνευτικής ισχύος.
- **Διαγνωστικά υπολοίπων:**
 - Από το «Residuals vs. Fitted» δεν εμφανίζεται έντονη μη-γραμμικότητα.
 - **Jarque-Bera:** $p = 0$ ($< 0.05 \rightarrow$ απορρίπτεται η κανονικότητα των καταλοίπων, σύμφωνα με τις παχιές ουρές/λοξότητα της A1). Στο Q-Q plot τα υπόλοιπα αποκλίνουν από την κανονικότητα στις ουρές — σύμφωνο με την A1 (παχιές ουρές των αποδόσεων).
 - **Breusch-Pagan:** $p = 1.01 \times 10^{-6}$ ($< 0.05 \rightarrow$ ενδείξεις ετεροσκεδαστικότητας).
 - **Durbin-Watson:** $DW = 2.043$ (κοντά στο 2 $\rightarrow$ πρακτικά απουσία αυτοσυσχέτισης πρώτου βαθμού στα residuals, αναμενόμενο για ημερήσιες αποδόσεις).
 - **Συνολικός έλεγχος gvlma:** Η μόνη υπόθεση που παραβιάζεται είναι η κανονικότητα, και μάλιστα **αποκλειστικά μέσω της κύρτωσης** (Kurtosis component): η λοξότητα, η μορφή σύνδεσης (link) και η ομοσκεδαστικότητα κρίνονται αποδεκτές. Το εύρημα είναι απόλυτα συνεπές με την A1 (παχιές ουρές) και τον έλεγχο Jarque-Bera, και επιβεβαιώνει ότι το πρόβλημα δεν είναι η συστηματική δομή του μοντέλου αλλά οι ακραίες αποδόσεις.

5 Μέρος Β — Διαστηματική Ανάλυση

5.1 Β1. Περιγραφή Διαστηματικών Δεδομένων

5.1.1 Ιστογράμματα mid και rad

```
long_mid <- utils::stack(df_mid)
long_mid$ind <- factor(long_mid$ind, levels = colnames(df_mid))
ggplot(long_mid, aes(x = values)) +
  geom_histogram(bins = 40, fill = "#009E73", colour = "white", linewidth = 0.1) +
  facet_wrap(~ ind, scales = "free", ncol = 4) +
  labs(title = "Β1 – Ιστογράμματα mid (κέντρα διαστημάτων)",
       x = "mid (κέντρο ημερήσιου διαστήματος)", y = "Συχνότητα") +
  theme_paper()
```

B1 — Ιστογράμματα mid (κέντρα διαστημάτων)




Figure 6: Ιστογράμματα των mid (κέντρα διαστημάτων) για DIA και τις 15 μετοχές.

```
long_rd <- utils::stack(df_rad)
long_rd$ind <- factor(long_rd$ind, levels = colnames(df_rad))
ggplot(long_rd, aes(x = values)) +
  geom_histogram(bins = 40, fill = "#D55E00", colour = "white", linewidth = 0.1) +
  facet_wrap(~ ind, scales = "free", ncol = 4) +
  labs(title = "B1 — Ιστογράμματα rad (ημι-εύρη / ενδοημερήσια αστάθεια)",
       x = "rad (ημι-εύρος ημερήσιου διαστήματος)", y = "Συχνότητα") +
  theme_paper()
```

B1 — Ιστογράμματα rad (ημι-εύρη / ενδοημερήσια αστάθεια)




Figure 7: Ιστογράμματα των rad (ημι-εύρη): έντονα δεξιά-λοξά και μη-αρνητικά.

5.1.2 Boxplots του rad ανά Τομέα


```
# Μακρά μορφή: για κάθε ανεξάρτητη μετοχή και τομέα συγκεντρώνουμε rad
long_rad <- do.call(rbind, lapply(seq_len(nrow(sectors_df)), function(i) {
  data.frame(Sector = sectors_df$Sector[i],
    Ticker = sectors_df$Ticker[i],
    rad = df_rad[[sectors_df$Ticker[i]]])
})
```

```

)))

long_rad$Sector <- factor(long_rad$Sector,
                          levels = c("Tech", "Fin", "Comm", "Cons", "Health"))
ggplot(long_rad, aes(x = Sector, y = rad, fill = Sector)) +
  geom_boxplot(outlier.alpha = 0.2, outlier.size = 0.4, linewidth = 0.3) +
  scale_fill_manual(values = sector_pal) +
  labs(title = "B1.1 — Ημερήσιο ημι-εύρος (rad) ανά τομέα",
       x = "Τομέας", y = "rad (ενδοημερήσια αστάθεια)") +
  theme_paper()

```



5.1.3 Συσχέτιση μεταξύ mid και rad

```

# Για κάθε ticker, υπολογίζουμε τη συσχέτιση μεταξύ της mid και της rad σειράς του
mid_rad_cor <- sapply(colnames(df_mid),
                      function(nm) cor(df_mid[[nm]], df_rad[[nm]]))
ktab(data.frame(Ticker = names(mid_rad_cor),
                Cor_mid_rad = round(mid_rad_cor, 3)),
      caption = "Πίνακας B1.1 — Συσχέτιση mid-rad ανά ticker.", row.names = FALSE)

```

Table 5: Πίνακας B1.1 — Συσχέτιση mid-rad ανά ticker.

Ticker	Cor_mid_rad
DIA	-0.085

NVDA	0.005
AAPL	0.000
MSFT	0.033
BAC	-0.030
JPM	-0.024
V	-0.083
GOOGL	0.038
META	0.103
NFLX	0.041
AMZN	-0.018
TSLA	0.006
HD	-0.064
LLY	0.090
JNJ	0.003
UNH	-0.122

```
# Μεγέθη για τον σχολιασμό
sector_mean_rad <- tapply(long_rad$rad, long_rad$Sector, mean)
b1_sec_max <- names(which.max(sector_mean_rad))
b1_sec_min <- names(which.min(sector_mean_rad))
b1_cor_md <- mean(mid_rad_cor[setdiff(names(mid_rad_cor), "DIA")])
```

5.1.3.1 Σχολιασμός B1

- Τα ιστογράμματα του **mid** έχουν σχήμα παρόμοιο με τα ιστογράμματα των κλασικών αποδόσεων (A1) — γεγονός θεωρητικά αναμενόμενο, αφού το **mid** αποτελεί ομοιόμορφη εκτίμηση του κέντρου της ημερήσιας πορείας τιμών.
- Τα ιστογράμματα του **rad** είναι **έντονα δεξιά λοξά** και **αυστηρά μη-αρνητικά** ($\text{rad} \geq 0$ εξ ορισμού). Αυτό υπαγορεύει τη χρήση log-transform ή GLM στην ενδεχόμενη μοντελοποίηση της αστάθειας.
- Το boxplot ανά τομέα δείχνει ότι η μεγαλύτερη **μέση** ενδοημερήσια αστάθεια (**rad**) εμφανίζεται στον τομέα **Cons** και η χαμηλότερη στον **Fin**.
- Η μέση **συσχέτιση mid-rad** των ανεξάρτητων μετοχών είναι -0.001 — μικρή κατ' απόλυτη τιμή, που υπογραμμίζει ότι **το κέντρο και το εύρος της ημέρας μεταφέρουν διαφορετική πληροφορία**, δικαιολογώντας τη διττή ανάλυση της επόμενης ενότητας.

5.2 B2. Διαστηματική Παλινδρόμηση — Μέθοδος των Κέντρων (Billard & Diday, 2000)

Ακολουθώντας την εκφώνηση, προσαρμόζουμε **δύο ανεξάρτητες γραμμικές παλινδρομήσεις**: μία στα κέντρα (**mid**) και μία στα ημι-εύρη (**rad**). Σημείωση ακριβείας: η εκτίμηση *ξεχωριστής* εξίσωσης και για το εύρος αντιστοιχεί αυστηρά στη **Μέθοδο Κέντρου-και-Εύρους (Center and Range Method, CRM)** των Lima Neto and Carvalho (2008)· η αρχική **Μέθοδος Κέντρων** των Billard and Diday (2000) εκτιμά μόνο την εξίσωση των κέντρων και τη χρησιμοποιεί για αμφότερα τα άκρα του διαστήματος. Διατηρούμε τον όρο «Μέθοδος των Κέντρων» όπως στην εκφώνηση, υλοποιώντας τη γενίκευσή της (CRM, δηλαδή **mid και rad**).

```
# Μοντέλο για τα mids: εξηγούμε το κέντρο της απόδοσης του DIA
mid_data <- data.frame(Y = Y_mid, X_mid)
model_mid <- lm(Y ~ ., data = mid_data)
summary(model_mid)
```

Call:

```
lm(formula = Y ~ ., data = mid_data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0141172	-0.0016548	0.0000586	0.0015431	0.0106138

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)				
(Intercept)	-1.671e-04	7.498e-05	-2.229	0.025987	*			
NVDA	1.285e-02	4.117e-03	3.122	0.001839	**			
AAPL	6.255e-02	7.751e-03	8.070	1.65e-15	***			
MSFT	7.820e-02	8.732e-03	8.955	< 2e-16	***			
BAC	8.789e-02	1.029e-02	8.540	< 2e-16	***			
JPM	1.520e-01	1.184e-02	12.841	< 2e-16	***			
V	1.113e-01	8.775e-03	12.683	< 2e-16	***			
GOOGL	5.123e-03	6.377e-03	0.803	0.421974				
META	-4.433e-03	4.160e-03	-1.066	0.286805				
NFLX	6.648e-03	3.823e-03	1.739	0.082338	.			
AMZN	2.307e-02	5.938e-03	3.885	0.000108	***			
TSLA	2.962e-03	3.168e-03	0.935	0.349911				
HD	1.297e-01	8.141e-03	15.930	< 2e-16	***			
LLY	1.345e-02	4.918e-03	2.734	0.006340	**			
JNJ	1.005e-01	1.117e-02	8.993	< 2e-16	***			
UNH	7.865e-02	5.077e-03	15.492	< 2e-16	***			

Signif. codes:	0	'***'	0.001	'**'	0.01	'*' 0.05	'.' 0.1	' ' 1

Residual standard error: 0.002636 on 1237 degrees of freedom

Multiple R-squared: 0.8463, Adjusted R-squared: 0.8444

F-statistic: 454 on 15 and 1237 DF, p-value: < 2.2e-16

```
# Μοντέλο για τα rads: εξηγούμε την αστάθεια (ημι-εύρος) του DIA
# Σημείωση: το Y_rad ίσως έχει σχεδόν μηδενική διακύμανση -> πιθανό NaN R²
rad_data <- data.frame(Y = Y_rad, X_rad)

# Έλεγχος προσαπίας έναντι μηδενικής διακύμανσης στο Y_rad
var_Y_rad <- var(Y_rad, na.rm = TRUE)
cat("Διακύμανση Y_rad =", signif(var_Y_rad, 4), "\n")
```

Διακύμανση Y_rad = 1.071e-05

```
if (var_Y_rad > .Machine$double.eps * 100) {
  model_rad <- lm(Y ~ ., data = rad_data)
  print(summary(model_rad))
} else {
  cat("ΠΡΟΣΟΧΗ: το Y_rad έχει σχεδόν μηδενική διακύμανση -",
      "το rad model δεν είναι ερμηνεύσιμο (R² ~ NaN).\n")
  model_rad <- NULL
}
```

```
Call:
lm(formula = Y ~ ., data = rad_data)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0067081 -0.0008544  0.0000328  0.0008988  0.0125593

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0025254  0.0001527 -16.537  < 2e-16 ***
NVDA         0.0120420  0.0060051   2.005  0.045149 *
AAPL         0.0848039  0.0111401   7.612  5.31e-14 ***
MSFT         0.1152424  0.0149753   7.696  2.87e-14 ***
BAC          0.0464983  0.0130135   3.573  0.000366 ***
JPM          0.1595230  0.0146412  10.896  < 2e-16 ***
V            0.0617499  0.0121418   5.086  4.23e-07 ***
GOOGL        0.0152223  0.0111271   1.368  0.171547
META         0.0050821  0.0092452   0.550  0.582623
NFLX         0.0152106  0.0075104   2.025  0.043054 *
AMZN         0.0235841  0.0115802   2.037  0.041903 *
TSLA         0.0096741  0.0050017   1.934  0.053321 .
HD           0.1338908  0.0124425  10.761  < 2e-16 ***
LLY          0.0076613  0.0075406   1.016  0.309826
JNJ          0.0749776  0.0152035   4.932  9.27e-07 ***
UNH          0.0202035  0.0088689   2.278  0.022895 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.001509 on 1237 degrees of freedom
Multiple R-squared:  0.79, Adjusted R-squared:  0.7874
F-statistic: 310.2 on 15 and 1237 DF, p-value: < 2.2e-16
```

5.2.1 Γραφική Σύγκριση Παρατηρούμενων–Προβλεπόμενων Διαστημάτων


```
# Προβλέψεις mid (και rad αν είναι ερμηνεύσιμο)
yhat_mid <- as.numeric(predict(model_mid))
yhat_rad <- if (!is.null(model_rad)) as.numeric(predict(model_rad)) else rep(mean(Y_rad), length(Y_rad))

idx <- seq_len(min(100, length(Y_mid))) # κρατάμε τις πρώτες 100 παρατηρήσεις
plot_df <- data.frame(
  t = idx,
  obs_low = Y_mid[idx] - Y_rad[idx],
  obs_high = Y_mid[idx] + Y_rad[idx],
  pred_low = yhat_mid[idx] - yhat_rad[idx],
  pred_high = yhat_mid[idx] + yhat_rad[idx]
)

ggplot(plot_df, aes(x = t)) +
  geom_ribbon(aes(ymin = obs_low, ymax = obs_high, fill = "Παρατηρούμενο"),
    alpha = 0.55) +
  geom_ribbon(aes(ymin = pred_low, ymax = pred_high, fill = "Προβλεπόμενο (CRM)"),
    alpha = 0.5) +
  scale_fill_manual(values = c("Παρατηρούμενο" = "grey60",
    "Προβλεπόμενο (CRM)" = "#0072B2")) +
  labs(title = "B2.1 – Παρατηρούμενα vs Προβλεπόμενα διαστήματα DIA (πρώτες 100 ημέρες)",
    x = "Ημέρα (χρονικός δείκτης)",
    y = "Διάστημα απόδοσης [mid - rad, mid + rad]", fill = NULL) +
```

```
theme_paper() +
theme(legend.position = "top")
```

B2.1 — Παρατηρούμενα vs Προβλεπόμενα διαστήματα DIA (πρώτες 100 ημέρες)



5.2.2 Ακρίβεια Πρόβλεψης Διαστημάτων (RMSE κάτω/άνω ορίου)

Η ποιότητα της μεθόδου CRM δεν αποτυπώνεται μόνο από τα R^2 των δύο εξισώσεων, αλλά κυρίως από το πόσο καλά ανακατασκευάζεται το ίδιο το διάστημα $[\hat{L}, \hat{U}]$. Ακολουθώντας τους Lima Neto and Carvalho (2008), αξιολογούμε χωριστά το κάτω όριο $\hat{L} = \hat{Y}_{mid} - \hat{Y}_{rad}$ και το άνω όριο $\hat{U} = \hat{Y}_{mid} + \hat{Y}_{rad}$, καθώς και το ποσοστό προβλέψεων με έγκυρη διάταξη ($\hat{U} \geq \hat{L}$).

```
# Παρατηρούμενα και προβλεπόμενα όρια διαστήματος (πλήρες δείγμα)
obs_L <- Y_mid - Y_rad;      obs_U <- Y_mid + Y_rad
pred_L <- yhat_mid - yhat_rad; pred_U <- yhat_mid + yhat_rad

rmse <- function(a, b) sqrt(mean((a - b)^2))
b2_rmse_L <- rmse(obs_L, pred_L)      # RMSE κάτω ορίου
b2_rmse_U <- rmse(obs_U, pred_U)      # RMSE άνω ορίου
b2_valid <- mean(pred_U >= pred_L) * 100 # % έγκυρων (μη-αναστροφών) διαστημάτων
# Σύγκριση με «αφελέη» πρόβλεψη (σταθερό μέσο διάστημα) -> βελτίωση RMSE
naive_L <- mean(obs_L); naive_U <- mean(obs_U)
b2_skill_L <- (1 - b2_rmse_L / rmse(obs_L, rep(naive_L, length(obs_L)))) * 100
b2_skill_U <- (1 - b2_rmse_U / rmse(obs_U, rep(naive_U, length(obs_U)))) * 100
```

```
b2_acc_tab <- data.frame(
  `Όριο` = c("Κάτω (L)", "Άνω (U)"),
  `RMSE` = signif(c(b2_rmse_L, b2_rmse_U), 3),
  `Βελτίωση έναντι αφελούς (%)` = round(c(b2_skill_L, b2_skill_U), 1),
  check.names = FALSE)
ktab(b2_acc_tab, digits = 3, row.names = FALSE,
  caption = "Πίνακας B2.1 – Ακρίβεια πρόβλεψης ορίων διαστήματος (CRM).")
```

Table 6: Πίνακας B2.1 — Ακρίβεια πρόβλεψης ορίων διαστήματος (CRM).

Όριο	RMSE	Βελτίωση έναντι αφελούς (%)
Κάτω (L)	0.003	60.7
Άνω (U)	0.003	58.0

5.2.2.1 Σχολιασμός B2

- **mid model:** Το R^2 του μοντέλου των κέντρων είναι **0.846**, παραπλήσιο με αυτό της κλασικής παλινδρόμησης (A5). Αυτό είναι θεωρητικά αναμενόμενο: τα κέντρα διατηρούν σχεδόν όλη την πληροφορία τάσης που εμπεριέχει η απόδοση Close-to-Close. Στατιστικά σημαντικές ($p < 0.05$) είναι **11** μεταβλητές: NVDA, AAPL, MSFT, BAC, JPM, V, AMZN, HD, LLY, JNJ, UNH.
- **rad model:** Η διακύμανση του Y_{rad} (αστάθεια του DIA) **δεν είναι μηδενική** ($\approx 1.07 \times 10^{-5}$) — ακριβώς επειδή ως Y επιλέχθηκε ο **ETF DIA** (και όχι ο ίδιος ο δείκτης Dow Jones, που λόγω τρόπου υπολογισμού θα έδινε σχεδόν μηδενικό rad). Το R^2 του rad μοντέλου είναι **0.79**, αλλά πρέπει να ερμηνευτεί με προσοχή:
 - **Είναι σε μεγάλο βαθμό μηχανικό (φαινόμενο άθροισης):** μια απλή παλινδρόμηση του Y_{rad} στον μέσο όρο των 15 επιμέρους rad δίνει ήδη $R^2 = 0.72$. Δηλαδή το εύρημα είναι κατά βάση η ταυτότητα «το εύρος του δείκτη $\approx$ μέσο εύρος των συστατικών», όχι μια ανακαλυφθείσα δομική σχέση.
 - **Η συμπερασματολογία OLS είναι άκυρη:** τα κατάλοιπα του rad μοντέλου είναι **έντονα αυτοσυσχετισμένα** (Ljung-Box $p < 0.001$, volatility clustering), οπότε τα μη-διορθωμένα p-values υπερεκτιμούν τη σημαντικότητα. **Υπό εύρωστους (HAC) εκτιμητές** οι στατιστικά σημαντικές μεταβλητές πέφτουν από 11 σε 7. Το ορθό συμπέρασμα είναι ότι η ενδοημερήσια αστάθεια του DIA αντανακλά έναν **ισχυρό κοινό παράγοντα αστάθειας** (market-wide volatility) — όχι ότι είναι «γραμμικά προβλέψιμη». Η σωστή μοντελοποίησή της απαιτεί δυναμικά υποδείγματα τύπου **GARCH** (βλ. Γ3, Δ6).
- **Ακρίβεια διαστημάτων (Πίνακας B2.1):** Τα RMSE των δύο ορίων είναι μικρά (κάτω: 0.00302, άνω: 0.00301) και η μέθοδος βελτιώνει την αφελή πρόβλεψη σταθερού διαστήματος κατά 60.7% (κάτω όριο) και 58% (άνω όριο). Επιπλέον, **100%** των προβλεπόμενων διαστημάτων έχουν έγκυρη διάταξη ($\hat{U} \geq \hat{L}$), δηλαδή η μη-περιορισμένη CRM εδώ δεν παράγει ανάστροφα διαστήματα — γι' αυτό και δεν χρειάζεται η περιοριστική παραλλαγή Constrained CRM (Lima Neto and Carvalho 2010).
- **Εξάρτηση από την περίοδο:** Όπως προειδοποιεί η εκφώνηση (FAQ), σε ηρεμότερες περιόδους η διακύμανση του Y_{rad} μπορεί να γίνει πολύ μικρή και το R^2 του rad μοντέλου να καταρρεύσει (ή να γίνει NaN). Στη δική μας πενταετία η αυξημένη μακροοικονομική μεταβλητότητα (πανδημία, πληθωρισμός, AI-cycle) διατήρησε ισχυρό σήμα και άρα αξιοσημείωτη ερμηνευτική ισχύ.

5.3 B3. Ανάλυση Κύριων Συνιστωσών στα mid (Σύγκριση με την A4)

```
pca_mid <- prcomp(X_mid, center = TRUE, scale. = TRUE)
summary(pca_mid)
```

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.2092	1.3230	1.09897	0.98478	0.91787	0.90347	0.86924
Proportion of Variance	0.3254	0.1167	0.08052	0.06465	0.05617	0.05442	0.05037
Cumulative Proportion	0.3254	0.4420	0.52257	0.58722	0.64339	0.69780	0.74818

	PC8	PC9	PC10	PC11	PC12	PC13	PC14
Standard deviation	0.81544	0.78848	0.74618	0.71357	0.6775	0.66141	0.60666
Proportion of Variance	0.04433	0.04145	0.03712	0.03395	0.0306	0.02916	0.02454
Cumulative Proportion	0.79251	0.83395	0.87107	0.90502	0.9356	0.96478	0.98931

	PC15
Standard deviation	0.40036
Proportion of Variance	0.01069
Cumulative Proportion	1.00000

5.3.1 Scree Plot και Σύγκριση Φορτίσεων

```
ev_cl <- pca_classical$sdev^2
ev_md <- pca_mid$sdev^2
scree_cmp <- rbind(
  data.frame(PC = seq_along(ev_cl), eig = ev_cl, Ανάλυση = "Κλασική (αποδόσεις)"),
  data.frame(PC = seq_along(ev_md), eig = ev_md, Ανάλυση = "PCA στα mid"))
ggplot(scree_cmp, aes(PC, eig, colour = Ανάλυση)) +
  geom_hline(yintercept = 1, linetype = 2, colour = "grey50") +
  geom_line(linewidth = 0.7) + geom_point(size = 1.8) +
  scale_colour_manual(values = c("Κλασική (αποδόσεις)" = "#0072B2",
                                "PCA στα mid" = "#D55E00")) +
  scale_x_continuous(breaks = seq(1, length(ev_cl), 2)) +
  labs(title = "B3.1 – Σύγκριση scree: κλασική PCA vs PCA στα mid",
       x = "Κύρια συνιστώσα (PC)", y = "Ιδιοτιμή (eigenvalue)", colour = NULL) +
  theme_paper() +
  theme(legend.position = "top")
```

B3.1 — Σύγκριση scree: κλασική PCA vs PCA στα mid




Figure 8: Επικαλυπτόμενα scree plots: κλασική PCA (αποδόσεις) vs PCA στα mid.

```
# Πόσο όμοιες είναι οι πρώτες συνιστώσες; Συγκρίνουμε τα Loadings.
common_pcs <- min(3, ncol(pca_mid$rotation), ncol(pca_classical$rotation))
cor_loadings_pc <- sapply(seq_len(common_pcs), function(k) {
  abs(cor(pca_mid$rotation[, k], pca_classical$rotation[, k]))
})

ktab(data.frame(PC = paste0("PC", seq_len(common_pcs)),
  AbsCor = round(cor_loadings_pc, 3)),
  caption = "Πίνακας B3.1 — Απόλυτη συσχέτιση loadings κλασικής PCA και PCA στα mid.",
  row.names = FALSE)
```

Table 7: Πίνακας B3.1 — Απόλυτη συσχέτιση loadings κλασικής PCA και PCA στα mid.

PC	AbsCor
PC1	0.986
PC2	0.991
PC3	0.979

5.3.1.1 Σχολιασμός B3

- Τα ποσοστά εξηγημένης διακύμανσης από την PCA-στα-mid είναι **σχεδόν ταυτόσημα** με αυτά της κλασικής PCA: η πρώτη συνιστώσα εξηγεί **32.5%** (έναντι 38.9% στην κλασική) και οι τρεις πρώτες **52.3%**.
- Η **απόλυτη συσχέτιση των loadings** μεταξύ των δύο αναλύσεων είναι PC1: 0.986, PC2: 0.991, PC3: 0.979. Οι τιμές (σχεδόν μονάδα) δείχνουν ότι:

Η οικονομική δομή που μετράμε δεν εξαρτάται από το αν χρησιμοποιούμε close-to-close ή mid αποδόσεις — είναι η ίδια **κοινή δομή κινήσεων αγοράς και κλάδων**.

- Το εύρημα δικαιολογεί εκ των υστέρων τη σύσταση της εκφώνησης: η κλασική PCA στα mid είναι έγκυρη και ερμηνεύσιμη, χωρίς ανάγκη περίπλοκης Interval PCA.

5.4 B4. Διαστηματική Παραγοντική Ανάλυση — Βιβλιογραφική Συζήτηση

Η ενότητα αυτή είναι, σύμφωνα με τις οδηγίες της εκφώνησης, **καθαρά βιβλιογραφική και θεωρητική** — δεν παρουσιάζεται υλοποίηση.

5.4.1 Γιατί δεν υπάρχει «εύκολη» Interval Factor Analysis;

Η κλασική παραγοντική ανάλυση (PAF, ML-FA, αλγόριθμος EM) βασίζεται **εξ ολοκλήρου στον πίνακα συσχετίσεων R** . Όταν οι μεταβλητές είναι διαστήματα και όχι σημεία, η κατασκευή ενός **μοναδικά καθορισμένου** πίνακα συσχετίσεων είναι μη τετριμμένη:

1. **Πολλαπλοί ορισμοί συνδιακύμανσης για διαστήματα**. Στη βιβλιογραφία (Bertrand & Goupil, 2000· Billard & Diday, 2003) έχουν προταθεί διαφορετικοί ορισμοί συνδιακύμανσης (centers method, vertices method, symbolic covariance, span-based covariance). Διαφορετική επιλογή $\rightarrow$ διαφορετικός $R \rightarrow$ διαφορετικά loadings $\rightarrow$ **μη μοναδική λύση**.
2. **Πρόβλημα ταυτοποίησης (identifiability)**. Στο κλασικό μοντέλο FA, εάν Λ είναι ένας πίνακας φορτίσεων, τότε για κάθε ορθογώνιο Q είναι ΛQ επίσης λύση. Για διαστηματικές μεταβλητές, στην ταυτοποίηση προστίθεται και η **ασάφεια ορισμού του πεδίου ορισμού** (η μεταβλητή «τύπου διαστήματος» δεν είναι ένα σημείο, αλλά ένα **πεδίο τιμών** — άρα η παραγοντική δομή πρέπει να σέβεται και την τάξη/ένταξη των ορίων του διαστήματος).
3. **Δεν υπάρχει σταθερή μετρική**. Σε αντίθεση με την κλασική PCA που έχει μοναδική γεωμετρική ερμηνεία (μέγιστη διακύμανση), η Interval FA δεν διαθέτει γενικά αποδεκτή μετρική «καλής εφαρμογής» που να έχει επικρατήσει.

5.4.2 Οι προτάσεις των Douzal-Chouakria & Diday (2007· 2011)

Στη σχετική βιβλιογραφία για συμβολική/διαστηματική πολυμεταβλητή ανάλυση (Douzal-Chouakria and Diday 2007; Douzal-Chouakria et al. 2011) οι συγγραφείς:

- Προτείνουν να αντικατασταθεί κάθε διάστημα από ζεύγος (**mid, rad**) και να εφαρμοστεί FA σε ένα **διπλάσιας διάστασης** πίνακα — αλλά υποδεικνύουν ότι αυτό **δεν είναι ισοδύναμο** με την παραγοντοποίηση του αρχικού symbolic πίνακα.
- Συζητούν την έννοια της **interval correlation** η οποία δεν είναι πάντα στο $[-1, 1]$ και μπορεί να δίνει ασύμμετρα αποτελέσματα.
- Παρουσιάζουν αλγόριθμους που απαιτούν εξειδικευμένο λογισμικό· δεν υπάρχει τυποποιημένο πακέτο R/Python που να εφαρμόζει τη μέθοδό τους με σταθερά, αναπαραγώγιμα αποτελέσματα. Το παλαιότερο πακέτο RSDA παρουσιάζει γνωστές αστάθειες υλοποίησης.

5.4.3 Γιατί η Interval PCA είναι ευκολότερη από την Interval FA;

Η Interval PCA, ακόμη και με τις εναλλακτικές μετρικές, βασίζεται σε **γεωμετρική παραγοντοποίηση πίνακα** η οποία έχει αναλυτική λύση (SVD-like). Η Interval FA, αντίθετα, βασίζεται σε **πιθανοθεωρητικό μοντέλο** με latent parameters που πρέπει να εκτιμηθούν με αλγόριθμο EM ή ML — αλγόριθμοι που απαιτούν τη μοναδικότητα του covariance και υποθέσεις για την κατανομή των σφαλμάτων. Για διαστηματικά δεδομένα, **δεν υπάρχουν αντίστοιχα αποδεκτά πιθανοθεωρητικά μοντέλα** (π.χ. multivariate interval-normal κατανομές δεν είναι καθιερωμένες).

5.4.4 Πορισματικός Σχολιασμός

Στην παρούσα εργασία, σύμφωνα και με την οδηγία της εκφώνησης, **δεν επιχειρούμε** υλοποίηση Interval FA. Αντί αυτής, στην ενότητα **A3 εφαρμόσαμε κλασική FA** στις αποδόσεις και στην **B3 κλασική PCA στα mids**, που αποτελεί την επιστημονικά αποδεκτή πρακτική προσέγγιση.

5.5 B5. Δομικά Μοντέλα Εξισώσεων (SEM) — Bonus

Στο πλαίσιο του bonus, εκτιμούμε ένα μοντέλο Δομικών Εξισώσεων **με μία λανθάνουσα μεταβλητή «Tech-Factor»** που μετράται από τα κέντρα των τριών τεχνολογικών μετοχών (NVDA, AAPL, MSFT). Η εξίσωση δομής συνδέει την απόδοση του DIA (στο mid) με αυτόν τον τεχνολογικό παράγοντα:

$$\text{TechFactor} = \sim \text{NVDA}_{\text{mid}} + \text{AAPL}_{\text{mid}} + \text{MSFT}_{\text{mid}}$$
$$Y_{\text{mid}} \sim \text{TechFactor}$$

```
# Προετοιμασία δεδομένων για το lavaan
sem_data <- data.frame(
  Y_mid = Y_mid,
  NVDA_mid = X_mid$NVDA,
  AAPL_mid = X_mid$AAPL,
  MSFT_mid = X_mid$MSFT
)

# Ορισμός του μοντέλου SEM
# =~ : μετρητικό μοντέλο (latent =~ indicators)
# ~ : δομικό μοντέλο (outcome ~ predictors)
sem_model <- '
  TechFactor =~ NVDA_mid + AAPL_mid + MSFT_mid
  Y_mid ~ TechFactor
'

fit_sem <- lavaan::sem(model = sem_model, data = sem_data)
lavaan::summary(fit_sem, fit.measures = TRUE, standardized = TRUE)
```

lavaan 0.6-21 ended normally after 79 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	8

Number of observations	1253
------------------------	------

Model Test User Model:

Test statistic	44.534
Degrees of freedom	2
P-value (Chi-square)	0.000

Model Test Baseline Model:

Test statistic	1492.054
Degrees of freedom	6
P-value	0.000

User Model versus Baseline Model:

Comparative Fit Index (CFI)	0.971
Tucker-Lewis Index (TLI)	0.914

Loglikelihood and Information Criteria:

Loglikelihood user model (H0)	15554.537
Loglikelihood unrestricted model (H1)	15576.804
Akaike (AIC)	-31093.075
Bayesian (BIC)	-31052.008
Sample-size adjusted Bayesian (SABIC)	-31077.420

Root Mean Square Error of Approximation:

RMSEA	0.130
90 Percent confidence interval - lower	0.099
90 Percent confidence interval - upper	0.165
P-value H ₀ : RMSEA ≤ 0.050	0.000
P-value H ₀ : RMSEA ≥ 0.080	0.995

Standardized Root Mean Square Residual:

SRMR	0.031
------	-------

Parameter Estimates:

Standard errors	Standard
Information	Expected
Information saturated (h1) model	Structured

Latent Variables:

	Estimate	Std.Err	z-value	P(> z)	Std.lv	Std.all
TechFactor =~						
NVDA_mid	1.000				0.016	0.658
AAPL_mid	0.551	0.029	19.027	0.000	0.009	0.684
MSFT_mid	0.588	0.029	20.248	0.000	0.009	0.765

Regressions:

	Estimate	Std.Err	z-value	P(> z)	Std.lv	Std.all
Y_mid ~						
TechFactor	0.300	0.015	19.512	0.000	0.005	0.710

Variances:

	Estimate	Std.Err	z-value	P(> z)	Std.lv	Std.all
--	----------	---------	---------	---------	--------	---------

.NVDA_mid	0.000	0.000	20.139	0.000	0.000	0.568
.AAPL_mid	0.000	0.000	19.358	0.000	0.000	0.533
.MSFT_mid	0.000	0.000	15.869	0.000	0.000	0.415
.Y_mid	0.000	0.000	18.395	0.000	0.000	0.495
TechFactor	0.000	0.000	11.716	0.000	1.000	1.000

```
# Εξαγωγή των βασικών μέτρων προσαρμογής
fm <- lavaan::fitMeasures(fit_sem,
  c("cfi", "tli", "rmsea", "srmr", "chisq", "df", "pvalue"))
ktab(data.frame(Measure = names(fm), Value = round(as.numeric(fm), 3)),
  caption = "Πίνακας B5.1 – Συγκεντρωτικά μέτρα προσαρμογής SEM.", row.names = FALSE)
```

Table 8: Πίνακας B5.1 — Συγκεντρωτικά μέτρα προσαρμογής SEM.

Measure	Value
cfi	0.971
tli	0.914
rmsea	0.130
srmr	0.031
chisq	44.534
df	2.000
pvalue	0.000

5.5.0.1 Σχολιασμός B5 (SEM)

- **Latent loadings:** Και οι τρεις τεχνολογικές μετοχές φορτώνουν θετικά και σημαντικά στον λανθάνοντα παράγοντα «TechFactor»: η ελάχιστη τυποποιημένη φόρτιση είναι **0.66**, ένδειξη ισχυρής και ομοιόμορφης μέτρησης του παράγοντα (τα NVDA/AAPL/MSFT οδηγούνται από κοινούς παράγοντες — AI cycle, semiconductors, επιτόκια).
- **Δομικός συντελεστής (Y_mid ~ TechFactor):** Εκτίμηση **0.3** με p-value < 0.001 — θετικός και ισχυρά σημαντικός: ο τεχνολογικός παράγοντας επιδρά θετικά στο κέντρο της απόδοσης του DIA.
- **Δείκτες προσαρμογής (df = 2, n = 1253):**
 - **CFI = 0.971, TLI = 0.914** (κατώφλι «καλής» 0.95).
 - **RMSEA = 0.13** (κατώφλι «καλής» 0.06· 0.08–0.10 οριακό).
 - **SRMR = 0.031** (κατώφλι 0.08).

Η εικόνα προσαρμογής είναι **μεικτή και πρέπει να ερμηνευτεί προσεκτικά**: το SRMR (0.031) είναι εξαιρετικά υψηλό και το CFI πάνω από το κατώφλι, αλλά το **RMSEA = 0.13 υποδηλώνει δομική απόκλιση** (ένας μόνο λανθάνων παράγοντας δεν συλλαμβάνει τέλεια τη συν-διακύμανση NVDA/AAPL/MSFT) και το TLI είναι κάτω από το κατώφλι. Δύο επιμέρους παράγοντες: (α) με df = 2 (πολύ λίγοι βαθμοί ελευθερίας) ο RMSEA είναι γνωστό ότι **υπερεκτιμάται**: (β) το μεγάλο n κάνει το χ^2 -test να απορρίπτει ακόμη και μικρές αποκλίσεις (αυτό αφορά μόνο το χ^2 , όχι τον RMSEA). Σημειώνεται επίσης ότι ο εκτιμητής δείχνει προειδοποίηση οριακής ταυτοποίησης (μη θετικά ορισμένος πίνακας συνδιακύμανσης παραμέτρων), συμβατή με τη σχεδόν-τέλεια συγγραμμικότητα των τριών δεικτών.

- **Επεκτάσεις:** Ένα πιο σύνθετο SEM θα μπορούσε να ενσωματώσει και άλλους λανθάνοντες παράγοντες (FinFactor, HealthFactor, CommFactor) και να ελέγξει την υπόθεση ενός γενικευμένου «MarketFactor». Εδώ διατηρούμε τη μινιμαλιστική μορφή που ορίζει η εκφώνηση.

6 Μέρος Γ — Σύγκριση και Συμπεράσματα

6.1 Γ1. Συγκεντρωτικός Πίνακας Σύγκρισης

```
# Βασικά συνοπτικά μέτρα από κάθε προσέγγιση
r2_classical <- summary(lm_step)$r.squared
adj_classical <- summary(lm_step)$adj.r.squared
n_sig_classical <- sum(summary(lm_step)$coefficients[-1, "Pr(>|t|)"] < 0.05)

r2_mid <- summary(model_mid)$r.squared
adj_mid <- summary(model_mid)$adj.r.squared
n_sig_mid <- sum(summary(model_mid)$coefficients[-1, "Pr(>|t|)"] < 0.05)

if (!is.null(model_rad)) {
  r2_rad <- summary(model_rad)$r.squared
  adj_rad <- summary(model_rad)$adj.r.squared
  n_sig_rad <- sum(summary(model_rad)$coefficients[-1, "Pr(>|t|)"] < 0.05)
} else {
  r2_rad <- NA; adj_rad <- NA; n_sig_rad <- NA
}

comp <- data.frame(
  Προσέγγιση = c("Κλασική (A5, stepwise)", "Διαστηματική mid (B2)", "Διαστηματική rad (B2)"),
  R2 = round(c(r2_classical, r2_mid, r2_rad), 4),
  Adj_R2 = round(c(adj_classical, adj_mid, adj_rad), 4),
  N_significant_Vars = c(n_sig_classical, n_sig_mid, n_sig_rad),
  Ερμηνευσιμότητα = c("Υψηλή", "Υψηλή",
    ifelse(is.na(r2_rad) || r2_rad < 0.05, "Χαμηλή", "Μέτρια-υψηλή"))
)
ktab(comp, digits = 4, caption = "Πίνακας C1.1 – Συγκριτικός πίνακας τριών προσεγγίσεων.",
  row.names = FALSE)
```

Table 9: Πίνακας C1.1 — Συγκριτικός πίνακας τριών προσεγγίσεων.

Προσέγγιση	R2	Adj_R2	N_significant_Vars	Ερμηνευσιμότητα
Κλασική (A5, stepwise)	0.8844	0.8834	11	Υψηλή
Διαστηματική mid (B2)	0.8463	0.8444	11	Υψηλή
Διαστηματική rad (B2)	0.7900	0.7874	11	Μέτρια-υψηλή

6.2 Γ2. Ερμηνεία Αποτελεσμάτων

- **Ποιοι τομείς/μετοχές είναι σημαντικοί στην κλασική παλινδρόμηση;** Το stepwise μοντέλο (A5) διατηρεί τις: NVDA, AAPL, MSFT, BAC, JPM, V, AMZN, HD, LLY, JNJ, UNH. Πρόκειται κατά κύριο λόγο για μετοχές που είναι συστατικά του δείκτη, σύμφωνα με την κατασκευή του DJIA ως **price-weighted average** 30 μετοχών. Οι μετοχές εκτός δείκτη (BAC, GOOGL, META, NFLX, TSLA, LLY) τείνουν να εμφανίζουν μικρότερους ή μη-σημαντικούς συντελεστές.
- **Αλλάζει η εικόνα όταν δουλεύουμε με τα mid;** Σχεδόν καθόλου. Το mid αποτελεί ακριβώς το μέσο όρο του ενδοημερήσιου διαστήματος και είναι **σχεδόν ταυτόσημο** με την Close-to-Close απόδοση όταν η ημερήσια κίνηση είναι περίπου συμμετρική. Συνεπώς, τα ίδια ζεύγη μετοχών παραμένουν σημαντικά και οι συντελεστές έχουν παρόμοιο μέγεθος και πρόσημο.

- **Τι μας λέει η ανάλυση rad για την αστάθεια;** Στο συγκεκριμένο δείγμα (2021–2025) το R^2 του rad μοντέλου είναι **0.79**, που υποδηλώνει έναν **ισχυρό κοινό παράγοντα αστάθειας** (market-wide volatility) στο cross-section. Δεν πρέπει όμως να ερμηνευτεί ως «γραμμική προβλεψιμότητα»: όπως δείξαμε στη B2, το R^2 είναι κατά κύριο λόγο **μηχανικό** ($R^2 \approx 0.72$ προκύπτει ήδη από τον απλό μέσο όρο των επιμέρους rad — ταυτότητα άθροισης), και η OLS συμπερασματολογία είναι άκυρη λόγω αυτοσυσχέτισης (υπό HAC οι σημαντικές μεταβλητές πέφτουν σε 7). Η ορθή μοντελοποίηση της αστάθειας απαιτεί δυναμικά υποδείγματα (GARCH).

Παρ’ όλα αυτά, η ίδια η **ύπαρξη** ενός μετρήσιμου κοινού παράγοντα αστάθειας είναι κάτι **που η κλασική Close-to-Close ανάλυση δεν μπορεί να αποκαλύψει** (δεν μετράει αστάθεια), οπότε η συνεισφορά της διαστηματικής μεθοδολογίας παραμένει σαφής.

Αξίζει να σημειωθεί ότι, σε διαφορετική περίοδο (π.χ. ήρεμη bull market), η διακύμανση του Y_{rad} ίσως είναι ακόμη μικρότερη και η ερμηνευτική ισχύς του μοντέλου να εξαφανιστεί — όπως προειδοποιεί η εκφώνηση. Στη δική μας περίπτωση, η μεγάλη μακροοικονομική αστάθεια της πενταετίας (πανδημία, inflation cycle, geopolitical shocks, AI rally) διατήρησε αρκετό σήμα ώστε η σχέση να είναι ανιχνεύσιμη.

6.3 Γ3. Κριτική και Περιορισμοί

- **Υπόθεση γραμμικότητας:** Όλα τα μοντέλα που εφαρμόστηκαν είναι γραμμικά. Στην πραγματικότητα, η σχέση μεταξύ μεμονωμένων μετοχών και του δείκτη D1A μπορεί να μην είναι αυστηρά γραμμική, ειδικά σε ακραίες ημέρες (μη-γραμμικά διαμετάφραστα, jump-diffusion processes, regime-switching).
- **Μη-κανονικότητα και ετεροσκεδαστικότητα:** Όπως δείξαμε στις ενότητες A1 και A5, οι αποδόσεις δεν είναι κανονικές και τα residuals παρουσιάζουν ετεροσκεδαστικότητα. Σε μια πληρέστερη μελέτη θα έπρεπε:
 - Είτε να εφαρμοστούν **robust standard errors** (HC3 sandwich estimator).
 - Είτε να προσαρμοστούν **GARCH(1,1)** στις σειρές για ρητή μοντελοποίηση της δομής αστάθειας.
- **Στατικός χρονικός ορίζοντας:** Χρησιμοποιήσαμε όλη την πενταετία 2021–2025. Οι σχέσεις μεταξύ μετοχών δεν είναι σταθερές στο χρόνο. Μια rolling-window ή Bayesian dynamic linear model θα αποκάλυπτε χρονικές αλλαγές.
- **Μη-εκτεταμένη επεξεργασία outliers:** Δεν αφαιρέθηκαν ακραίες παρατηρήσεις. Στην πράξη θα ήταν δόκιμη η χρήση **robust regression** (M-estimators) για να μη δεσπόζουν λίγες ακραίες παρατηρήσεις.
- **Περιορισμοί της Interval προσέγγισης:**
 - Η αναπαράσταση (mid, rad) χάνει την πληροφορία **της κατανομής εντός του διαστήματος** (π.χ. αν η μετοχή πέρασε περισσότερο χρόνο κοντά στο High ή στο Low).
 - Η Center Method των Billard & Diday προϋποθέτει **ανεξάρτητη εκτίμηση** των δύο εξισώσεων (mid και rad). Σύγχρονες παραλλαγές (Constrained Interval Regression, MinMax method) επιβάλλουν περιορισμούς ώστε το προβλεπόμενο διάστημα να μη γίνεται ανάστροφο.
 - Δεν υπάρχει καθιερωμένη Interval FA με αναπαραγωγή υλοποίηση (βλ. ενότητα B4).
- **Τι θα κάναμε διαφορετικά:**
 1. Θα ενσωματώναμε **GARCH** για ρητή μοντελοποίηση Y_{rad} (υλοποιείται στο Παράρτημα Δ9).
 2. Θα δοκιμάζαμε **MinMax** ή **Constrained Center & Range Method** (Lima Neto and Carvalho 2010) για interval regression που σέβεται την περιοριστική σχέση $rad \geq 0$ (η CCRM υλοποιείται στο Παράρτημα Δ5).
 3. Θα προσθέταμε **μακρο-ελεγχόμενες** μεταβλητές (επιτόκια, VIX, oil prices) για βελτιωμένη ερμηνεία.

4. Θα εφαρμόζαμε **SEM με πολλαπλούς λανθάνοντες παράγοντες** ανά τομέα (υλοποιείται στο Παράρτημα Δ8, όπου αναδεικνύεται και ο περιορισμός ταυτοποίησης).
-

7 Σύνοψη – Συμπεράσματα

Η εργασία αυτή υλοποίησε ένα ολοκληρωμένο πειραματικό πλαίσιο σύγκρισης κλασικής και διαστηματικής στατιστικής μοντελοποίησης για τη σχέση του δείκτη DIA με 15 βασικές αμερικανικές μετοχές. Τα κύρια ευρήματα είναι:

1. Η **παραγοντική δομή** των μετοχών αναδεικνύει 3 παράγοντες — έναν ευρύ mega-cap growth (τεχνολογία/επικοινωνίες/καταναλωτικά), έναν στενό τραπεζικό (BAC, JPM) και έναν αμυντικό/υγείας — με τη συν-κίνηση των αποδόσεων να **μην ταυτίζεται πάντα με τον ονομαστικό κλάδο** (π.χ. η V κινείται με το growth, η HD με τις αμυντικές). Η δομή παραμένει σταθερή σε κλασική και διαστηματική (mid) προσέγγιση.
 2. Η **κλασική γραμμική παλινδρόμηση** εξηγεί άριστα τη συμπεριφορά του DIA χρησιμοποιώντας τις μετοχές που πραγματικά συμμετέχουν στον δείκτη.
 3. Η **διαστηματική παλινδρόμηση στα κέντρα** (μέθοδος Center-and-Range, Lima Neto & de Carvalho 2008, γενίκευση της Billard & Diday 2000) δίνει ουσιαστικά ίδια αποτελέσματα στο mid, επιβεβαιώνοντάς την ως αξιόπιστη και ερμηνεύσιμη.
 4. Η **παλινδρόμηση στα rad** αποκαλύπτει έναν **ισχυρό κοινό παράγοντα ενδοημερήσιας αστάθειας** (market-wide volatility) — κάτι που η κλασική Close-to-Close ανάλυση δεν μπορεί να μετρήσει. Το υψηλό R^2 ($= 0.79$) είναι ωστόσο **κυρίως μηχανικό** (≈ 0.72 προκύπτει από τον μέσο όρο των συστατικών — ταυτότητα άθροισης) και η OLS συμπερασματολογία είναι άκυρη λόγω αυτοσυσχέτισης· επομένως **δεν** πρόκειται για γνήσια «προβλεψιμότητα» της αστάθειας, η οποία απαιτεί δυναμικά υποδείγματα (GARCH).
 5. Το **SEM (bonus B5)** πιστοποιεί την ύπαρξη ενός λανθάνοντος «τεχνολογικού παράγοντα» που επηρεάζει σημαντικά την κεντρική απόδοση του DIA.
-

8 Παράρτημα — Επεκτάσεις πέραν της εκφώνησης

Οι παρακάτω αναλύσεις **δεν απαιτούνται** από την εκφώνηση προστίθενται επειδή εφαρμόζονται στο **υλικό του μαθήματος** (Διάλεξη 13 και 14, υποδειγματική εργασία) και εμπλουτίζουν την ανάλυση περαιτέρω.

8.1 Δ1. Δέντρο Παλινδρόμησης — Σημαντικότητα Μεταβλητών για τον DIA

Στη **Διάλεξη 13** (§«Εύρεση υποδείγματος») χρησιμοποιείται δέντρο παλινδρόμησης (rpart) για **μη-γραμμική** διερεύνηση και κατάταξη της σημαντικότητας των μεταβλητών — εργαλείο που συμπληρώνει τη γραμμική stepwise επιλογή της A5. Εφαρμόζουμε την ίδια μεθοδολογία στον DIA: προσαρμόζουμε δέντρο, το **κλαδεύουμε** στο cp με το ελάχιστο σφάλμα διασταύρωσης (cross-validation), και αναφέρουμε τη σχετική σημαντικότητα κάθε μετοχής.

```

set.seed(1125886)
tree_data <- data.frame(DIA = Y_classical, X_classical)
tree_full <- rpart(DIA ~ ., data = tree_data, method = "anova")
best_cp <- tree_full$cptable[which.min(tree_full$cptable[, "xerror"]), "CP"]
tree <- prune(tree_full, cp = best_cp)
rpart.plot(tree, type = 4, fallen.leaves = FALSE, box.palette = "Blues",
  main = "Δ1.1 — Δέντρο παλινδρόμησης για τον DIA")

```

Δ1.1 — Δέντρο παλινδρόμησης για τον DIA




Figure 9: Κλαδεμένο δέντρο παλινδρόμησης για τον DIA (μέθοδος anova).

```

vi <- round(100 * prop.table(tree$variable.importance), 2)
ktab(data.frame(Μετοχή = names(vi), `Σημαντικότητα (%)` = as.numeric(vi),
  check.names = FALSE),
  caption = "Πίνακας Δ1.1 — Σχετική σημαντικότητα μεταβλητών (δέντρο παλινδρόμησης).",
  row.names = FALSE)

```

Table 10: Πίνακας Δ1.1 — Σχετική σημαντικότητα μεταβλητών (δέντρο παλινδρόμησης).

Μετοχή	Σημαντικότητα (%)
JPM	25.13
V	15.06
BAC	13.68

MSFT	11.01
HD	8.01
AAPL	7.85
AMZN	6.24
GOOGL	6.08
NVDA	3.30
META	2.14
NFLX	0.70
JNJ	0.40
UNH	0.38

8.1.0.1 Σχολιασμός Δ1

- Οι τρεις μετοχές με τη μεγαλύτερη σημαντικότητα στο δέντρο είναι **JPM, V, BAC**. Και οι τρεις ανήκουν επίσης στο stepwise γραμμικό μοντέλο (A5), γεγονός που **διασταυρώνει** τα δύο ανεξάρτητα εργαλεία: η γραμμική (A5) και η μη-γραμμική (δέντρο) προσέγγιση συμφωνούν στις βαρύτερες μετοχές του δείκτη.
- Το δέντρο, σε αντίθεση με την παλινδρόμηση, αποτυπώνει **κατώφλια και αλληλεπιδράσεις** (π.χ. διαφορετική συμπεριφορά σε ημέρες μεγάλων κινήσεων) — απαντώντας εν μέρει στον περιορισμό μη-γραμμικότητας που επισημάναμε στη Γ3.

8.2 Δ2. PCA Biplot

Στη **Διάλεξη 14** το biplot αποτελεί τυποποιημένη οπτικοποίηση της PCA (ταυτόχρονη προβολή παρατηρήσεων και φορτίσεων). Το κατασκευάζουμε απευθείας από το αντικείμενο `prcomp` (χωρίς εξωτερικό πακέτο), προβάλλοντας τις φορτίσεις των μετοχών ως διανύσματα πάνω στο νέφος των ημερήσιων παρατηρήσεων στο επίπεδο PC1–PC2.

```
scores <- as.data.frame(pca_classical$x[, 1:2])
load_arrows <- as.data.frame(pca_classical$rotation[, 1:2])
load_arrows$var <- rownames(load_arrows)
arrow_scale <- 0.9 * max(abs(scores[, 1:2])) / max(abs(load_arrows[, 1:2]))
v1 <- 100 * eig_vals[1] / sum(eig_vals)
v2 <- 100 * eig_vals[2] / sum(eig_vals)
ggplot() +
  geom_point(data = scores, aes(PC1, PC2),
    alpha = 0.10, colour = "#56B4E9", size = 0.7) +
  geom_segment(data = load_arrows,
    aes(x = 0, y = 0, xend = PC1 * arrow_scale, yend = PC2 * arrow_scale),
    arrow = arrow(length = grid::unit(0.18, "cm")),
    colour = "#D55E00", linewidth = 0.5) +
  geom_text(data = load_arrows,
    aes(x = PC1 * arrow_scale * 1.08, y = PC2 * arrow_scale * 1.08, label = var),
    colour = "#D55E00", size = 3, check_overlap = TRUE) +
  labs(title = "Δ2.1 – PCA biplot (κλασικές αποδόσεις)",
    x = sprintf("PC1 (%.1f%%)", v1), y = sprintf("PC2 (%.1f%%)", v2)) +
  theme_paper()
```





Figure 10: PCA biplot (PC1–PC2): νέφος ημερών + διανύσματα φορτίσεων των μετοχών.

8.2.0.1 Σχολιασμός Δ2

- Σχεδόν όλα τα διανύσματα δείχνουν προς την ίδια κατεύθυνση στον άξονα PC1, οπτικοποιώντας τον κοινό *market factor* (PC1, 38.9%): οι μετοχές κινούνται μαζί.
- Ο άξονας PC2 (11.7%) διαχωρίζει τις growth/tech μετοχές από τις αμυντικές, σε πλήρη συμφωνία με την ερμηνεία της A4 και τη δομή παραγόντων της A3.

8.3 Δ3. Διμεταβλητή Ανάλυση DIA–Μετοχής

Ο υποχρεωτικός κατάλογος προ-μοντελοποίησης (Διάλεξη 13, «Μέρος 2») προβλέπει **διμεταβλητή διερεύνηση** κάθε σχέσης $Y-X$ πριν από την πολυμεταβλητή ανάλυση: scatter plot με loess (για μη-γραμμικότητα) και συντελεστές **Pearson** (γραμμική) & **Spearman** (μονότονη) συσχέτισης.

```
biv <- do.call(rbind, lapply(colnames(X_classical), function(nm)
  data.frame(X = X_classical[[nm]], DIA = Y_classical, Ticker = nm)))
biv$Ticker <- factor(biv$Ticker, levels = colnames(X_classical))
```

```
ggplot(biv, aes(X, DIA)) +
  geom_point(alpha = 0.06, colour = "#56B4E9", size = 0.5) +
  geom_smooth(method = "loess", se = FALSE, colour = "#0072B2", linewidth = 0.5) +
  geom_smooth(method = "lm", se = FALSE, colour = "#D55E00", linewidth = 0.5) +
  facet_wrap(~ Ticker, scales = "free_x", ncol = 4) +
  labs(title = "Δ3.1 — DIA vs κάθε μετοχή (loess μπλε, γραμμικό κόκκινο)",
       x = "Ημερήσια απόδοση μετοχής", y = "Ημερήσια απόδοση DIA") +
  theme_paper()
```




Figure 11: DIA vs κάθε μετοχή: loess (μπλε) και γραμμική (κόκκινη) προσαρμογή.

```

biv_cor <- data.frame(
  Μετοχή = colnames(X_classical),
  Pearson = sapply(X_classical, function(x) cor(x, Y_classical)),
  Spearman = sapply(X_classical, function(x) cor(x, Y_classical, method = "spearman")),
  check.names = FALSE)
biv_cor <- biv_cor[order(-biv_cor$Pearson), ]
ktab(biv_cor, digits = 3, row.names = FALSE,
     caption = "Πίνακας Δ3.1 – Συσχέτιση DIA–μετοχής (Pearson και Spearman).")

```

Table 11: Πίνακας Δ3.1 — Συσχέτιση DIA–μετοχής (Pearson και Spearman).

Μετοχή	Pearson	Spearman
JPM	0.714	0.681
BAC	0.693	0.643
V	0.688	0.656
AAPL	0.645	0.556
HD	0.641	0.637
MSFT	0.619	0.570
AMZN	0.571	0.510
GOOGL	0.535	0.506
NVDA	0.494	0.450
META	0.475	0.477
TSLA	0.433	0.395
UNH	0.399	0.448
NFLX	0.390	0.393
JNJ	0.356	0.374
LLY	0.294	0.325

8.3.0.1 Σχολιασμός Δ3

- Οι γραμμές loess (μπλε) είναι σχεδόν ευθείες και σχεδόν ταυτίζονται με τη γραμμική προσαρμογή (κόκκινη): **οι σχέσεις DIA–μετοχής είναι κατά βάση γραμμικές**, γεγονός που δικαιολογεί εκ των προτέρων τη χρήση γραμμικών υποδειγμάτων στη A5/B2.
- Pearson και Spearman **σχεδόν συμπίπτουν** (μέγιστη απόκλιση 0.089), επιβεβαιώνοντας την απουσία ισχυρής μονότονης-μη-γραμμικής δομής. Η ισχυρότερη συσχέτιση με τον DIA είναι της **JPM**.

8.4 Δ4. Παραγοντική Ανάλυση σε Βάθος: Πλάγια Περιστροφή, Αξιοπιστία, Παλινδρόμηση Σκορ

8.4.1 Πλάγια (oblique) περιστροφή και συσχέτιση παραγόντων

```

fa_obl <- psych::fa(X_classical, nfactors = 3, fm = "pa",
  rotate = "oblimin", scores = "regression")
cat("Πίνακας συσχέτισης παραγόντων (oblimin – επιτρέπει συσχετισμένους παράγοντες):\n")

```

Πίνακας συσχέτισης παραγόντων (oblimin – επιτρέπει συσχετισμένους παράγοντες):

```
print(round(fa_obl$Phi, 3))
```

```
      PA1   PA3   PA2
PA1 1.000 0.460 0.142
PA3 0.460 1.000 0.292
PA2 0.142 0.292 1.000
```

8.4.2 Αξιοπιστία (Cronbach's α) ανά παράγοντα

```
# Ομαδοποίηση από τη μέγιστη φόρτιση varimax (A3): fa_groups από το chunk a3-facts
alpha_by_factor <- sapply(fa_groups, function(grp) {
  if (length(grp) < 2) return(NA_real_)
  suppressWarnings(suppressMessages(
    psych::alpha(X_classical[, grp], check.keys = TRUE)$total$raw_alpha))
})
ktab(data.frame(Παράγοντας = paste0("F", seq_along(alpha_by_factor)),
  Μετοχές = vapply(fa_groups, paste, character(1), collapse = ", "),
  `Cronbach α` = round(alpha_by_factor, 3), check.names = FALSE),
  caption = "Πίνακας Δ4.1 – Εσωτερική συνέπεια (Cronbach's  $\alpha$ ) ανά παράγοντα.",
  row.names = FALSE)
```

Table 12: Πίνακας Δ4.1 — Εσωτερική συνέπεια (Cronbach's α) ανά παράγοντα.

Παράγοντας	Μετοχές	Cronbach α
F1	NVDA, AAPL, MSFT, V, GOOGL, META, NFLX, AMZN, TSLA	0.868
F2	BAC, JPM	0.895
F3	HD, LLY, JNJ, UNH	0.485

8.4.3 Παλινδρόμηση στα factor scores

```
fa_sc <- as.data.frame(fa_model$scores)
names(fa_sc) <- paste0("F", seq_len(ncol(fa_sc)))
fs_model <- lm(Y_classical ~ ., data = fa_sc)
summary(fs_model)
```

Call:

```
lm(formula = Y_classical ~ ., data = fa_sc)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-0.0175685 -0.0021389  0.0000983  0.0020418  0.0186025
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0004178  0.0001008   4.144 3.64e-05 ***
F1           0.0051367  0.0001074  47.821 < 2e-16 ***
F2           0.0051208  0.0001095  46.756 < 2e-16 ***
F3           0.0053122  0.0001250  42.502 < 2e-16 ***
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003569 on 1249 degrees of freedom
Multiple R-squared: 0.852, Adjusted R-squared: 0.8516
F-statistic: 2397 on 3 and 1249 DF, p-value: < 2.2e-16

8.4.3.1 Σχολιασμός Δ4

- **Πλάγια περιστροφή:** Η μέγιστη συσχέτιση μεταξύ παραγόντων (oblimin) είναι 0.46. Είναι μη-αμελητέα, ένδειξη ότι οι παράγοντες δεν είναι πλήρως ανεξάρτητοι (η oblimin δίνει πιο ρεαλιστική εικόνα από τη varimax).
- **Αξιοπιστία (Cronbach's α):** Εδώ το α δεν έχει την κλασική ψυχομετρική έννοια — μετρά τη μέση εντός-ομάδας συν-κίνηση των αποδόσεων (είναι μονότονη συνάρτηση της μέσης συσχέτισης των μελών). Οι τιμές διαφέρουν ουσιαστικά: ο ευρύς growth παράγοντας έχει υψηλό α , αλλά ο αμυντικός/υγείας παράγοντας έχει χαμηλό $\alpha = 0.485$ — επιβεβαιώνοντας (όπως και η A3) ότι πρόκειται για ετερογενή ομάδα (HD + τρεις διαφορετικές μετοχές υγείας) με ασθενή κοινή κίνηση. Επιπλέον, το α ενός διμελούς παράγοντα (BAC, JPM) είναι εγγενώς ασταθές και πρέπει να ερμηνεύεται με επιφύλαξη.
- **Παλινδρόμηση σκορ:** Με μόλις 3 ορθογώνια factor scores ως παλινδρομητές, το R^2 είναι **0.852** (έναντι 0.884 του πλήρους stepwise μοντέλου A5) — αξιοσημείωτη συμπύκνωση: τρεις παράγοντες συλλαμβάνουν το μεγαλύτερο μέρος της ερμηνευτικής ισχύος των 15 μετοχών.

8.5 Δ5. Περιορισμένη Μέθοδος Κέντρου-και-Εύρους (CCRM)

Η μη-περιορισμένη CRM (B2) μπορεί θεωρητικά να παράγει **αρνητικό** προβλεπόμενο ημι-εύρος. Η **Constrained CRM** (Lima Neto and Carvalho 2010) επαναπροσαρμόζει την εξίσωση του εύρους με **μη-αρνητικά ελάχιστα τετράγωνα** (NNLS), εγγυώμενη $\text{rad} \geq 0$.

```
Xr_mat <- as.matrix(cbind(Intercept = 1, X_rad))
nn <- nnls::nnls(Xr_mat, Y_rad) # συντελεστές >= 0
yhat_mid_h <- as.numeric(predict(model_mid))
yhat_rad_ccrm <- if (!is.null(model_rad)) as.numeric(predict(model_rad)) else rep(mean(Y_rad),
  ↪ length(Y_rad))
yhat_rad_ccrm <- as.numeric(Xr_mat %*% nn$x)

obs_L <- Y_mid - Y_rad; obs_U <- Y_mid + Y_rad; w_obs <- obs_U - obs_L
ival_metrics <- function(yhat_rad) {
  pL <- yhat_mid_h - yhat_rad; pU <- yhat_mid_h + yhat_rad
  overlap <- pmax(0, pmin(obs_U, pU) - pmax(obs_L, pL))
  c(RMSE_L = sqrt(mean((obs_L - pL)^2)),
    RMSE_U = sqrt(mean((obs_U - pU)^2)),
    Κάλυψη = mean(overlap / w_obs),
    Efficiency = mean((pU - pL) / w_obs),
    `Εγκυρα %` = 100 * mean(pU >= pL))
}
tab_ccrm <- rbind(CRM = ival_metrics(yhat_rad_ccrm), CCRM = ival_metrics(yhat_rad_ccrm))
ktab(tab_ccrm, digits = 4,
  caption = "Πίνακας Δ5.1 – Σύγκριση CRM (μη περιορισμένη) vs CCRM (rad ≥ 0).")
```

Table 13: Πίνακας Δ5.1 — Σύγκριση CRM (μη περιορισμένη) vs CCRM ($\text{rad} \geq 0$).

	RMSE_L	RMSE_U	Κάλυψη	Efficiency	Έγκυρα %
CRM	0.0030	0.0030	0.7889	1.0696	100
CCRM	0.0031	0.0031	0.8287	1.1710	100

8.5.0.1 Σχολιασμός Δ5

- Στο μοντέλο εύρους της CRM, **1** συντελεστής είναι αρνητικός, αλλά οι προβλεπόμενες τιμές rad είναι αρνητικές σε **0** ημέρες — δηλαδή η μη περιορισμένη CRM παράγει ήδη 100% έγκυρα διαστήματα εδώ.
- Συνεπώς οι μετρικές CRM και CCRM είναι **σχεδόν ταυτόσημες** (Πίνακας Δ5.1): ο περιορισμός $\hat{\text{rad}} \geq 0$ είναι **μη-δεσμευτικός** για το συγκεκριμένο dataset. Αυτό είναι ένα ουσιαστικό, αναφέρσιμο εύρημα — η CCRM προσφέρει εγγύηση εγκυρότητας χωρίς κόστος ακρίβειας, ενώ σε πιο «ήσυχα»/ασταθή δείγματα όπου η CRM παραβιάζει το $\text{rad} \geq 0$ η διαφορά θα ήταν ουσιώδης.

8.6 Δ6. Εύρωση Συμπερασματολογία & Διαγνωστικοί Έλεγχοι Χρονοσειράς

Επειδή η A5 εντόπισε **ετεροσκεδαστικότητα** (Breusch-Pagan $p \approx 10^{-6}$), επαναυπολογίζουμε τα p-values με **εύρωστους** εκτιμητές διακύμανσης: HC3 (White) για ετεροσκεδαστικότητα και Newey-West (HAC) για ετεροσκεδαστικότητα + αυτοσυσχέτιση.

```
ct_ols <- summary(lm_step)$coefficients
ct_hc3 <- lmtest::coefest(lm_step, vcov. = sandwich::vcovHC(lm_step, type = "HC3"))
ct_hac <- lmtest::coefest(lm_step, vcov. = sandwich::NeweyWest(lm_step, lag = 5, prewhite = FALSE))
rob <- data.frame(
  Μεταβλητή = sub("\\(Intercept\\)", "Σταθερά", rownames(ct_ols)),
  Συντελεστής = round(ct_ols[, "Estimate"], 4),
  `p_OLS` = signif(ct_ols[, "Pr(>|t|)"], 2),
  `p_HC3` = signif(ct_hc3[, "Pr(>|t|)"], 2),
  `p_HAC` = signif(ct_hac[, "Pr(>|t|)"], 2),
  check.names = FALSE)
ktab(rob, digits = 4, row.names = FALSE,
  caption = "Πίνακας Δ6.1 — Εύρωση συμπερασματολογία: p-values OLS vs HC3 vs Newey-West HAC.")
```

Table 14: Πίνακας Δ6.1 — Εύρωση συμπερασματολογία: p-values OLS vs HC3 vs Newey-West HAC.

Μεταβλητή	Συντελεστής	p_OLS	p_HC3	p_HAC
Σταθερά	-0.0001	0.3200	0.3200	0.3100
NVDA	0.0127	0.0009	0.0024	0.0033
AAPL	0.0732	0.0000	0.0000	0.0000
MSFT	0.0817	0.0000	0.0000	0.0000
BAC	0.0971	0.0000	0.0000	0.0000
JPM	0.1384	0.0000	0.0000	0.0000
V	0.1120	0.0000	0.0000	0.0000
AMZN	0.0262	0.0000	0.0001	0.0002
HD	0.1228	0.0000	0.0000	0.0000
LLY	0.0160	0.0008	0.0010	0.0015

JNJ	0.0917	0.0000	0.0000	0.0000
UNH	0.0839	0.0000	0.0000	0.0000

```
res <- as.numeric(resid(lm_step))
cat("Ljung-Box (αυτοσυσχέτιση καταλοίπων, lag 10):\n")
```

Ljung-Box (αυτοσυσχέτιση καταλοίπων, lag 10):

```
print(Box.test(res, lag = 10, type = "Ljung-Box"))
```

Box-Ljung test

data: res
X-squared = 9.116, df = 10, p-value = 0.5211

```
# ARCH-LM (δεσμευμένη ετεροσκεδαστικότητα - ARCH effects), χειροκίνητα:
p_arch <- 5; emb <- embed(res^2, p_arch + 1)
arch_fit <- lm(emb[, 1] ~ emb[, -1])
arch_LM <- nrow(emb) * summary(arch_fit)$r.squared
cat(sprintf("\nARCH-LM (lag %d): LM = %.1f, df = %d, p = %.3g\n",
            p_arch, arch_LM, p_arch, pchisq(arch_LM, p_arch, lower.tail = FALSE)))
```

ARCH-LM (lag 5): LM = 21.4, df = 5, p = 0.000695

```
cat("\nADF test (H0: μοναδιαία ρίζα / μη στασιμότητα):\n")
```

ADF test (H0: μοναδιαία ρίζα / μη στασιμότητα):

```
print(suppressWarnings(tseries::adf.test(Y_classical)))
```

Augmented Dickey-Fuller Test

data: Y_classical
Dickey-Fuller = -10.981, Lag order = 10, p-value = 0.01
alternative hypothesis: stationary

```
cat("\nKPSS test (H0: στασιμότητα):\n")
```

KPSS test (H0: στασιμότητα):

```
print(suppressWarnings(tseries::kpss.test(Y_classical)))
```

KPSS Test for Level Stationarity

data: Y_classical

KPSS Level = 0.068215, Truncation lag parameter = 7, p-value = 0.1

8.6.0.1 Σχολιασμός Δ6

- **Εύρωστα p-values:** Παρά την ετεροσκεδαστικότητα/αυτοσυσχέτιση, τα συμπεράσματα είναι **σταθερά**: η αλλαγή από OLS σε HAC μεταβάλλει το πλήθος σημαντικών συντελεστών ($\alpha=0.05$) κατά 0 — οι βαρύτερες μετοχές παραμένουν ισχυρά σημαντικές με εύρωστους εκτιμητές.
- **Ljung-Box** ($p = 0.521$): δεν εντοπίζεται σημαντική αυτοσυσχέτιση καταλοίπων.
- **ARCH-LM** ($p = 6.95 \times 10^{-4}$): ισχυρές ARCH επιδράσεις — δεσμευμένη ετεροσκεδαστικότητα (volatility clustering), που δικαιολογεί μοντέλα τύπου GARCH ως μελλοντική επέκταση.
- **Στασιμότητα:** Το ADF απορρίπτει τη μοναδιαία ρίζα ($p < 0.01$, στο όριο αναφοράς του ελέγχου) και το KPSS δεν απορρίπτει τη στασιμότητα ($p > 0.10$) — οι αποδόσεις είναι **στάσιμες**, προϋπόθεση εγκυρότητας της παλινδρόμησης (σε αντίθεση με τις μη-στάσιμες τιμές).

8.7 Δ7. Σταθερότητα Εκτός Δείγματος (Out-of-Sample)

Σημαντική διευκρίνιση: Η παλινδρόμηση είναι **σύγχρονη** — η απόδοση του DIA την ημέρα t ερμηνεύεται από τις αποδόσεις των μετοχών την **ίδια** ημέρα t . Επειδή ο DIA είναι (κατά κατασκευή) σχεδόν ένα σταθμισμένο καλάθι αυτών των μετοχών, αυτό αποτελεί **ανακατασκευή του καλαθιού, ΟΧΙ πρόβλεψη**. Το out-of-sample R^2 εδώ ελέγχει τη **σταθερότητα της ερμηνευτικής σχέσης** (απουσία overfitting) σε χρονολογικά μεταγενέστερα δεδομένα — δεν αποτελεί ισχυρισμό προβλεψιμότητας. Χωρίζουμε χρονολογικά (χωρίς ανακάτεμα) σε **80% train / 20% test**.

```
n_obs2 <- length(Y_classical); cut <- floor(0.8 * n_obs2)
tr <- seq_len(cut); te <- (cut + 1):n_obs2
oos_one <- function(Y, X) {
  d <- data.frame(Y = Y, X)
  m <- lm(Y ~ ., data = d[tr, ]); ph <- predict(m, newdata = d[te, ])
  sse <- sum((Y[te] - ph)^2); sst <- sum((Y[te] - mean(Y[tr]))^2)
  c(R2 = 1 - sse / sst, RMSE = sqrt(mean((Y[te] - ph)^2)), MAE = mean(abs(Y[te] - ph)))
}
oos <- rbind(`Κλασική` = oos_one(Y_classical, X_classical),
  `Διάστημα mid` = oos_one(Y_mid, X_mid),
  `Διάστημα rad` = oos_one(Y_rad, X_rad))
ktab(oos, digits = 4,
  caption = "Πίνακας Δ7.1 – Επίδοση εκτός δείγματος (χρονολογικό 80/20 split).")
```

Table 15: Πίνακας Δ7.1 — Επίδοση εκτός δείγματος (χρονολογικό 80/20 split).

	R2	RMSE	MAE
Κλασική	0.8655	0.0038	0.0029
Διάστημα mid	0.8232	0.0031	0.0024
Διάστημα rad	0.8553	0.0017	0.0012


```
dcl <- data.frame(Y = Y_classical, X_classical)
pred_ew <- vapply(cut:(n_obs2 - 1), function(i) {
  m <- lm(Y ~ ., data = dcl[seq_len(i), ])
  as.numeric(predict(m, newdata = dcl[i + 1, ], drop = FALSE)))
}, numeric(1))
ew_idx <- (cut + 1):n_obs2
ew_df <- data.frame(Actual = Y_classical[ew_idx], Predicted = pred_ew)
ew_rmse <- sqrt(mean((ew_df$Actual - ew_df$Predicted)^2))
ggplot(ew_df, aes(Actual, Predicted)) +
  geom_point(alpha = 0.30, colour = "#0072B2", size = 0.8) +
  geom_abline(slope = 1, intercept = 0, colour = "#D55E00", linetype = 2) +
  labs(title = sprintf("Δ7.1 — Σύγχρονη ανακατασκευή εκτός δείγματος: RMSE = %.4f", ew_rmse),
       x = "Πραγματική απόδοση DIA", y = "Ανακατασκευασμένη απόδοση DIA") +
  theme_paper()
```




Figure 12: Σύγχρονη ανακατασκευή του DIA εκτός δείγματος (expanding window): προβλεπόμενες vs πραγματικές τιμές.

```
# το ίδιο σχήμα, αλλά με πραγματική υστέρηση 1 ημέρας ( $X_{t-1} \rightarrow Y_t$ ): γνήσια πρόβλεψη
dlag <- data.frame(Y = Y_classical[-1], X_classical[-nrow(X_classical), ])
nL <- nrow(dlag); cutL <- floor(0.8 * nL) # δικό του 80/20 split (n-1 γραμμές)
trL <- seq_len(cutL); teL <- (cutL + 1):nL
m_lag <- lm(Y ~ ., data = dlag[trL, ])
ph_lag <- predict(m_lag, newdata = dlag[teL, ])
oos_r2_lag <- 1 - sum((dlag$Y[teL] - ph_lag)^2) / sum((dlag$Y[teL] - mean(dlag$Y[trL]))^2)
cat("OOS R2 με ΓΝΗΣΙΑ υστέρηση 1 ημέρας (πραγματική πρόβλεψη):", round(oos_r2_lag, 3), "\n")
```

OOS R^2 με ΓΝΗΣΙΑ υστέρηση 1 ημέρας (πραγματική πρόβλεψη): -0.016

8.7.0.1 Σχολιασμός Δ7

- **Σταθερότητα (σύγχρονη):** Το κλασικό μοντέλο διατηρεί υψηλό out-of-sample $R^2 = 0.865$ στο μεταγενέστερο 20% — η ερμηνευτική σχέση είναι **σταθερή και δεν οφείλεται σε overfitting**. Τα μοντέλα mid δίνουν σχεδόν ταυτόσημη επίδοση. Όμως, όπως τονίστηκε, αυτό είναι **ανακατασκευή του καλαθιού** (σύγχρονοι παλινδρομητές), **όχι πρόβλεψη**.
- **Γνήσια προβλεψιμότητα (έλεγχος υστέρησης):** Όταν επαναλάβουμε το ίδιο σχήμα με **πραγματική υστέρηση μίας ημέρας** ($X_{t-1} \rightarrow Y_t$), το out-of-sample R^2 καταρρέει σε **-0.016** (πρακτικά μηδέν / αρνητικό) — οι ημερήσιες αποδόσεις του DIA **δεν είναι προβλέψιμες** από τις χθεσινές αποδόσεις των μετοχών, σύμφωνα με την υπόθεση αποτελεσματικής αγοράς. Το υψηλό σύγχρονο R^2 αντανακλά αποκλειστικά τη λογιστική ταυτότητα «δείκτης $\approx$ καλάθι συστατικών», όχι προβλεπτική ικανότητα.

8.8 Δ8. Πολυπαραγοντικό Δομικό Υπόδειγμα (SEM)

Επεκτείνουμε το μινιμαλιστικό SEM της B5 σε **τέσσερις λανθάνοντες κλαδικούς παράγοντες** (Tech, Fin, Comm, Health), καθένας με 3 δείκτες, που μαζί ερμηνεύουν το κέντρο της απόδοσης του DIA. Χρησιμοποιούμε τον **εύρωστο εκτιμητή MLR**.

```
# Σε ποσοστιαίες αποδόσεις (*100) για αριθμητική ευστάθεια του εκτιμητή.
sem_data2 <- data.frame(Y_mid = Y_mid, X_mid) * 100
model2 <- '
  Tech   =~ NVDA + AAPL + MSFT
  Fin    =~ BAC + JPM + V
  Comm   =~ GOOGL + META + NFLX
  Health =~ LLY + JNJ + UNH
  Y_mid ~ Tech + Fin + Comm + Health
'

fit2 <- tryCatch(suppressWarnings(lavaan::sem(model2, data = sem_data2, estimator = "MLR")),
  error = function(e) NULL)
conv2 <- !is.null(fit2) && isTRUE(lavaan::lavInspect(fit2, "converged"))
# έλεγχος παραδεκτότητας (όχι μόνο σύγκλισης): Heywood case (αρνητική εκτιμώμενη
# διακύμανση) ή τυποποιημένος συντελεστής > 1 (αδύνατος) -> μη παραδεκτή λύση.
neg_var2 <- NA; max_std2 <- NA; adm2 <- FALSE
if (conv2) {
  pev <- lavaan::parameterEstimates(fit2)
  neg_var2 <- any(pev$op == "~" & pev$lhs == pev$rhs & pev$est < 0)
  ss2 <- lavaan::standardizedSolution(fit2)
  max_std2 <- max(abs(ss2$est.std[ss2$op == "~"]))
  adm2 <- !neg_var2 && max_std2 <= 1.0001
}
if (conv2) {
  fm2 <- lavaan::fitMeasures(fit2, c("cfi", "tli", "rmsea", "srmr", "chisq", "df"))
  ktab(data.frame(Δείκτης = names(fm2), Τιμή = round(as.numeric(fm2), 3), check.names = FALSE),
    caption = "Πίνακας Δ8.1 – Μέτρα προσαρμογής πολυπαραγοντικού SEM (MLR).", row.names = FALSE)
  if (!adm2) cat("\nΠΡΟΣΟΧΗ – ΜΗ ΠΑΡΑΔΕΚΤΗ ΛΥΣΗ (Heywood case):",
    if (isTRUE(neg_var2)) "αρνητική εκτιμώμενη διακύμανση." else "",
    sprintf("μέγιστος τυποπ. δομικός συντελεστής = %.2f (> 1).\n", max_std2))
} else {
  fm2 <- NULL
  cat("Το πολυπαραγοντικό SEM ΔΕΝ συνέκλινε: πρόβλημα ταυτοποίησης – βλ. σχολιασμό.\n")
}
```

ΠΡΟΣΟΧΗ – ΜΗ ΠΑΡΑΔΕΚΤΗ ΛΥΣΗ (Heywood case): αρνητική εκτιμώμενη διακύμανση· μέγιστος τυποπ. δομικός
 $\hookrightarrow$ συντελεστής = 1.39 (> 1).

```

if (conv2) {
  pe2 <- lavaan::standardizedSolution(fit2)
  struct <- pe2[pe2$op == "~", c("rhs", "est.std", "pvalue")]
  names(struct) <- c("Παράγοντας", "Τυποπ. συντελεστής", "p-value")
  ktab(struct, digits = 3, row.names = FALSE,
        caption = "Πίνακας Δ8.2 — Δομικοί συντελεστές: κέντρο DIA ανά κλαδικό παράγοντα.")
} else {
  cat("(Δεν εμφανίζονται δομικοί συντελεστές — το μοντέλο δεν συνέκλινε.)\n")
}

```

Table 16: Πίνακας Δ8.2 — Δομικοί συντελεστές: κέντρο DIA ανά κλαδικό παράγοντα.

Παράγοντας	Τυποπ. συντελεστής	p-value
Tech	1.389	0.159
Fin	0.454	0.000
Comm	-0.954	0.336
Health	0.444	0.000

8.8.0.1 Σχολιασμός Δ8

- **Παραδεκτότητα της λύσης:** Αν και ο εκτιμητής επιστρέφει αριθμητική σύγκλιση (CFI = 0.921), η λύση είναι **μη παραδεκτή** — **Heywood case**: εμφανίζεται **αρνητική εκτιμώμενη διακύμανση** και ο τυποποιημένος δομικός συντελεστής φτάνει το **1.39 (> 1, μαθηματικά αδύνατο)**. Επομένως οι επιμέρους δομικοί συντελεστές του Πίνακα Δ8.2 **ΔΕΝ είναι ερμηνεύσιμοι** — δεν μπορούμε να πούμε «ποιος κλάδος επηρεάζει περισσότερο».
- **Αιτία — ταυτοποίηση & πολυσυγγραμμικότητα:** Οι κλαδικοί παράγοντες είναι **έντονα συσχετισμένοι** (κοινός παράγοντας αγοράς), γεγονός που — όπως προειδοποιεί η Διάλεξη 16 — οδηγεί ακριβώς σε τέτοιες μη παραδεκτές/ασταθείς λύσεις (το συνολικό «μήνυμα αγοράς» μοιράζεται ασταθώς μεταξύ συσχετισμένων παραγόντων, παράγοντας συντελεστές > 1 και αρνητικές διακυμάνσεις). Πρόκειται για **γνήσιο μεθοδολογικό περιορισμό** του πολυπαραγοντικού SEM σε ισχυρά συσχετισμένα χρηματιστηριακά δεδομένα — και είναι ο λόγος που το **μινιμαλιστικό SEM της B5 (ένας παράγοντας)** είναι η σταθερά ερμηνεύσιμη επιλογή.

8.9 Δ9. Το rad ως Εκτιμητής Αστάθειας: Parkinson και GARCH

Το Μέρος Β μεταχειρίζεται το rad ως «τη διαστηματική πλευρά» των δεδομένων. Εδώ το συνδέουμε ρητά με τη χρηματοοικονομική βιβλιογραφία: το κανονικοποιημένο ημι-εύρος είναι ένας **range-based εκτιμητής αστάθειας** της οικογένειας του Parkinson (1980), και η δυναμική του συγκρίνεται με τη δεσμευμένη αστάθεια ενός GARCH(1,1) (Engle 1982; Bollerslev 1986).

8.9.1 Δ9.1 Σύγκριση με τον εκτιμητή του Parkinson

Ο Parkinson (1980) έδειξε ότι η ημερήσια διακύμανση εκτιμάται αποδοτικά από το εύρος: $\hat{\sigma}_{P,t}^2 = \ln^2(H_t/L_t)/(4 \ln 2)$. Για μικρές ημερήσιες κινήσεις $\ln(H/L) \approx (H - L)/L$, οπότε το $\text{rad}_t = (H_t - L_t)/(2C_{t-1})$ είναι, ως προς κλίμακα, το ίδιο μέγεθος — το επιβεβαιώνουμε εμπειρικά.

```

dia_ohlc <- prices_list$DIA
sig_park <- sqrt(log(as.numeric(Hi(dia_ohlc)) / as.numeric(Lo(dia_ohlc)))^2 / (4 * log(2)))
# ευθυγράμμιση με το panel (το panel χάνει την 1η μέρα λόγω Lag)
park_df <- data.frame(Date = index(dia_ohlc), sig_park = sig_park)
park_df <- park_df[match(as.Date(rownames(df_classical)), park_df$Date), ]
d9_cor_park <- cor(park_df$sig_park, Y_rad)

ggplot(data.frame(park = park_df$sig_park, rad = Y_rad), aes(park, rad)) +
  geom_point(alpha = 0.15, colour = "#0072B2", size = 0.7) +
  geom_smooth(method = "lm", se = FALSE, colour = "#D55E00", linewidth = 0.5) +
  labs(title = sprintf("Δ9.1 — rad vs Parkinson: r = %.3f", d9_cor_park),
       x = "Εκτιμητής Parkinson (ημερήσιο σ)", y = "rad (κανονικοποιημένο ημι-εύρος)") +
  theme_paper()

```




Figure 13: Το rad του DIA έναντι του εκτιμητή Parkinson: πρακτικά ταυτόσημα (ως προς κλίμακα).

8.9.1.1 Σχολιασμός Δ9.1

- Η συσχέτιση rad–Parkinson είναι $r = 1$ — πρακτικά ταύτιση. Το rad της διαστηματικής αναπαράστασης **είναι** ο εκτιμητής αστάθειας του Parkinson (με διαφορετική κανονικοποίηση: C_{t-1} αντί για L_t στον παρονομαστή). Η διαστηματική προσέγγιση του Μέρους Β αποκτά έτσι άμεση θεωρητική θεμελίωση στη βιβλιογραφία range-based volatility: ο εκτιμητής των Garman and Klass (1980) αποτελεί το OHLC-βελτιωμένο ανάλογο και φυσική μελλοντική επέκταση.

8.9.2 Δ9.2 GARCH(1,1) και σύγκριση με το rad

Η Δ6 τεκμηρίωσε ισχυρές ARCH επιδράσεις (LM $p < 0.001$) και τόσο η Γ3 όσο και η Β2 παραπέμπουν σε GARCH ως το ορθό δυναμικό μοντέλο αστάθειας. Το προσαρμόζουμε εδώ.

```

# GARCH(1,1) στις ποσοστιαίες αποδόσεις (x100 για αριθμητική ευστάθεια του optimizer)
r_pct <- Y_classical * 100
g_fit <- tryCatch(suppressWarnings(tseries::garch(r_pct, order = c(1, 1), trace = FALSE)),
  error = function(e) NULL)
if (!is.null(g_fit)) {
  co <- coef(g_fit) # a0 (omega), a1 (ARCH), b1 (GARCH)
  sig_g <- as.numeric(fitted(g_fit)[, 1]) / 100 # conditional sigma, πίσω σε απλές μονάδες
  d9_persist <- unname(co["a1"] + co["b1"])
  d9_cor_garch <- cor(sig_g, Y_rad, use = "complete.obs")
  # Ljung-Box στα τυποποιημένα τετραγωνισμένα κατάλοιπα: απορρόφησε το ARCH;
  z <- na.omit(residuals(g_fit))
  d9_lb_g <- Box.test(z^2, lag = 10, type = "Ljung-Box")$p.value
  cat(sprintf("GARCH(1,1): omega=%.4f alpha=%.3f beta=%.3f (a+b=%.3f)\n",
    co["a0"], co["a1"], co["b1"], d9_persist))
  cat(sprintf("cor(sigma_t, rad_t) = %.3f Ljung-Box z^2 (lag 10): p = %.3f\n",
    d9_cor_garch, d9_lb_g))
  gd <- data.frame(Date = as.Date(rownames(df_classical)),
    `GARCH σ` = sig_g, rad = Y_rad, check.names = FALSE)
  gd_long <- rbind(data.frame(Date = gd$Date, value = gd$`GARCH σ`, Σειρά = "GARCH σ_t"),
    data.frame(Date = gd$Date, value = gd$rad, Σειρά = "rad_t"))
  print(
    ggplot(gd_long, aes(Date, value, colour = Σειρά)) +
      geom_line(linewidth = 0.3, alpha = 0.85, na.rm = TRUE) +
      scale_colour_manual(values = c("GARCH σ_t" = "#D55E00", "rad_t" = "#56B4E9")) +
      labs(title = "Δ9.2 – Δεσμευμένη αστάθεια GARCH vs rad (DIA)",
        x = NULL, y = "Ημερήσια αστάθεια", colour = NULL) +
      theme_paper() + theme(legend.position = "top")
  )
} else {
  d9_persist <- NA; d9_cor_garch <- NA; d9_lb_g <- NA
  cat("To GARCH(1,1) δεν συνέκλινε στο δείγμα - αναφέρεται ως περιορισμός.\n")
}

```

```

GARCH(1,1): omega=0.0411 alpha=0.110 beta=0.841 (a+b=0.951)
cor(sigma_t, rad_t) = 0.511 Ljung-Box z^2 (lag 10): p = 0.150

```

Δ9.2 — Δεσμευμένη αστάθεια GARCH vs rad (DIA)




Figure 14: Δεσμευμένη αστάθεια GARCH(1,1) του DIA και κανονικοποιημένο ημι-εύρος rad.

8.9.2.1 Σχολιασμός Δ9.2

- Το GARCH(1,1) εκτιμά **επιμονή αστάθειας $\alpha + \beta = 0.951$** — τυπική τιμή για ημερήσιες αποδόσεις δεικτών (ισχυρό volatility clustering, κοντά στη μονάδα αλλά στάσιμο). Τα τυποποιημένα κατάλοιπα δεν εμφανίζουν πλέον ARCH δομή (Ljung-Box στα z^2 $p = 0.15$) — το μοντέλο απορρόφησε την ετεροσκεδαστικότητα που τεκμηρίωσε η Δ6.
- **Σύνδεση με το rad:** η συσχέτιση της δεσμευμένης αστάθειας σ_t με το rad_t είναι **0.511**. Οι δύο σειρές παρακολουθούν τον ίδιο κοινό κύκλο αστάθειας (2022, Αύγ 2024, Απρ 2025), με το GARCH να δίνει την **εξομαλυσμένη/επίμονη** συνιστώσα και το rad την **ημερήσια πραγματοποιημένη** — δύο συμπληρωματικές όψεις: το rad είναι θορυβώδης αλλά άμεσος (range-based) εκτιμητής, το GARCH φιλτραρισμένη δυναμική πρόβλεψη. Σημειώνεται ότι πρόκειται για **σύγχρονη συν-κίνηση**, όχι αξιολόγηση προβλεπτικής ικανότητας.

8.10 Δ10. Χρονική Σταθερότητα: Rolling Window και Υποπερίοδοι

Η Γ3 αναγνώρισε ως περιορισμό τον **στατικό χρονικό ορίζοντα**. Εδώ ποσοτικοποιούμε τη χρονική μεταβλητότητα της σχέσης: κυλιόμενο παράθυρο 250 ημερών (≈ 1 έτος συναλλαγών) για το R^2 και τους συντελεστές, και σύγκριση των δύο μεγάλων υποπεριοδών.

```
dates_cl <- as.Date(rownames(df_classical))
dat_cl   <- data.frame(Y = Y_classical, X_classical)
win <- 250
idx_end <- win:nrow(dat_cl)
# ένα lm ανά παράθυρο (~1000 προσαρμογές, δευτερόλεπτα)
roll <- vapply(idx_end, function(i) {
  m <- lm(Y ~ ., data = dat_cl[(i - win + 1):i, ])
})
```

```

c(r2 = summary(m)$r.squared, coef(m)[c("JPM", "V", "HD")])
}, numeric(4))
roll_df <- data.frame(Date = dates_cl[idx_end], t(roll))
names(roll_df) <- c("Date", "R2", "JPM", "V", "HD")
roll_long <- reshape(roll_df, direction = "long", varying = c("R2", "JPM", "V", "HD"),
                     v.names = "value", times = c("R2", "JPM", "V", "HD"),
                     timevar = "Μέγεθος")
roll_long$Μέγεθος <- factor(roll_long$Μέγεθος,
                             levels = c("R2", "JPM", "V", "HD"),
                             labels = c("Κυλιόμενο R²", "β JPM", "β V", "β HD"))
ggplot(roll_long, aes(Date, value)) +
  geom_line(colour = "#0072B2", linewidth = 0.4) +
  facet_wrap(~ Μέγεθος, ncol = 2, scales = "free_y") +
  labs(title = "Δ10.1 – Κυλιόμενη (250 ημ.) εκτίμηση: R² και συντελεστές",
       x = NULL, y = NULL) +
  theme_paper()

```

Δ10.1 — Κυλιόμενη (250 ημ.) εκτίμηση: R² και συντελεστές




Figure 15: Κυλιόμενο (250 ημερών) R² του κλασικού μοντέλου και κυλιόμενοι συντελεστές των JPM, V, HD.

```

# υποπερίοδοι: 2021-2022 (πληθωρισμός/bear) vs 2023-2025 (AI rally κ.ε.)
cutd <- as.Date("2023-01-01")
sp <- function(rows) {
  m1 <- lm(Y ~ ., data = data.frame(Y = Y_classical, X_classical)[rows, ])
  m2 <- lm(Y ~ ., data = data.frame(Y = Y_rad, X_rad)[rows, ])
  c(`n ημέρες` = sum(rows),
    `R² κλασικό` = summary(m1)$r.squared,
    `R² rad` = summary(m2)$r.squared,

```

```

  `β JPM` = unname(coef(m1)["JPM"]))
}
sub_tab <- rbind(`2021–2022 (bear/πληθωρισμός)` = sp(dates_c1 < cutd),
  `2023–2025 (AI rally κ.ε.)` = sp(dates_c1 >= cutd))
ktab(sub_tab, digits = 3,
  caption = "Πίνακας Δ10.1 – Υποπερίοδοι: μέγεθος, R2 (κλασικό και rad), συντελεστής JPM.")

```

Table 17: Πίνακας Δ10.1 — Υποπερίοδοι: μέγεθος, R² (κλασικό και rad), συντελεστής JPM.

	n ημέρες	R ² κλασικό	R ² rad	β JPM
2021–2022 (bear/πληθωρισμός)	502	0.911	0.79	0.125
2023–2025 (AI rally κ.ε.)	751	0.869	0.80	0.136

8.10.0.1 Σχολιασμός Δ10

- Το κυλιόμενο R² κινείται μεταξύ **0.84** και **0.94**: η ερμηνευτική ισχύς του καλαθιού είναι διαχρονικά υψηλή αλλά όχι σταθερή — οι συντελεστές (π.χ. JPM) μετατοπίζονται αισθητά μεταξύ καθεστώτων, επιβεβαιώνοντας με στοιχεία τον περιορισμό της Γ3 περί στατικού ορίζοντα.
- Στις υποπερίοδοι (Πίνακας Δ10.1), το **R² του rad** διαφέρει μόλις κατά **0.01** μεταξύ 2021–22 και 2023–25. Η σταθερότητα αυτή είναι αξιοσημείωτη: ο κοινός παράγοντας ενδοημερήσιας αστάθειας παρέμεινε εξίσου ισχυρός και στα δύο καθεστώτα του δείγματός μας — η εξάρτηση από την περίοδο για την οποία προειδοποιεί η εκφώνηση (FAQ) δεν εκδηλώνεται σε αυτή την κλίμακα υποδιαίρεσης. Πιθανή εξήγηση: και οι δύο υποπερίοδοι περιέχουν επεισόδια υψηλής αστάθειας (2022 bear· Αύγ 2024 / Απρ 2025), οπότε καμία δεν είναι πραγματικά «ήρεμη».

8.11 Δ11. Αβεβαιότητα Εκτιμήσεων: Block Bootstrap και Time-Series CV

Τα R² των βασικών μοντέλων αναφέρονται ως σημειακές τιμές. Εδώ ποσοτικοποιούμε την αβεβαιότητά τους με **moving-block bootstrap** (Künsch 1989) — τα μπλοκ (μήκους 22 ημερών $\approx$ 1 μήνας συναλλαγών) διατηρούν την αυτοσυσχέτιση/volatility clustering εντός μπλοκ — και επεκτείνουμε τον έλεγχο του Δ7 σε **5 διαδοχικά χρονικά folds**.

```

set.seed(1125886)
block_boot_r2 <- function(Y, X, B = 1000, l = 22) {
  n <- length(Y); nb <- ceiling(n / l)
  vapply(seq_len(B), function(b) {
    starts <- sample.int(n - l + 1, nb, replace = TRUE)
    idx <- as.vector(outer(0:(l - 1), starts, "+"))[1:n] # συρραφή μπλοκ
    d <- data.frame(Y = Y[idx], X[idx, ])
    summary(lm(Y ~ ., data = d))$r.squared
  }, numeric(1))
}
bb_cl <- block_boot_r2(Y_classical, X_classical)
bb_rad <- block_boot_r2(Y_rad, X_rad)
ci <- function(v) quantile(v, c(0.025, 0.975))
boot_tab <- rbind(
  `Κλασικό R2` = c(Εκτίμηση = summary(lm(Y ~ ., data.frame(Y = Y_classical, X_classical)))$r.squared,
    ci(bb_cl)),
  `rad R2` = c(Εκτίμηση = summary(lm(Y ~ ., data.frame(Y = Y_rad, X_rad)))$r.squared,

```



```

        ci(bb_rad)))
colnames(boot_tab) <- c("Εκτίμηση", "2.5%", "97.5%")
ktab(boot_tab, digits = 3,
     caption = "Πίνακας Δ11.1 – Moving-block bootstrap: 95% διαστήματα εμπιστοσύνης (B = 1000, l = 22).")

```

Table 18: Πίνακας Δ11.1 — Moving-block bootstrap: 95% διαστήματα εμπιστοσύνης (B = 1000, l = 22).

	Εκτίμηση	2.5%	97.5%
Κλασικό R ²	0.885	0.863	0.909
rad R ²	0.790	0.681	0.873

```

# 5 expanding-origin folds: train έως 60..80%, test το επόμενο 5% (σύγχρονη ανακατασκευή,
# ίδια ειλικρινής ανάγνωση με το Δ7 - ΟΧΙ ισχυρισμός πρόβλεψης)
n <- length(Y_classical)
origins <- floor(n * seq(0.60, 0.80, by = 0.05))
cv_r2 <- vapply(origins, function(cutp) {
  test <- (cutp + 1):min(cutp + floor(0.05 * n), n)
  d <- data.frame(Y = Y_classical, X_classical)
  m <- lm(Y ~ ., data = d[seq_len(cutp), ])
  ph <- predict(m, newdata = d[test, ])
  1 - sum((Y_classical[test] - ph)^2) /
    sum((Y_classical[test] - mean(Y_classical[seq_len(cutp)]))^2)
}, numeric(1))
cv_tab <- data.frame(Fold = seq_along(origins),
  `Τέλος train` = format(as.Date(rownames(df_classical))[origins]),
  `OOS R^2` = round(cv_r2, 3), check.names = FALSE)
ktab(cv_tab, digits = 3, row.names = FALSE,
     caption = "Πίνακας Δ11.2 – Expanding-origin CV (5 folds): σύγχρονη ανακατασκευή εκτός δείγματος.")

```

Table 19: Πίνακας Δ11.2 — Expanding-origin CV (5 folds): σύγχρονη ανακατασκευή εκτός δείγματος.

Fold	Τέλος train	OOS R ²
1	2023-12-28	0.790
2	2024-04-01	0.768
3	2024-07-01	0.840
4	2024-09-27	0.846
5	2024-12-27	0.873

8.11.0.1 Σχολιασμός Δ11

- **Bootstrap:** Το 95% διάστημα για το κλασικό R² είναι [0.863, 0.909] και για το rad R² [0.681, 0.873] — στενά διαστήματα που δείχνουν ότι τα σημειακά R² δεν είναι προϊόν δειγματοληπτικού θορύβου, ακόμη και όταν σεβαστούμε την εξάρτηση της χρονοσειράς (μπλοκ αντί για ανεξάρτητες παρατηρήσεις).
- **Time-series CV:** Στα 5 διαδοχικά folds το εκτός-δείγματος R² (σύγχρονη ανακατασκευή) είναι 0.824 ± 0.043 — η σταθερότητα του Δ7 δεν εξαρτάται από ένα συγκεκριμένο σημείο διαχωρισμού.

8.12 Παράρτημα Αναπαραγωγιμότητας

Η μελέτη είναι πλήρως αναπαραγώγιμη: (α) σπόρος τυχειότητας `set.seed(1125886)` (= AM φοιτητή) σε όλα τα στοχαστικά βήματα· (β) τα δεδομένα (Yahoo Finance, 16 tickers OHLC, 02/01/2021–30/12/2025)

συνοδεύουν το .Rmd ως τοπικό στιγμιότυπο CSV στον φάκελο data/, ώστε το knitr να μην εξαρτάται από το δίκτυο· (γ) οι εξαρτήσεις εγκαθίστανται αυτόματα από το setup chunk. Το υπολογιστικό περιβάλλον:

```
sessionInfo()
```

```
R version 4.6.1 (2026-06-24 ucrt)
Platform: x86_64-w64-mingw32/x64
Running under: Windows 11 x64 (build 26200)

Matrix products: default
  LAPACK version 3.12.1

locale:
[1] LC_COLLATE=English_United States.utf8
[2] LC_CTYPE=English_United States.utf8
[3] LC_MONETARY=English_United States.utf8
[4] LC_NUMERIC=C
[5] LC_TIME=English_United States.utf8

time zone: Europe/Athens
tzcode source: internal

attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods   base

other attached packages:
[1] tseries_0.10-61  nnls_1.6      sandwich_3.1-2  lmtest_0.9-40
[5] rpart.plot_3.1.4 rpart_4.1.27  gvlma_1.0.0.3   kableExtra_1.4.1
[9] MASS_7.3-65      moments_0.14.1 car_3.1-5       carData_3.0-6
[13] knitr_1.51       lavaan_0.6-21 ggplot2_4.0.3   corrplot_0.95
[17] psych_2.6.5      quantmod_0.4.29 TTR_0.24.4      xts_0.14.2
[21] zoo_1.8-15

loaded via a namespace (and not attached):
[1] gtable_0.3.6      xfun_0.60      lattice_0.22-9
[4] quadprog_1.5-8    vctrs_0.7.3    tools_4.6.1
[7] generics_0.1.4    stats4_4.6.1   curl_7.1.0
[10] parallel_4.6.1    tibble_3.3.1   pkgconfig_2.0.3
[13] Matrix_1.7-5      RColorBrewer_1.1-3 S7_0.2.2
[16] lifecycle_1.0.5   compiler_4.6.1 farver_2.1.2
[19] stringr_1.6.0     GPArotation_2026.6-1 textshaping_1.0.5
[22] mnormt_2.1.2      tinytex_0.60   htmltools_0.5.9
[25] yaml_2.3.12       Formula_1.2-5  pillar_1.11.1
[28] pandoc_0.2.0      abind_1.4-8    nlme_3.1-169
[31] tidyselect_1.2.1  digest_0.6.39  stringi_1.8.7
[34] dplyr_1.2.1       labeling_0.4.3 splines_4.6.1
[37] fastmap_1.2.0     grid_4.6.1     cli_3.6.6
[40] magrittr_2.0.5    pbivnorm_0.6.0 withr_3.0.3
[43] scales_1.4.0      rappdirs_0.3.4 rmarkdown_2.31
[46] evaluate_1.0.5    viridisLite_0.4.3 mgcv_1.9-4
[49] rlang_1.3.0       glue_1.8.1     xml2_1.6.0
[52] svglite_2.2.2     rstudioapi_0.19.0 R6_2.6.1
[55] systemfonts_1.3.2 fs_2.1.0
```

Βιβλιογραφία

- Bertrand, Patrice, and Françoise Goupil. 2000. “Descriptive Statistics for Symbolic Data.” In *Analysis of Symbolic Data*, edited by Hans-Hermann Bock and Edwin Diday. Springer.
- Billard, Lynne, and Edwin Diday. 2000. “Regression Analysis for Interval-Valued Data.” In *Data Analysis, Classification, and Related Methods*, edited by Henk A. L. Kiers, Jean-Paul Rasson, Patrick J. F. Groenen, and Martin Schader. Springer.
- Billard, Lynne, and Edwin Diday. 2003. “From the Statistics of Data to the Statistics of Knowledge: Symbolic Data Analysis.” *Journal of the American Statistical Association* 98 (462): 470–87.
- Bollerslev, Tim. 1986. “Generalized Autoregressive Conditional Heteroskedasticity.” *Journal of Econometrics* 31 (3): 307–27.
- Cronbach, Lee J. 1951. “Coefficient Alpha and the Internal Structure of Tests.” *Psychometrika* 16 (3): 297–334.
- Douzal-Chouakria, Ahlame, Lynne Billard, and Edwin Diday. 2011. “Principal Component Analysis for Interval-Valued Observations.” *Statistical Analysis and Data Mining* 4 (2): 229–46.
- Douzal-Chouakria, Ahlame, and Edwin Diday. 2007. “Principal Component Analysis for Interval-Valued Data.” *Computational Statistics* 22 (4): 607–27.
- Engle, Robert F. 1982. “Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation.” *Econometrica* 50 (4): 987–1007.
- Garman, Mark B., and Michael J. Klass. 1980. “On the Estimation of Security Price Volatilities from Historical Data.” *Journal of Business* 53 (1): 67–78.
- Künsch, Hans R. 1989. “The Jackknife and the Bootstrap for General Stationary Observations.” *The Annals of Statistics* 17 (3): 1217–41.
- Kutner, Michael H., Christopher J. Nachtsheim, John Neter, and William Li. 2005. *Applied Linear Statistical Models*. 5th ed. McGraw-Hill.
- Lima Neto, Eufrásio de A., and Francisco de A. T. de Carvalho. 2008. “Centre and Range Method for Fitting a Linear Regression Model to Symbolic Interval Data.” *Computational Statistics & Data Analysis* 52 (3): 1500–1515.
- Lima Neto, Eufrásio de A., and Francisco de A. T. de Carvalho. 2010. “Constrained Linear Regression Models for Symbolic Interval-Valued Variables.” *Computational Statistics & Data Analysis* 54 (2): 333–47.
- Newey, Whitney K., and Kenneth D. West. 1987. “A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix.” *Econometrica* 55 (3): 703–8.
- Parkinson, Michael. 1980. “The Extreme Value Method for Estimating the Variance of the Rate of Return.” *Journal of Business* 53 (1): 61–65.

- Rosseel, Yves. 2012. “Lavaan: An R Package for Structural Equation Modeling.” *Journal of Statistical Software* 48 (2): 1–36.
- White, Halbert. 1980. “A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity.” *Econometrica* 48 (4): 817–38.
- Ανδρουλάκης, Γεώργιος Σ., and Θεοδούλα Ν. Γράψα. 2026. *Βοηθητικό Υλικό Για Το Project 2025-2026: Αριθμητικές Μέθοδοι Στην Επιστήμη Των Δεδομένων*. Σημειώσεις μαθήματος, Πανεπιστήμιο Πατρών.

Παράρτημα A: Πηγαίος κώδικας R Markdown

Alexandros Tsagkanos – AM: up1125886

Πλήρες περιεχόμενο του αρχείου project_report.Rmd

από το οποίο παρήχθη εξ ολοκλήρου η παρούσα αναφορά (knit σε PDF)

```
1 | ---
2 | title: "Project: Αριθμητικές Μέθοδοι στην Επιστήμη των Δεδομένων"
3 | subtitle: "Κλασική και Διαστηματική Ανάλυση Χρηματιστηριακών Αποδόσεων (DIA ETF και 15 μετοχές)"
4 | author: "Alexandros Tsagkanos – AM: up1125886"
5 | date: ``r format(Sys.Date(), '%d %B %Y')``
6 | output:
7 |   pdf_document:
8 |     toc: true
9 |     toc_depth: 3
10 |     number_sections: true
11 |     latex_engine: xelatex
12 |     fig_width: 7
13 |     fig_height: 4.3
14 |     fig_caption: true
15 |     highlight: tango
16 |   fontsize: 11pt
17 |   mainfont: "Times New Roman"
18 |   monofont: "Consolas"
19 |   geometry: "margin=2.4cm"
20 |   bibliography: refs.bib
21 |   link-citations: true
22 |   nocite: |
23 |     @kutner2005, @rosseel2012, @cronbach1951, @white1980, @neweywest1987,
24 |     @kunsch1989, @androulakis2026
25 | header-includes: |
26 |   \usepackage{fvextra}
27 |   \DefineVerbatimEnvironment{Highlighting}{Verbatim}{breaklines,breakanywhere,commandchars=\\\{\},fontsize=\footnotesize}
28 |   \DefineVerbatimEnvironment{verbatim}{Verbatim}{breaklines,breakanywhere,fontsize=\footnotesize}
29 |   \usepackage{float}
30 | ---
31 |
32 | ```{r setup, include=FALSE}
33 | # knitr defaults για όλο το report. cairo_pdf: διανυσματικά γραφήματα που
34 | # αποδίδουν σωστά τα ελληνικά. width=80 ώστε τα summary() να χωράνε στη σελίδα.
35 | knitr::opts_chunk$set(
36 |   echo = TRUE, message = FALSE, warning = FALSE, comment = "",
37 |   fig.align = "center", fig.pos = "H", out.width = "100%",
38 |   dev = "cairo_pdf", dpi = 150
39 | )
40 | options(width = 80)
41 |
42 | # Αν λείπει κάποιο πακέτο ή το LaTeX, το εγκαθιστούμε μία φορά (αλλιώς no-op).
43 | # Έτσι το report χτίζεται και σε καθαρό μηχάνημα / RStudio.
44 | .req <- c("quantmod", "psych", "corrplot", "ggplot2", "lavaan", "knitr",
45 |   "car", "moments", "MASS", "kableExtra", "gvlma", "rpart", "rpart.plot",
46 |   "GPArotation", "lmtest", "sandwich", "nnls", "tseries",
47 |   "rmarkdown", "tinytex")
48 | .missing <- .req[!vapply(.req, requireNamespace, logical(1), quietly = TRUE)]
49 | if (length(.missing) > 0)
50 |   install.packages(.missing, repos = "https://cloud.r-project.org")
51 | if (!nzchar(Sys.which("xelatex")) && !nzchar(Sys.which("pdflatex"))) &&
52 |   !tinytex::is_tinytex())
53 |   tinytex::install_tinytex()
54 | ```
55 |
```

```

56 | # Περίληψη {-}
57 |
58 | Η εργασία συγκρίνει την κλασική στατιστική ανάλυση (αποδόσεις Close-to-Close) με τη
59 | **διαστηματική ανάλυση δεδομένων** (ημερήσια διαστήματα [Low, High], αναπαράσταση mid/rad)
60 | για τη σχέση του ETF **DIA** (Dow Jones Industrial Average) με 15 μετοχές από 5 κλάδους του
61 | S&P 500, σε 1.253 ευθυγραμμισμένες ημερήσιες παρατηρήσεις της περιόδου 2021-2025. Η κλασική
62 | stepwise παλινδρόμηση εξηγεί το 88,4% της διακύμανσης του DIA και το μοντέλο των κέντρων
63 | (CRM) το 84,6% – σχεδόν ταυτόσημη εικόνα, όπως αναμένεται θεωρητικά. Η εξίσωση του εύρους
64 | (rad) εμφανίζει  $R^2 = 0,79$ , το οποίο όμως τεκμηριώνεται ότι είναι κατά κύριο λόγο
65 | **μηχανικό αποτέλεσμα άθροισης** (το 0,72 προκύπτει από τον απλό μέσο όρο των επιμέρους
66 | rad) με στατιστικά άκυρη OLS συμπερασματολογία λόγω αυτοσυσχέτισης· το ορθό συμπέρασμα
67 | είναι η ύπαρξη ισχυρού **κοινού παράγοντα ενδοημερήσιας αστάθειας**, μη παρατηρήσιμου από
68 | την κλασική ανάλυση. Η ανάλυση συμπληρώνεται με παραγοντική ανάλυση, PCA, SEM, εύρωστη
69 | (HC3/HAC) συμπερασματολογία, περιορισμένη CRM (CCRM), έλεγχο εκτός δείγματος και πλήρως
70 | αναπαραγώγιμο pipeline.
71 |
72 | **Abstract.** We compare classical (close-to-close) and interval-valued (daily [Low, High],
73 | mid/rad representation) statistical analysis of the relation between the DIA ETF and 15
74 | S&P 500 stocks across five sectors, over 1,253 aligned trading days (2021-2025). Classical
75 | stepwise regression explains 88.4% of DIA variance and the interval Centre Method 84.6%.
76 | The range (rad) equation attains  $R^2 = 0.79$ , which we show is largely a mechanical
77 | aggregation effect (0.72 from the constituent mean alone) with OLS inference invalidated
78 | by autocorrelation; the substantive finding is a strong common intraday-volatility factor
79 | invisible to close-to-close analysis. Robust (HC3/HAC) inference, constrained CRM,
80 | out-of-sample checks and a fully reproducible pipeline complete the study.
81 |
82 | **Λέξεις-κλειδιά:** διαστηματικά δεδομένα· συμβολική ανάλυση δεδομένων· Center-and-Range
83 | Method· αποδόσεις μετοχών· ενδοημερήσια αστάθεια· εύρωστη συμπερασματολογία.
84 |
85 | **Συνεισφορές:** (α) συγκριτικό πλαίσιο κλασικής-διαστηματικής παλινδρόμησης στο ίδιο
86 | panel με κοινή προεπεξεργασία· (β) πλήρης αξιολόγηση διαστηματικής πρόβλεψης (CRM και
87 | CCRM με μετρικές κάλυψης/αποδοτικότητας/εγκυρότητας)· (γ) ειλικρινής ερμηνεία του rad
88 | μέσω αποσύνθεσης του μηχανικού μέρους (ταυτότητα άθροισης) και εύρωστης
89 | συμπερασματολογίας· (δ) πλήρως αναπαραγώγιμο pipeline (σπόρος = AM, τοπικό στιγμιότυπο
90 | δεδομένων, αυτόματη εγκατάσταση εξαρτήσεων).
91 |
92 | *Σημείωση: οι αριθμοί της περίληψης είναι στατικοί· υπολογίζονται και τεκμηριώνονται
93 | δυναμικά στις αντίστοιχες ενότητες (ντετερμινιστικό pipeline: σταθερό seed + τοπικά CSV).*
94 |
95 | # Εισαγωγή και Στόχος της Εργασίας
96 |
97 | Η παρούσα εργασία εκπονείται στο πλαίσιο του μαθήματος *«Αριθμητικές Μέθοδοι στην
98 | Επιστήμη των Δεδομένων»* και αποσκοπεί στη **συγκριτική μελέτη της κλασικής
99 | στατιστικής ανάλυσης** (όπου κάθε ημερήσια παρατήρηση είναι ένας πραγματικός αριθμός
100 | – η απόδοση Close-to-Close) **έναντι της διαστηματικής (interval) ανάλυσης δεδομένων**
101 | (όπου κάθε παρατήρηση είναι ένα διάστημα [Low, High] και αναπαρίσταται από το ζεύγος
102 | *mid* και *rad*).
103 |
104 | Ως **εξαρτημένη μεταβλητή Y** χρησιμοποιείται ο δείκτης **DIA** (SPDR Dow Jones
105 | Industrial Average ETF) και ως **ανεξάρτητες μεταβλητές  $X_1, \dots, X_{15}$ ** έχουν επιλεγεί
106 | δεκαπέντε μετοχές κατανεμημένες σε πέντε τομείς της αμερικανικής αγοράς:
107 |
108 | | Τομέας (Sector ETF) | Μετοχές |
109 | |---|---|
110 | | Technology (XLK) | NVDA, AAPL, MSFT |
111 | | Financials (XLF) | BAC, JPM, V |
112 | | Communications (XLC) | GOOGL, META, NFLX |
113 | | Consumer Discretionary (XLY) | AMZN, TSLA, HD |
114 | | Health (XLV) | LLY, JNJ, UNH |
115 |
116 | Η μελέτη καλύπτει την περίοδο **01-01-2021 έως 31-12-2025** (πέντε ολόκληρα ημερολογιακά
117 | έτη), παρέχοντας περισσότερες από 1.250 ευθυγραμμισμένες ημερήσιες παρατηρήσεις (ο
118 | ακριβής αριθμός υπολογίζεται και αναφέρεται παρακάτω).
119 | Το θεωρητικό πλαίσιο για τη διαστηματική παλινδρόμηση ακολουθεί τη **μέθοδο των κέντρων**
120 | των @billard2000 (για την ακριβή σχέση με τη Center-and-Range Method των Lima Neto &
121 | de Carvalho, βλ. §B2), ενώ για τη συζήτηση της Interval Factor Analysis βασιζόμαστε
122 | στην εργασία των @douzal2007.
123 |
124 | # Σχετική Βιβλιογραφία
125 |
126 | Η **συμβολική ανάλυση δεδομένων** (Symbolic Data Analysis) επεκτείνει την κλασική
127 | στατιστική σε παρατηρήσεις που δεν είναι σημεία αλλά σύνολα – διαστήματα, ιστογράμματα,
128 | κατανομές. Τα θεμέλια για διαστηματικές μεταβλητές τέθηκαν από τους @bertrand2000
129 | (περιγραφική στατιστική διαστημάτων) και συστηματοποιήθηκαν από τους @billard2003, οι

```

```

130 |  οποίοι τοποθέτησαν το πεδίο ως μετάβαση «από τη στατιστική των δεδομένων στη στατιστική
131 |  της γνώσης». Στην παλινδρόμηση, οι @billard2000 πρότειναν την αρχική **Μέθοδο των Κέντρων**
132 |  (προσαρμογή στο κέντρο του διαστήματος), την οποία οι @limaneto2008 γενίκευσαν στη
133 |  **Center-and-Range Method (CRM)** με χωριστή εξίσωση για το εύρος, και αργότερα
134 |  [@limaneto2010] στην **περιορισμένη CCRM** που εγγυάται μη-αρνητικό προβλεπόμενο εύρος.
135 |  Για τη μείωση διάστασης, η επέκταση της PCA σε διαστηματικά δεδομένα μελετήθηκε από τους
136 |  @douzal2007 και @douzal2011, με τα γνωστά προβλήματα μη-μοναδικότητας της διαστηματικής
137 |  συνδιακύμανσης που καθιστούν την πλήρη Interval FA δυσεπίλυτη (βλ. §B4).
138 |
139 |  Παράλληλα, στη χρηματοοικονομική βιβλιογραφία το **ημερήσιο εύρος τιμών** έχει μακρά
140 |  ιστορία ως εκτιμητής αστάθειας: ο @parkinson1980 έδειξε ότι το εύρος High-Low παρέχει
141 |  σημαντικά αποδοτικότερη εκτίμηση της διακύμανσης από τις αποδόσεις κλεισίματος, και οι
142 |  @garmanklass1980 τον βελτίωσαν αξιοποιώντας πλήρη OHLC πληροφορία. Η δυναμική της
143 |  δεσμευμένης αστάθειας μοντελοποιείται κλασικά με την οικογένεια ARCH/GARCH
144 |  [@engle1982; @bollerslev1986]. Το Παράρτημα Δ9 γεφυρώνει ρητά τα δύο ρεύματα: δείχνουμε
145 |  ότι το `rad` της διαστηματικής αναπαράστασης ταυτίζεται (ως προς κλίμακα) με τον εκτιμητή
146 |  του Parkinson και συγκρίνεται με τη δεσμευμένη αστάθεια ενός GARCH(1,1).
147 |
148 |  Η παρούσα εργασία τοποθετείται στην τομή των δύο ρευμάτων: εφαρμόζει το πλαίσιο
149 |  CRM/CCRM σε πραγματικά χρηματιστηριακά διαστήματα [Low, High], αξιολογεί την ποιότητα
150 |  ανακατασκευής των διαστημάτων με τις μετρικές της βιβλιογραφίας (RMSE ορίων, κάλυψη,
151 |  αποδοτικότητα, εγκυρότητα), και ερμηνεύει το αποτέλεσμα του εύρους υπό το πρίσμα της
152 |  βιβλιογραφίας range-based volatility – με εύρωστη συμπερασματολογία [@white1980;
153 |  @neweywest1987] όπου οι κλασικές υποθέσεις παραβιάζονται.
154 |
155 |  ```{r libraries}
156 |  # core πακέτα: δεδομένα, περιγραφικά/FA, γραφήματα, SEM, VIF, πίνακες
157 |  library(quantmod); library(psych); library(corrplot); library(ggplot2)
158 |  library(lavaan); library(knitr); library(car); library(moments)
159 |  library(MASS); library(kableExtra)
160 |  # χρησιμοποιούνται στο Παράρτημα (Δ): δέντρο, robust/HAC SE, CCRM, έλεγχοι χρονοσειράς
161 |  library(gvlma); library(rpart); library(rpart.plot)
162 |  library(lmtest); library(sandwich); library(nnlms); library(tseries)
163 |
164 |  # Μικρός wrapper για τους πίνακες: booktabs + σταθερή θέση. Σε PDF εφαρμόζει
165 |  # kableExtra styling, ενώ διαδραστικά (console) επιστρέφει απλό markdown - αλλιώς
166 |  # η kable(format="latex") θα τύπωνε ωμό LaTeX. wide=TRUE -> μικρότερη γραμματοσειρά
167 |  # (δουλεύει και σε longtables, όπου το scale_down αγνοείται).
168 |  ktab <- function(x, caption = NULL, digits = 3, wide = FALSE, ...) {
169 |    k <- knitr::kable(x, caption = caption, booktabs = TRUE,
170 |                      digits = digits, linesep = "", ...)
171 |    if (knitr::is_latex_output()) {
172 |      opts <- if (wide) c("HOLD_position", "scale_down") else "HOLD_position"
173 |      k <- kableExtra::kable_styling(k, latex_options = opts,
174 |                                     font_size = if (wide) 8 else 9)
175 |    }
176 |    k
177 |  }
178 |
179 |  # κοινό θέμα για όλα τα ggplot (συνέπεια) + παλέτα Okabe-Ito (φιλική σε αχρωματοψία)
180 |  theme_paper <- function(base = 11) {
181 |    ggplot2::theme_bw(base_size = base) +
182 |      ggplot2::theme(
183 |        panel.grid.minor = ggplot2::element_blank(),
184 |        panel.grid.major = ggplot2::element_line(linewidth = 0.3, colour = "grey88"),
185 |        plot.title = ggplot2::element_text(face = "bold", size = ggplot2::rel(1.0)),
186 |        plot.subtitle = ggplot2::element_text(colour = "grey30", size = ggplot2::rel(0.85)),
187 |        strip.background = ggplot2::element_rect(fill = "grey92", colour = NA),
188 |        strip.text = ggplot2::element_text(face = "bold", size = ggplot2::rel(0.75)),
189 |        axis.title = ggplot2::element_text(size = ggplot2::rel(0.9)),
190 |        legend.position = "none")
191 |  }
192 |  okabe_ito <- c("#000000", "#E69F00", "#56B4E9", "#009E73",
193 |                "#F0E442", "#0072B2", "#D55E00", "#CC79A7")
194 |  sector_pal <- c(Tech = "#0072B2", Fin = "#E69F00", Comm = "#009E73",
195 |                 Cons = "#D55E00", Health = "#CC79A7")
196 |
197 |  # seed = AM φοιτητή, για αναπαραγωγιμότητα
198 |  set.seed(1125886)
199 |  ```
200 |
201 |  # Λήψη Δεδομένων και Κατασκευή Μεταβλητών
202 |
203 |  ## Λήψη Δεδομένων από το Yahoo Finance

```

```

204 |
205 | ```{r download-data, results='hide'}
206 | # Y = DIA (εξαρτημένη), X1..X15 = οι 15 μετοχές, ομαδοποιημένες κατά τομέα
207 | tickers_Y <- "DIA"
208 | tickers_tech <- c("NVDA", "AAPL", "MSFT") # Τεχνολογία
209 | tickers_fin <- c("BAC", "JPM", "V") # Χρηματοοικονομικά
210 | tickers_comm <- c("GOOGL", "META", "NFLX") # Επικοινωνίες
211 | tickers_cons <- c("AMZN", "TSLA", "HD") # Καταναλωτικά
212 | tickers_health <- c("LLY", "JNJ", "UNH") # Υγεία
213 |
214 | # Συγκεντρωτικός πίνακας μετοχών και τομέων (θα χρησιμεύσει αργότερα)
215 | sectors_df <- data.frame(
216 |   Ticker = c(tickers_tech, tickers_fin, tickers_comm, tickers_cons, tickers_health),
217 |   Sector = c(rep("Tech", 3),
218 |               rep("Fin", 3),
219 |               rep("Comm", 3),
220 |               rep("Cons", 3),
221 |               rep("Health", 3))
222 | )
223 | all_tickers <- c(tickers_Y, sectors_df$Ticker)
224 |
225 | # Ημερομηνίες περιόδου μελέτης
226 | date_from <- "2021-01-01"
227 | date_to <- "2025-12-31"
228 |
229 | # Cache των δεδομένων σε CSV: αν υπάρχει το αρχείο στο data/ το διαβάζουμε,
230 | # αλλιώς το κατεβάζουμε μία φορά από το Yahoo και το σώζουμε. Έτσι το knit είναι
231 | # ντετερμινιστικό, δεν εξαρτάται από το δίκτυο, και τα δεδομένα ταξιδεύουν με το
232 | # report (αναπαραγωγιμότητα, §3.3).
233 | data_dir <- "data"
234 | dir.create(data_dir, showWarnings = FALSE)
235 |
236 | get_one <- function(sym) {
237 |   csv <- file.path(data_dir, paste0(sym, ".csv"))
238 |   if (file.exists(csv)) { # από cache
239 |     df <- read.csv(csv, stringsAsFactors = FALSE)
240 |     x <- xts::xts(as.matrix(df[, -1]), order.by = as.Date(df$Date))
241 |     return(x)
242 |   }
243 |   res <- tryCatch( # αλλιώς κατέβασέ το
244 |     quantmod::getSymbols(sym, src = "yahoo",
245 |                           from = date_from, to = date_to,
246 |                           auto.assign = FALSE),
247 |     error = function(e) NULL
248 |   )
249 |   if (!is.null(res)) {
250 |     write.csv(data.frame(Date = index(res), zoo::coredata(res)),
251 |               csv, row.names = FALSE)
252 |   }
253 |   res
254 | }
255 |
256 | prices_list <- setNames(lapply(all_tickers, get_one), all_tickers)
257 |
258 | # Έλεγχος ότι διαβάστηκαν/κατέβηκαν όλα τα σύμβολα
259 | ok <- sapply(prices_list, function(x) !is.null(x) && NROW(x) > 100)
260 | stopifnot("Αποτυχία λήψης/ανάγνωσης για ένα ή περισσότερα tickers." = all(ok))
261 | ```
262 |
263 | ## Κατασκευή Κλασικών και Διαστηματικών Αποδόσεων
264 |
265 | Σύμφωνα με την εκφώνηση και το συνοδευτικό υλικό:
266 |
267 | - **Κλασική απόδοση (Close-to-Close):**  $r_t = \frac{C_t}{C_{t-1}} - 1$ 
268 | - **Διαστηματική απόδοση:**  $R_t = \frac{1}{\Delta t} \ln \left( \frac{H_t}{L_t} \right)$ 
269 | - **Κέντρο:**  $\text{mid}_t = \frac{L_t + H_t}{2}$ 
270 | - **Ημι-εύρος:**  $\text{rad}_t = \frac{H_t - L_t}{2}$ 
271 |
272 | ```{r build-returns}
273 | # ΣΥΝΑΡΤΗΣΗ: Υπολογισμός κλασικής και διαστηματικής απόδοσης
274 | compute_returns <- function(prices_xts) {
275 |   P_prev <- lag(Cl(prices_xts)) # προηγούμενο close
276 |   L <- Lo(prices_xts) # ημερήσιο low
277 |   H <- Hi(prices_xts) # ημερήσιο high

```



```

278 | Ccur <- Cl(prices_xts) # τρέχον close
279 |
280 | classical <- Ccur / P_prev - 1 # κλασική απόδοση Close-to-Close
281 | mid <- (L + H) / (2 * P_prev) - 1 # κέντρο διαστήματος
282 | rad <- (H - L) / (2 * P_prev) # ημι-εύρος διαστήματος
283 |
284 | out <- merge(classical, mid, rad)
285 | colnames(out) <- c("classical", "mid", "rad")
286 | out
287 | }
288 |
289 | # Εφαρμογή σε όλες τις σειρές
290 | returns_list <- lapply(prices_list, compute_returns)
291 |
292 | # ενώνουμε τα πάντα σε ένα ευθυγραμμισμένο panel: κάθε ticker -> 3 στήλες
293 | # (classical, mid, rad) με πρόθεμα το ticker
294 | build_panel <- function(rlist) {
295 |   zs <- lapply(seq_along(rlist), function(i) {
296 |     z <- rlist[[i]]
297 |     colnames(z) <- paste0(names(rlist)[i], "_", colnames(z))
298 |     z
299 |   })
300 |   out <- Reduce(function(a, b) merge(a, b, join = "inner"), zs)
301 |   out <- na.omit(out)
302 |   as.data.frame(out)
303 | }
304 |
305 | panel <- build_panel(returns_list)
306 |
307 | # Διαχωρισμός σε τρία υπο-σύνολα: κλασικά, mid, rad
308 | get_block <- function(suffix) {
309 |   cols <- grep(paste0("_", suffix, "$"), colnames(panel), value = TRUE)
310 |   df <- panel[, cols, drop = FALSE]
311 |   colnames(df) <- sub(paste0("_", suffix, "$"), "", cols)
312 |   df
313 | }
314 |
315 | df_classical <- get_block("classical") # απλές αποδόσεις
316 | df_mid <- get_block("mid") # κέντρα διαστημάτων
317 | df_rad <- get_block("rad") # ημι-εύρη διαστημάτων
318 |
319 | # Στις τρεις παρακάτω μεταβλητές απομονώνουμε την εξαρτημένη και τις
320 | # ανεξάρτητες, για διευκόλυνση των επόμενων ενοτήτων.
321 | Y_classical <- df_classical$DIA
322 | X_classical <- df_classical[, setdiff(colnames(df_classical), "DIA")]
323 |
324 | Y_mid <- df_mid$DIA
325 | X_mid <- df_mid[, setdiff(colnames(df_mid), "DIA")]
326 |
327 | Y_rad <- df_rad$DIA
328 | X_rad <- df_rad[, setdiff(colnames(df_rad), "DIA")]
329 |
330 | # Συμβολοσειρά διάστασης δείγματος (για ερμηνεία)
331 | n_obs <- nrow(df_classical)
332 | ```
333 |
334 | ```{r show-panel-dim}
335 | cat("Αριθμός ευθυγραμμισμένων ημερήσιων παρατηρήσεων: ", n_obs, "\n")
336 | cat("Αριθμός ανεξάρτητων μεταβλητών : ", ncol(X_classical), "\n")
337 | cat("Περίοδος μελέτης : ", date_from, "έως", date_to, "\n")
338 | ```
339 |
340 | **Σχόλιο:** Μετά την ευθυγράμμιση των 16 σειρών και την αφαίρεση των NAs (που οφείλονται
341 | κυρίως στη μετατόπιση `lag` της πρώτης ημέρας), προκύπτει ένα πλήρες ισορροπημένο panel
342 | που μας επιτρέπει αδιάβλητη παράλληλη ανάλυση κλασικών και διαστηματικών μεταβλητών
343 | χωρίς αλγοριθμικές προκαταλήψεις λόγω missing values.
344 |
345 | ## Επισκόπηση της Περιόδου Μελέτης
346 |
347 | ```{r fig1-timeline, fig.height=5, fig.cap="Σχήμα 1 – Πορεία του DIA στην περίοδο μελέτης: τιμή κλεισίματος (πάνω) και ημερή
348 | | στα απόδοση (κάτω), με σημειωμένα βασικά γεγονότα αγοράς."}
349 | # χρονογραμμή αναφοράς: τι "βλέπει" το δείγμα 2021-2025
350 | dia_px <- prices_list$DIA
350 | tl <- rbind(

```

```

351 | data.frame(Date = index(dia_px), value = as.numeric(Cl(dia_px)),
352 |           panel = "Τιμή κλεισίματος DIA ($)"),
353 | data.frame(Date = as.Date(rownames(df_classical)), value = Y_classical,
354 |           panel = "Ημερήσια απόδοση DIA"))
355 | tl$panel <- factor(tl$panel, levels = unique(tl$panel))
356 | events <- data.frame(
357 |   Date = as.Date(c("2022-01-05", "2023-03-10", "2023-06-01",
358 |                   "2024-08-05", "2025-04-02")),
359 |   label = c("έναρξη bear\\n(πληθωρισμός)", "SVB", "AI rally",
360 |            "vol spike\\nΑυγ 2024", "δασμοί\\nΑπρ 2025"))
361 | ggplot(tl, aes(Date, value)) +
362 |   geom_vline(data = events, aes(xintercept = Date),
363 |             linetype = 3, colour = "grey45") +
364 |   geom_line(colour = "#0072B2", linewidth = 0.35) +
365 |   geom_text(data = cbind(events, panel = factor(levels(tl$panel)[1],
366 |                                               levels = levels(tl$panel))),
367 |             aes(x = Date, y = Inf, label = label),
368 |             vjust = 1.15, size = 2.4, colour = "grey25", lineheight = 0.9) +
369 |   facet_wrap(~ panel, ncol = 1, scales = "free_y") +
370 |   labs(title = "Σχήμα 1 – DIA: τιμή και αποδόσεις, 2021-2025",
371 |        x = NULL, y = NULL) +
372 |   theme_paper()
373 | ```
374 |
375 | Η πενταετία καλύπτει ένα ασυνήθιστα πλούσιο φάσμα καθεστώτων αγοράς: την ανάκαμψη του
376 | 2021, τη bear market του 2022 (πληθωρισμός / επιθετικές αυξήσεις επιτοκίων), το τραπεζικό
377 | στρες του Μαρτίου 2023 (SVB), το AI rally του 2023-24, το απότομο vol spike του Αυγούστου
378 | 2024 και την αναταραχή των δασμών του Απριλίου 2025. Η ποικιλία αυτή είναι σημαντική για
379 | τη μελέτη: τροφοδοτεί τόσο τη διακύμανση των αποδόσεων (Μέρος Α) όσο και τη διακύμανση
380 | της **αστάθειας** (Μέρος Β) – και αξιοποιείται ρητά στην ανάλυση υποπεριόδων του
381 | Παραρτήματος Δ10.
382 |
383 | ---
384 |
385 | # Μέρος Α – Κλασική Ανάλυση
386 |
387 | ## A1. Περιγραφική Στατιστική {#a1}
388 |
389 | ### Πίνακας Περιγραφικών Μέτρων
390 |
391 | ```{r a1-desc-table}
392 | # Υπολογισμός βασικών περιγραφικών μέτρων για κάθε κλασική απόδοση
393 | desc_stats <- function(x) {
394 |   c(
395 |     Mean      = mean(x, na.rm = TRUE),
396 |     Median    = median(x, na.rm = TRUE),
397 |     SD        = sd(x, na.rm = TRUE),
398 |     IQR       = IQR(x, na.rm = TRUE),          # ενδοτεταρτημοριακό εύρος
399 |     Min       = min(x, na.rm = TRUE),
400 |     Max       = max(x, na.rm = TRUE),
401 |     Skewness  = moments::skewness(x, na.rm = TRUE),
402 |     Kurtosis  = moments::kurtosis(x, na.rm = TRUE), # ορισμός Pearson (Normal=3)
403 |     Missing   = 100 * mean(is.na(x))           # ποσοστό ελλειπουσών (%)
404 |   )
405 | }
406 |
407 | tab_desc_classical <- t(sapply(df_classical, desc_stats))
408 | ktab(tab_desc_classical, digits = 4, wide = TRUE,
409 |      caption = "Πίνακας A1.1 – Περιγραφικά μέτρα κλασικών ημερήσιων αποδόσεων (Close-to-Close).")
410 | ```
411 |
412 | ### Ιστογράμματα
413 |
414 | ```{r a1-histograms, fig.height=7.5, fig.cap="Ιστογράμματα των 16 κλασικών ημερήσιων αποδόσεων (κόκκινη γραμμή: μέσος όρος)."}
415 | # Ιστογράμματα όλων των κλασικών αποδόσεων - ggplot facet (paper level)
416 | long_cl <- utils::stack(df_classical)
417 | long_cl$ind <- factor(long_cl$ind, levels = colnames(df_classical))
418 | means_cl <- data.frame(ind = factor(colnames(df_classical),
419 |                                     levels = colnames(df_classical)),
420 |                        mu = sapply(df_classical, mean))
421 | ggplot(long_cl, aes(x = values)) +
422 |   geom_histogram(bins = 40, fill = "#0072B2", colour = "white", linewidth = 0.1) +
423 |   geom_vline(data = means_cl, aes(xintercept = mu),

```

```

424 |         colour = "#D55E00", linewidth = 0.5) +
425 | facet_wrap(~ ind, scales = "free", ncol = 4) +
426 | labs(title = "A1 – Ιστογράμματα κλασικών ημερήσιων αποδόσεων",
427 |       x = "Ημερήσια απόδοση (Close-to-Close)", y = "Συχνότητα") +
428 | theme_paper()
429 | ```
430 |
431 | ### Boxplots
432 |
433 | ```{r a1-boxplots, fig.height=4.6, fig.cap="Boxplots κλασικών αποδόσεων ανά μετοχή, χρωματισμένα κατά τομέα."}
434 | long_box <- utils::stack(df_classical)
435 | long_box$ind <- factor(long_box$ind, levels = colnames(df_classical))
436 | grp <- c(DIA = "Δείκτης", setNames(sectors_df$Sector, sectors_df$Ticker))
437 | long_box$grp <- factor(grp[as.character(long_box$ind)],
438 |                       levels = c("Δείκτης", "Tech", "Fin", "Comm", "Cons", "Health"))
439 | ggplot(long_box, aes(x = ind, y = values, fill = grp)) +
440 |   geom_hline(yintercept = 0, linetype = 2, colour = "grey50") +
441 |   geom_boxplot(outlier.alpha = 0.2, outlier.size = 0.4, linewidth = 0.3) +
442 |   scale_fill_manual(values = c("Δείκτης" = "#444444", sector_pal)) +
443 |   labs(title = "A1.2 – Boxplots κλασικών αποδόσεων (DIA + 15 μετοχές)",
444 |        x = NULL, y = "Ημερήσια απόδοση", fill = "Κατηγορία") +
445 |   theme_paper() +
446 |   theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1),
447 |         legend.position = "right")
448 | ```
449 |
450 | ```{r a1-facts, include=FALSE}
451 | # Υπολογιζόμενα μεγέθη που τροφοδοτούν τον σχολιασμό (αντί για σταθερές).
452 | sds_cl      <- sapply(X_classical, sd)
453 | kurt_cl     <- sapply(df_classical, moments::kurtosis)
454 | skew_cl     <- sapply(df_classical, moments::skewness)
455 | a1_vol      <- names(sort(sds_cl, decreasing = TRUE))[1:2]
456 | a1_dia_sd   <- sd(df_classical$DIA)
457 | a1_kmin     <- round(min(kurt_cl), 1)
458 | a1_kmax     <- round(max(kurt_cl), 1)
459 | a1_nneg     <- sum(skew_cl < 0)
460 | a1_mean_abs_max <- max(abs(sapply(df_classical, mean)))
461 | a1_miss_total <- sum(is.na(df_classical)) # συνολικές ελλείπουσες
462 | ```
463 |
464 | ##### Σχολιασμός A1
465 |
466 | Από τον Πίνακα A1.1 και τα παραπάνω διαγράμματα προκύπτουν τα εξής:
467 |
468 | * **Μέσοι όροι:** Όλες οι σειρές έχουν μέση ημερήσια απόδοση πολύ κοντά στο μηδέν·
469 |   η μεγαλύτερη (κατ' απόλυτη τιμή) μέση ημερήσια απόδοση σε όλο το δείγμα είναι μόλις
470 |   `r signif(a1_mean_abs_max, 2)`. Αυτό συμφωνεί με τη χρηματοοικονομική βιβλιογραφία:
471 |   η αναμενόμενη μέση ημερήσια απόδοση είναι πρακτικά μη διακριτή από το μηδέν στο
472 |   επίπεδο του θορύβου.
473 | * **Διασπορά:** Η τυπική απόκλιση του DIA (`r round(a1_dia_sd, 4)`) είναι σαφώς
474 |   μικρότερη από εκείνη των επιμέρους μετοχών – αποτύπωση της **επίδρασης του
475 |   χαρτοφυλακιακού διαφορισμού** (portfolio diversification). Οι δύο πιο ασταθείς
476 |   μετοχές του δείγματος είναι η `r a1_vol[1]` και η `r a1_vol[2]`. Το
477 |   ενδοτεταρτημοριακό εύρος (IQR) στον Πίνακα A1.1 επιβεβαιώνει την ίδια διάταξη
478 |   διασποράς, ανθεκτικά ως προς τις ακραίες τιμές.
479 | * **Πληρότητα δεδομένων:** Μετά την ευθυγράμμιση το panel είναι **πλήρως ισορροπημένο**
480 |   (`r a1_miss_total` ελλείπουσες τιμές, δηλαδή 0% σε κάθε σειρά), οπότε δεν απαιτείται
481 |   imputation – προϋπόθεση που ελέγχεται ρητά στον υποχρεωτικό προ-μοντελικό κατάλογο.
482 | * **Λοξότητα (Skewness):** Μόνο `r a1_nneg` από τις 16 σειρές είναι αρνητικά λοξές· οι
483 |   υπόλοιπες `r 16 - a1_nneg` (μαζί με τον ίδιο τον DIA) είναι ελαφρά θετικά λοξές. Έντονη
484 |   αρνητική λοξότητα εμφανίζεται μόνο σε μεμονωμένες μετοχές μετά από ειδικά γεγονότα (π.χ. NFLX,
485 |   UNH με απότομες πτώσεις). Δηλαδή στο δείγμα μας **δεν** ισχύει γενικευμένα το «φαινόμενο
486 |   αρνητικής λοξότητας» – η εικόνα είναι κατά μετοχή, με κυρίαρχη την ελαφριά θετική λοξότητα.
487 | * **Κύρτωση (Kurtosis):** Όλες οι σειρές έχουν `r kurtosis` > 3 (εύρος `r a1_kmin`-`r a1_kmax`,
488 |   ορισμός Pearson με Normal = 3), δηλαδή **παχιές ουρές (fat tails)** – κεντρικό
489 |   χαρακτηριστικό των χρηματιστηριακών αποδόσεων που αναιρεί την υπόθεση κανονικότητας
490 |   και δικαιολογεί τη χρήση robust διαγνωστικών στις επόμενες ενότητες.
491 | * **Boxplots:** Είναι εμφανή τα πολυάριθμα ακραία σημεία (outliers) πέραν των whiskers,
492 |   ιδίως για τις πιο ασταθείς μετοχές – ένδειξη ημερών έντονης διακύμανσης (π.χ.
493 |   ανακοινώσεις κερδών, μακρο-σοκ).
494 |
495 | Στο σύνολό τους, τα παραπάνω ευρήματα επιβεβαιώνουν τη **μη-κανονικότητα** των
496 | αποδόσεων και υποδεικνύουν ότι, για ασφαλέστερα συμπεράσματα, στη συνέχεια θα
497 | χρησιμοποιήσουμε διαγνωστικά και ευαισθησία σε ακραίες παρατηρήσεις (residual

```

```

498 | diagnostics, στην ενότητα A5).
499 |
500 | ---
501 |
502 | ## A2. Πίνακας Συσχετίσεων και Πολυσυγγραμμικότητα {#a2}
503 |
504 | ### Πίνακας Συσχετίσεων (Heatmap)
505 |
506 | ```{r a2-cor, fig.width=8, fig.height=7}
507 | # Υπολογισμός πίνακα συσχετίσεων Pearson για όλες τις κλασικές αποδόσεις
508 | cor_classical <- cor(df_classical)
509 |
510 | corrrplot::corrrplot(
511 |   cor_classical,
512 |   method       = "color",
513 |   type         = "upper",
514 |   order        = "hclust",
515 |   addCoef.col  = "black",
516 |   number.cex   = 0.55,
517 |   tl.cex       = 0.8,
518 |   tl.col       = "black",
519 |   tl.srt       = 45,
520 |   col          = colorRampPalette(c("#2166AC", "white", "#B2182B"))(200),
521 |   title        = "Σχήμα A2.1 – Heatmap συσχετίσεων (Pearson) – κλασικές αποδόσεις",
522 |   mar          = c(0,0,2,0)
523 | )
524 | ```
525 |
526 | ### Variance Inflation Factor (VIF)
527 |
528 | ```{r a2-vif}
529 | # Υπολόγισε VIF από το πλήρες γραμμικό μοντέλο  $Y \sim X1..X15$ 
530 | df_full <- data.frame(Y = Y_classical, X_classical)
531 | lm_full <- lm(Y ~ ., data = df_full)
532 | vif_vals <- car::vif(lm_full)
533 |
534 | ktab(data.frame(Variable = names(vif_vals),
535 |                 VIF      = round(as.numeric(vif_vals), 3)),
536 |       caption = "Πίνακας A2.1 – VIF για όλες τις ανεξάρτητες μεταβλητές.",
537 |       row.names = FALSE)
538 | ```
539 |
540 | ### Ζεύγη με  $|r| > 0.8$ 
541 |
542 | ```{r a2-high-corr}
543 | # Εντοπισμός υψηλά συσχετισμένων ζευγών (εκτός DIA)
544 | ind_corr <- cor(X_classical)
545 | hi <- which(abs(ind_corr) > 0.8 & upper.tri(ind_corr), arr.ind = TRUE)
546 |
547 | # Μεγέθη που τροφοδοτούν τον σχολιασμό
548 | n_hi_pairs <- nrow(hi)
549 | a2_maxvif <- max(vif_vals)
550 | a2_maxr <- max(ind_corr[upper.tri(ind_corr)])
551 | cor_with_dia <- cor(X_classical, df_classical$DIA)[, 1]
552 | a2_dia_max <- names(sort(cor_with_dia, decreasing = TRUE))[1]
553 | a2_dia_min <- names(sort(cor_with_dia))[1]
554 |
555 | if (n_hi_pairs > 0) {
556 |   hi_df <- data.frame(
557 |     Var1 = rownames(ind_corr)[hi[, 1]],
558 |     Var2 = colnames(ind_corr)[hi[, 2]],
559 |     r    = round(ind_corr[hi], 3)
560 |   )
561 |   hi_df <- hi_df[order(-abs(hi_df$r)), ]
562 |   ktab(hi_df, caption = "Πίνακας A2.2 – Ζεύγη ανεξάρτητων με  $|r| > 0.8$ .",
563 |     row.names = FALSE)
564 | } else {
565 |   cat("Δεν εντοπίστηκαν ζεύγη ανεξάρτητων μετοχών με  $|r| > 0.8$ .\n")
566 | }
567 | ```
568 |
569 | ##### Σχολιασμός A2
570 |
571 | * Το heatmap δείχνει τις ισχυρότερες θετικές συσχετίσεις **εντός των τομέων** (μετοχές

```

```

572 | του ίδιου κλάδου μοιράζονται κοινούς παράγοντες κινδύνου). Η μέγιστη συσχέτιση μεταξύ
573 | δύο ανεξάρτητων μετοχών στο δείγμα είναι `r round(a2_maxr, 3)`.
574 | * Όλες οι μετοχές παρουσιάζουν **θετική συσχέτιση με τον ΔΙΑ**· η ισχυρότερη είναι η
575 | **`r a2_dia_max`** και η ασθενέστερη η **`r a2_dia_min`** (λιγότερο ευθυγραμμισμένη με
576 | την price-weighted σύνθεση του δείκτη).
577 | * Από τον Πίνακα A2.1, η **μέγιστη τιμή VIF είναι `r round(a2_maxvif, 2)`** –
578 | `r if (a2_maxvif < 10)` "κάτω από το κρίσιμο όριο 10 (Kutner et al., 2005), οπότε δεν υφίσταται σοβαρή πολυσυγγραμμικότητα
στο πλήρες μοντέλο" else "πάνω από το όριο 10, ένδειξη ουσιαστικής πολυσυγγραμμικότητας"`.
579 | `r if (n_hi_pairs == 0)` "Κανένα ζεύγος ανεξάρτητων μετοχών δεν ξεπερνά το  $|r| > 0.8$ " else paste0("Εντοπίστηκαν ", n_hi_pai
rs, " ζεύγη με  $|r| > 0.8$ ")`,
580 | ωστόσο η εντός-τομέα συσχέτιση δικαιολογεί τη χρήση stepwise επιλογής (A5) και
581 | παραγοντικής ανάλυσης (A3).
582 |
583 | ---
584 |
585 | ## A3. Παραγοντική Ανάλυση (Factor Analysis) {#a3}
586 |
587 | ### Διαγνωστικοί Έλεγχοι (KMO & Bartlett)
588 |
589 | ```{r a3-prelim}
590 | # Ελέγχουμε αν είναι κατάλληλα τα δεδομένα για παραγοντική ανάλυση
591 | kmo_res <- psych::KMO(X_classical)
592 | print(kmo_res)
593 | bart_res <- psych::cortest.bartlett(cor(X_classical), n = n_obs)
594 | print(bart_res)
595 | ```
596 |
597 | ### Επιλογή Αριθμού Παραγόντων
598 |
599 | ```{r a3-nfactors, fig.height=4}
600 | # Παράλληλη ανάλυση + scree για να εκτιμήσουμε τον βέλτιστο αριθμό παραγόντων
601 | psych::fa.parallel(X_classical, fa = "fa", n.iter = 50,
602 |                    show.legend = TRUE, main = "A3.1 – Parallel analysis (FA)")
603 | ```
604 |
605 | ### Παραγοντική Ανάλυση με Principal Axis Factoring (PAF) και Varimax
606 |
607 | ```{r a3-fa}
608 | # Με βάση τα ευρήματα του scree/parallel analysis επιλέγουμε k παράγοντες.
609 | # Παρακάτω χρησιμοποιούμε k = 3, που είναι λογικό για 5 τομείς ομαδοποιήσιμους σε
610 | # ευρύτερες οικογένειες (growth/tech, financials, defensive). Ο αναγνώστης μπορεί
611 | # να αλλάξει το k βάσει του γραφήματος.
612 | fa_model <- psych::fa(X_classical, nfactors = 3, fm = "pa",
613 |                      rotate = "varimax", scores = "regression")
614 | print(fa_model$loadings, cutoff = 0.30, sort = TRUE)
615 | ```
616 |
617 | ```{r a3-fa-diagram, fig.height=5, fig.cap="A3.2 – Διάγραμμα παραγόντων (factor diagram, varimax)."}
618 | # Οπτικοποίηση της παραγοντικής δομής (όπως στο υλικό του μαθήματος)
619 | psych::fa.diagram(fa_model, main = "A3.2 – Δομή Παραγόντων (PAF + Varimax)")
620 | ```
621 |
622 | ```{r a3-fa-extras}
623 | cat("Πίνακας κοινοτήτων (communalities):\n")
624 | print(round(fa_model$communality, 3))
625 |
626 | cat("\nΠοσοστό συνολικής διακύμανσης που εξηγείται από κάθε παράγοντα:\n")
627 | print(round(fa_model$Vaccounted, 3))
628 | ```
629 |
630 | ```{r a3-facts, include=FALSE}
631 | # Μεγέθη που τροφοδοτούν τον σχολιασμό (αντί για σταθερές).
632 | a3_kmo <- kmo_res$MSA
633 | a3_bartp <- bart_res$p.value
634 | L_fa <- unclass(fa_model$loadings)
635 | fa_assign <- apply(abs(L_fa), 1, which.max) # κυρίαρχος παράγοντας/μετοχή
636 | fa_groups <- lapply(sort(unique(fa_assign)),
637 |                    function(k) names(fa_assign)[fa_assign == k])
638 | fa_group_str <- vapply(fa_groups, paste, character(1), collapse = ", ")
639 | vacc <- fa_model$Vaccounted
640 | a3_cumvar <- if ("Cumulative Var" %in% rownames(vacc))
641 |               vacc["Cumulative Var", ncol(vacc)] else sum(vacc["Proportion Var", ])
642 | a3_lowcomm <- names(sort(fa_model$communality))[1]
643 | a3_lowcomm_set <- names(which(fa_model$communality < 0.4)) # κάτω από το όριο 0.4

```

```

644 | ```
645 |
646 | ##### Σχολιασμός A3
647 |
648 | * **KM0:** Η συνολική τιμή Kaiser-Meyer-Olkin είναι **`r round(a3_kmo, 3)`**
649 | (`r if (a3_kmo >= 0.9) "«marvelous» κατά Kaiser" else if (a3_kmo >= 0.8) "«meritorious»" else "οριακή καταλληλότητα"),
650 | δηλαδή η αναλογία κοινής προς μοναδική διακύμανση δικαιολογεί απόλυτα την παραγοντική ανάλυση.
651 | * **Bartlett:** Η μηδενική υπόθεση ότι ο πίνακας συσχετίσεων είναι μοναδιαίος
652 | απορρίπτεται ισχυρά (p `r if (a3_bartp < 2.2e-16) "< 2.2e-16" else paste("=", signif(a3_bartp, 3))`),
653 | επιβεβαιώνοντας σημαντική κοινή διακύμανση μεταξύ των μετοχών.
654 | * **Δομή Παραγόντων:** Με βάση τη μέγιστη φόρτιση κάθε μετοχής (μετά από varimax), οι
655 | παράγοντες ομαδοποιούν τις μετοχές ως εξής:
656 | `r paste(sprintf("%d) %s", seq_along(fa_group_str), fa_group_str), collapse = " · ")`.
657 | Όπως φαίνεται από την **πραγματική** αυτή ομαδοποίηση, προκύπτει ένας **ευρύς παράγοντας
658 | mega-cap growth (τεχνολογία, επικοινωνίες και καταναλωτικά μαζί), ένας **στενός τραπεζικός**
659 | (BAC, JPM) και ένας **αμυντικός/υγείας**. Αξιοσημείωτο: η συν-κίνηση των αποδόσεων **δεν
660 | ταυτίζεται πάντα με τον ονομαστικό κλάδο **`r if (a3_lowcomm > 0.4) "Σύμφωνα με τον εμπειρικό κανόνα του μαθήματος
661 | (communality > 0.4), οι μετοχές **`r paste(a3_lowcomm_set, collapse="," )`** βρίσκονται
662 | κάτω από το όριο: ένα μεγάλο μέρος της διακύμανσής τους είναι **ιδιοσυγκρασιακό** και δεν
663 | εξηγείται από τους 3 κοινούς παράγοντες – αναμενόμενο για μετοχές με έντονη ειδική
664 | συμπεριφορά (π.χ. TSLA, ή αμυντικές με χαμηλό market beta).
665 |
666 | ---
667 |
668 | ## A4. Ανάλυση Κύριων Συνιστωσών (PCA) {#a4}
669 |
670 | ```{r a4-pca}
671 | # PCA στις κλασικές αποδόσεις των 15 ανεξάρτητων μετοχών (όχι του DIA)
672 | pca_classical <- prcomp(X_classical, center = TRUE, scale. = TRUE)
673 | summary(pca_classical)
674 | ```
675 |
676 | ##### Scree Plot & Κριτήριο Kaiser
677 |
678 | ```{r a4-scree, fig.height=3.6, fig.cap="Scree plot (ιδιοτιμές, κριτήριο Kaiser>1) και αθροιστική εξηγημένη διασπορά."}
679 | eig_vals <- (pca_classical$sdev)^2
680 | n_keep <- sum(eig_vals > 1)
681 | lv <- c("Ιδιοτιμές (κριτήριο Kaiser > 1)", "Αθροιστική εξηγημένη διασπορά")
682 | scree_df <- rbind(
683 |   data.frame(PC = seq_along(eig_vals), value = eig_vals, panel = lv[1]),
684 |   data.frame(PC = seq_along(eig_vals),
685 |     value = cumsum(eig_vals) / sum(eig_vals), panel = lv[2]))
686 | scree_df$panel <- factor(scree_df$panel, levels = lv)
687 | href <- data.frame(panel = factor(lv, levels = lv), y = c(1, 0.80))
688 | ggplot(scree_df, aes(PC, value)) +
689 |   geom_hline(data = href, aes(yintercept = y), linetype = 2, colour = "#D55E00") +
690 |   geom_line(colour = "#0072B2", linewidth = 0.6) +
691 |   geom_point(colour = "#0072B2", size = 1.6) +
692 |   facet_wrap(~ panel, scales = "free_y") +
693 |   scale_x_continuous(breaks = seq(1, length(eig_vals), 2)) +
694 |   labs(title = "A4.1 – Scree plot & αθροιστική εξηγημένη διασπορά (PCA)",
695 |     x = "Κύρια συνιστώσα (PC)", y = NULL) +
696 |   theme_paper()
697 |
698 | cat("Κανόνας Kaiser (eigenvalue > 1): διατηρούμε", n_keep, "κύριες συνιστώσες.\n")
699 | cat("Ποσοστό διακύμανσης που εξηγείται από PC1+PC2+PC3:",
700 |   round(sum(eig_vals[1:3]) / sum(eig_vals) * 100, 2), "%\n")
701 | ```
702 |
703 | ##### Φορτίσεις (Loadings) των πρώτων συνιστωσών
704 |
705 | ```{r a4-loadings}
706 | loadings_mat <- pca_classical$rotation[, 1:min(4, ncol(pca_classical$rotation))]
707 | ktab(loadings_mat, digits = 3,
708 |   caption = "Πίνακας A4.1 – Φορτίσεις των πρώτων 4 κύριων συνιστωσών.")
709 | ```
710 |
711 | ##### Σχολιασμός A4
712 |
713 | * Με βάση το **κριτήριο του Kaiser** (ιδιοτιμή > 1) διατηρούμε **`r n_keep`** κύριες

```

```

718 | συνιστώσες. Η πρώτη συνιστώσα εξηγεί **`r round(eig_vals[1] / sum(eig_vals) * 100, 1)`%**
719 | και οι τρεις πρώτες **`r round(sum(eig_vals[1:3]) / sum(eig_vals) * 100, 1)`%** της
720 | συνολικής διακύμανσης.
721 | * Kaiser έναντι αθροιστικής διασποράς: Οι δύο κανόνες δίνουν διαφορετική εικόνα. Με
722 | Kaiser κρατάμε `r n_keep` συνιστώσες, αλλά αυτές καλύπτουν μόλις
723 | `r round(sum(eig_vals[1:3]) / sum(eig_vals) * 100, 1)`%, Kaiser από τον εμπειρικό κανόνα
724 | του 70-80%*. για να φτάσουμε το 70% χρειάζονται **`r which(cumsum(eig_vals)/sum(eig_vals) >= 0.70)[1]`**
725 | συνιστώσες. Η ένταση αυτή είναι αναμενόμενη για ένα θορυβώδες cross-section ημερήσιων
726 | αποδόσεων (ισχυρός κοινός παράγοντας αγοράς + πολλές σχεδόν-ισοδύναμες ιδιοσυγκρασιακές
727 | διαστάσεις) και υπενθυμίζει ότι ο αριθμός των συνιστωσών εξαρτάται από τον στόχο
728 | (ερμηνεία vs ποσοστό διασποράς).
729 | * PC1 – «Market factor»: Όλες οι μετοχές φορτώνουν με το ίδιο πρόσημο (το πρόσημο
730 | του ιδιοδιανύσματος είναι συμβατικό). Πρόκειται για τον common market factor –
731 | εξηγεί γιατί όλες οι μετοχές κινούνται σε γενικές γραμμές μαζί (συστηματικός κίνδυνος).
732 | * PC2 – «Growth/Tech vs. Defensive»: Συνήθως διαχωρίζει τις growth/tech μετοχές από
733 | τις αμυντικές.
734 | * PC3: Λεπτομερέστερη διάκριση κλάδων (π.χ. χρηματοοικονομικά έναντι επικοινωνιών).
735 |
736 | Η οικονομική ερμηνεία είναι σύμφωνη με την παραγοντική ανάλυση της A3: δύο σχεδόν
737 | ισοδύναμες οπτικές γωνίες της ίδιας κοινής δομής διακύμανσης.
738 |
739 | ---
740 |
741 | ## A5. Γραμμική Παλινδρόμηση και Stepwise Επιλογή {#a5}
742 |
743 | ### Πλήρες Μοντέλο
744 |
745 | ```{r a5-full}
746 | # Πλήρες γραμμικό μοντέλο για την κλασική απόδοση του DIA
747 | df_lm <- data.frame(Y = Y_classical, X_classical)
748 | lm_full <- lm(Y ~ ., data = df_lm)
749 | summary(lm_full)
750 | ```
751 |
752 | ### Stepwise Επιλογή Μεταβλητών (Both Directions, AIC)
753 |
754 | ```{r a5-step, results='hide'}
755 | # Χρησιμοποιούμε step() με κριτήριο AIC και κατεύθυνση both, ξεκινώντας από
756 | # το πλήρες μοντέλο. Το trace = FALSE μειώνει τον θόρυβο στην έξοδο.
757 | lm_step <- step(lm_full, direction = "both", trace = FALSE)
758 | ```
759 |
760 | ```{r a5-step-summary}
761 | summary(lm_step)
762 | cat("\nΕπιλεγμένες μεταβλητές μετά το stepwise:\n")
763 | print(setdiff(all.vars(formula(lm_step)), "Y"))
764 | cat("\nAIC πλήρους: ", round(AIC(lm_full), 2),
765 |     "\nAIC stepwise: ", round(AIC(lm_step), 2), "\n")
766 | ```
767 |
768 | ### Διαγνωστικοί Έλεγχοι του Τελικού Μοντέλου
769 |
770 | ```{r a5-diag, fig.height=7}
771 | op <- par(mfrow = c(2, 2))
772 | plot(lm_step, which = 1:4)
773 | par(op)
774 | ```
775 |
776 | ```{r a5-diag-tests}
777 | # Έλεγχος κανονικότητας καταλοίπων - Jarque-Bera (κανονικό για χρηματοοικονομικές
778 | # σειρές: ελέγχει από κοινού λοξότητα & κύρτωση) και Shapiro-Wilk.
779 | cat("Jarque-Bera test (έλεγχος κανονικότητας – λοξότητα/κύρτωση):\n")
780 | print(moments::jarque.test(as.numeric(resid(lm_step))))
781 |
782 | cat("\nShapiro-Wilk επί των residuals (έλεγχος κανονικότητας):\n")
783 | print(shapiro.test(sample(resid(lm_step), min(5000, length(resid(lm_step))))))
784 |
785 | cat("\nBreusch-Pagan test (έλεγχος ετεροσκεδαστικότητας):\n")
786 | print(car::ncvTest(lm_step))
787 |
788 | cat("\nDurbin-Watson test (έλεγχος αυτοσυσχέτισης):\n")
789 | print(car::durbinWatsonTest(lm_step))
790 | ```
791 |

```

```

792 | ```{r a5-gvlma}
793 | # Συνολικός έλεγχος των υποθέσεων του γραμμικού μοντέλου (όπως στο υλικό
794 | # του μαθήματος: gvlma - Global Validation of Linear Model Assumptions).
795 | print(gvlma::gvlma(lm_step))
796 | ```
797 |
798 | ```{r a5-facts, include=FALSE}
799 | # Μεγέθη που τροφοδοτούν τον σχολιασμό (αντί για σταθερές).
800 | a5_r2 <- summary(lm_step)$r.squared
801 | a5_adj <- summary(lm_step)$adj.r.squared
802 | a5_naic <- AIC(lm_full); a5_saic <- AIC(lm_step)
803 | a5_bp_p <- car::ncvTest(lm_step)$p
804 | a5_dw <- car::durbinWatsonTest(lm_step)$dw
805 | a5_jb_p <- moments::jarque.test(as.numeric(resid(lm_step)))$p.value
806 | a5_sel <- setdiff(all.vars(formula(lm_step)), "Y") # επιλεγμένες μεταβλητές
807 | # Συστατικά του DJIA (που αντιγράφει ο DIA) εντός των 15 μετοχών μας, κατά την
808 | # περίοδο 2021-2025 (AMZN προστέθηκε 02/2024, NVDA 11/2024 - η σύνθεση μεταβάλλεται):
809 | dow_members <- c("AAPL", "MSFT", "JPM", "V", "UNH", "JNJ", "HD", "AMZN", "NVDA")
810 | dow_in_model <- intersect(dow_members, colnames(X_classical))
811 | non_dow <- setdiff(colnames(X_classical), dow_members)
812 | ```
813 |
814 | ##### Σχολιασμός A5
815 |
816 | * **Συντελεστές & p-values:** Το stepwise μοντέλο διατηρεί ```r length(a5_sel)``` από τις
817 | 15 μεταβλητές: ```r paste(a5_sel, collapse = ", ")```. Πρόκειται κατά κύριο λόγο για μετοχές
818 | με μεγάλη «βαρύτητα» στον δείκτη.
819 | * **R2 = ```r round(a5_r2, 3)``` (adj. R2 = ```r round(a5_adj, 3)```)** Υψηλό, καθώς ο δείκτης
820 | είναι σε μεγάλο βαθμό **γραμμικός συνδυασμός των συστατικών του**. Ο DJIA που αντιγράφει
821 | ο DIA περιλαμβάνει 30 μετοχές· από τις 15 μετοχές μας οι ```r length(dow_in_model)```
822 | (```r paste(dow_in_model, collapse = ", ")```) είναι συστατικά του δείκτη κατά την περίοδο
823 | μελέτης (οι AMZN και NVDA προστέθηκαν εντός του 2024), ενώ οι υπόλοιπες
824 | (```r paste(non_dow, collapse = ", ")```) δεν είναι.
825 | * **AIC:** Μειώνεται από ```r round(a5_naic, 1)``` (πλήρης) σε ```r round(a5_saic, 1)``` (stepwise):
826 | η αφαίρεση μη-σημαντικών μεταβλητών βελτιώνει το μοντέλο χωρίς ουσιαστική απώλεια
827 | ερμηνευτικής ισχύος.
828 | * **Διαγνωστικά υπολοίπων:**
829 | - Από το «Residuals vs. Fitted» δεν εμφανίζεται έντονη μη-γραμμικότητα.
830 | - **Jarque-Bera:** p = ```r signif(a5_jb_p, 3)```
831 | ```r if (a5_jb_p < 0.05) "(< 0.05 → απορρίπτεται η κανονικότητα των καταλοίπων, σύμφωνα με τις παχιές ουρές/λοξότητα της
832 | A1)" else "(δεν απορρίπτεται η κανονικότητα)"```.
833 | Στο Q-Q plot τα υπόλοιπα αποκλίνουν από την κανονικότητα στις ουρές – σύμφωνα με
834 | την A1 (παχιές ουρές των αποδόσεων).
835 | - **Breusch-Pagan:** p = ```r signif(a5_bp_p, 3)```
836 | ```r if (a5_bp_p < 0.05) "(< 0.05 → ενδείξεις ετεροσκεδαστικότητας· για στιβαρότητα ενδείκνυνται robust/HC standard erro
837 | rs, π.χ. coeftest με sandwich estimator)" else "(δεν απορρίπτεται η ομοσκεδαστικότητα)"```.
838 | - **Durbin-Watson:** DW = ```r round(a5_dw, 3)``` (κοντά στο 2 → πρακτικά απουσία
839 | αυτοσυσχέτισης πρώτου βαθμού στα residuals, αναμενόμενο για ημερήσιες αποδόσεις).
840 | - **Συνολικός έλεγχος gvlma:** Η μόνη υπόθεση που παραβιάζεται είναι η κανονικότητα,
841 | και μάλιστα **αποκλειστικά μέσω της κύρτωσης** (Kurtosis component): η λοξότητα, η
842 | μορφή σύνδεσης (link) και η ομοσκεδαστικότητα κρίνονται αποδεκτές. Το εύρημα είναι
843 | απόλυτα συνεπές με την A1 (παχιές ουρές) και τον έλεγχο Jarque-Bera, και επιβεβαιώνει
844 | ότι το πρόβλημα δεν είναι η συστηματική δομή του μοντέλου αλλά οι ακραίες αποδόσεις.
845 |
846 | ---
847 |
848 | # Μέρος B – Διαστηματική Ανάλυση
849 |
850 | ## B1. Περιγραφή Διαστηματικών Δεδομένων {#b1}
851 |
852 | ### Ιστογράμματα `mid` και `rad`
853 |
854 | ```{r b1-hist-mid, fig.height=7.5, fig.cap="Ιστογράμματα των mid (κέντρα διαστημάτων) για DIA και τις 15 μετοχές."}
855 | long_mid <- utils::stack(df_mid)
856 | long_mid$ind <- factor(long_mid$ind, levels = colnames(df_mid))
857 | ggplot(long_mid, aes(x = values)) +
858 |   geom_histogram(bins = 40, fill = "#009E73", colour = "white", linewidth = 0.1) +
859 |   facet_wrap(~ ind, scales = "free", ncol = 4) +
860 |   labs(title = "B1 – Ιστογράμματα mid (κέντρα διαστημάτων)",
861 |         x = "mid (κέντρο ημερήσιου διαστήματος)", y = "Συχνότητα") +
862 |   theme_paper()
863 | ```
864 |
865 | ```{r b1-hist-rad, fig.height=7.5, fig.cap="Ιστογράμματα των rad (ημι-εύρη): έντονα δεξιό-λοξά και μη-αρνητικά."}

```



```

864 | long_rd <- utils::stack(df_rad)
865 | long_rd$ind <- factor(long_rd$ind, levels = colnames(df_rad))
866 | ggplot(long_rd, aes(x = values)) +
867 |   geom_histogram(bins = 40, fill = "#D55E00", colour = "white", linewidth = 0.1) +
868 |   facet_wrap(~ ind, scales = "free", ncol = 4) +
869 |   labs(title = "B1 – Ιστογράμματα rad (ημι-εύρη / ενδοημερήσια αστάθεια)",
870 |        x = "rad (ημι-εύρος ημερήσιου διαστήματος)", y = "Συχνότητα") +
871 |   theme_paper()
872 | ```
873 |
874 | ### Boxplots του `rad` ανά Τομέα
875 |
876 | ```{r b1-rad-sector, fig.height=4.5}
877 | # Μακρά μορφή: για κάθε ανεξάρτητη μετοχή και τομέα συγκεντρώνουμε rad
878 | long_rad <- do.call(rbind, lapply(seq_len(nrow(sectors_df)), function(i) {
879 |   data.frame(Sector = sectors_df$Sector[i],
880 |             Ticker = sectors_df$Ticker[i],
881 |             rad = df_rad[[sectors_df$Ticker[i]]])
882 | })))
883 |
884 | long_rad$Sector <- factor(long_rad$Sector,
885 |                          levels = c("Tech", "Fin", "Comm", "Cons", "Health"))
886 | ggplot(long_rad, aes(x = Sector, y = rad, fill = Sector)) +
887 |   geom_boxplot(outlier.alpha = 0.2, outlier.size = 0.4, linewidth = 0.3) +
888 |   scale_fill_manual(values = sector_pal) +
889 |   labs(title = "B1.1 – Ημερήσιο ημι-εύρος (rad) ανά τομέα",
890 |        x = "Τομέας", y = "rad (ενδοημερήσια αστάθεια)") +
891 |   theme_paper()
892 | ```
893 |
894 | ### Συσχέτιση μεταξύ `mid` και `rad`
895 |
896 | ```{r b1-mid-rad-cor}
897 | # Για κάθε ticker, υπολογίζουμε τη συσχέτιση μεταξύ της mid και της rad σειράς του
898 | mid_rad_cor <- sapply(colnames(df_mid),
899 |                      function(nm) cor(df_mid[[nm]], df_rad[[nm]]))
900 | ktab(data.frame(Ticker = names(mid_rad_cor),
901 |                Cor_mid_rad = round(mid_rad_cor, 3)),
902 |       caption = "Πίνακας B1.1 – Συσχέτιση mid-rad ανά ticker.", row.names = FALSE)
903 |
904 | # Μεγέθη για τον σχολιασμό
905 | sector_mean_rad <- tapply(long_rad$rad, long_rad$Sector, mean)
906 | b1_sec_max <- names(which.max(sector_mean_rad))
907 | b1_sec_min <- names(which.min(sector_mean_rad))
908 | b1_cor_md <- mean(mid_rad_cor[setdiff(names(mid_rad_cor), "DIA")])
909 | ```
910 |
911 | ##### Σχολιασμός B1
912 |
913 | * Τα ιστογράμματα του mid έχουν σχήμα παρόμοιο με τα ιστογράμματα των κλασικών
914 | αποδόσεων (A1) – γεγονός θεωρητικά αναμενόμενο, αφού το mid αποτελεί ομοιόμορφη
915 | εκτίμηση του κέντρου της ημερήσιας πορείας τιμών.
916 | * Τα ιστογράμματα του rad είναι έντονα δεξιά λοξά και αυστηρά μη-αρνητικά
917 | ( $rad \geq 0$  εξ ορισμού). Αυτό απαγορεύει τη χρήση log-transform ή GLM στην ενδεχόμενη
918 | μοντελοποίηση της αστάθειας.
919 | * Το boxplot ανά τομέα δείχνει ότι η μεγαλύτερη μέση ενδοημερήσια αστάθεια (rad)
920 | εμφανίζεται στον τομέα Fin και η χαμηλότερη στον Comm.
921 | * Η μέση συσχέτιση mid-rad των ανεξάρτητων μετοχών είναι round(b1_cor_md, 3) –
922 | μικρή κατ' απόλυτη τιμή, που υπογραμμίζει ότι το κέντρο και το εύρος της ημέρας
923 | μεταφέρουν διαφορετική πληροφορία, δικαιολογώντας τη διττή ανάλυση της επόμενης ενότητας.
924 |
925 | ---
926 |
927 | ## B2. Διαστηματική Παλινδρόμηση – Μέθοδος των Κέντρων (Billard & Diday, 2000) {#b2}
928 |
929 | Ακολουθώντας την εκφώνηση, προσαρμόζουμε δύο ανεξάρτητες γραμμικές παλινδρομήσεις: μία
930 | στα κέντρα (mid) και μία στα ημι-εύρη (rad). Σημείωση ακριβείας: η εκτίμηση ξεχωριστής
931 | εξίσωσης και για το εύρος αντιστοιχεί αυστηρά στη Μέθοδο Κέντρου-και-Εύρους (Center and
932 | Range Method, CRM) των @limaneto2008· η αρχική Μέθοδος Κέντρων των
933 | @billard2000 εκτιμά μόνο την εξίσωση των κέντρων και τη χρησιμοποιεί για αμφότερα
934 | τα άκρα του διαστήματος. Διατηρούμε τον όρο «Μέθοδος των Κέντρων» όπως στην εκφώνηση,
935 | υλοποιώντας τη γενίκευσή της (CRM, δηλαδή mid και rad).
936 |
937 | ```{r b2-mid-model}

```

```

938 | # Μοντέλο για τα mids: εξηγούμε το κέντρο της απόδοσης του DIA
939 | mid_data <- data.frame(Y = Y_mid, X_mid)
940 | model_mid <- lm(Y ~ ., data = mid_data)
941 | summary(model_mid)
942 | ```
943 |
944 | ```{r b2-rad-model}
945 | # Μοντέλο για τα rads: εξηγούμε την αστάθεια (ημι-εύρος) του DIA
946 | # Σημείωση: το Y_rad ίσως έχει σχεδόν μηδενική διακύμανση -> πιθανό NaN R2
947 | rad_data <- data.frame(Y = Y_rad, X_rad)
948 |
949 | # Έλεγχος προσασίας έναντι μηδενικής διακύμανσης στο Y_rad
950 | var_Y_rad <- var(Y_rad, na.rm = TRUE)
951 | cat("Διακύμανση Y_rad =", signif(var_Y_rad, 4), "\n")
952 |
953 | if (var_Y_rad > .Machine$double.eps * 100) {
954 |   model_rad <- lm(Y ~ ., data = rad_data)
955 |   print(summary(model_rad))
956 | } else {
957 |   cat("ΠΡΟΣΟΧΗ: το Y_rad έχει σχεδόν μηδενική διακύμανση -",
958 |       "το rad model δεν είναι ερμηνεύσιμο (R2 ~ NaN).\n")
959 |   model_rad <- NULL
960 | }
961 | ```
962 |
963 | ```{r b2-facts, include=FALSE}
964 | b2_r2_mid <- summary(model_mid)$r.squared
965 | cm <- summary(model_mid)$coefficients
966 | b2_sig_mid <- rownames(cm)[-1][cm[-1, "Pr(>|t|)"] < 0.05]
967 | if (!is.null(model_rad)) {
968 |   b2_r2_rad <- summary(model_rad)$r.squared
969 |   cr <- summary(model_rad)$coefficients
970 |   b2_sig_rad <- rownames(cr)[-1][cr[-1, "Pr(>|t|)"] < 0.05]
971 |   # --- Έλεγχος εγκυρότητας του rad μοντέλου (κρίσιμο: αυτοσυσχέτιση/ευρωστία) ---
972 |   b2_rad_lb <- Box.test(resid(model_rad), lag = 10, type = "Ljung-Box")$p.value
973 |   b2_rad_hac <- lmtest::coeftest(model_rad,
974 |       vcov. = sandwich::NeweyWest(model_rad, lag = 5, prewhite = FALSE))
975 |   b2_nsig_rad_hac <- sum(b2_rad_hac[-1, "Pr(>|t|)"] < 0.05) # σημαντικές υπό HAC
976 |   # Πόσο "μηχανικό" είναι το R2: παλινδρόμηση Y_rad στον ΜΕΣΟ ΟΡΟ των 15 rad
977 |   b2_r2_rad_mean <- summary(lm(Y_rad ~ rowMeans(X_rad)))$r.squared
978 | } else { b2_r2_rad <- NA; b2_sig_rad <- character(0)
979 |   b2_rad_lb <- NA; b2_nsig_rad_hac <- NA; b2_r2_rad_mean <- NA }
980 | ```
981 |
982 | ### Γραφική Σύγκριση Παρατηρούμενων-Προβλεπόμενων Διαστημάτων
983 |
984 | ```{r b2-pred-actual, fig.height=5}
985 | # Προβλέψεις mid (και rad αν είναι ερμηνεύσιμο)
986 | yhat_mid <- as.numeric(predict(model_mid))
987 | yhat_rad <- if (!is.null(model_rad)) as.numeric(predict(model_rad)) else rep(mean(Y_rad), length(Y_rad))
988 |
989 | idx <- seq_len(min(100, length(Y_mid))) # κρατάμε τις πρώτες 100 παρατηρήσεις
990 | plot_df <- data.frame(
991 |   t = idx,
992 |   obs_low = Y_mid[idx] - Y_rad[idx],
993 |   obs_high = Y_mid[idx] + Y_rad[idx],
994 |   pred_low = yhat_mid[idx] - yhat_rad[idx],
995 |   pred_high = yhat_mid[idx] + yhat_rad[idx]
996 | )
997 |
998 | ggplot(plot_df, aes(x = t)) +
999 |   geom_ribbon(aes(ymin = obs_low, ymax = obs_high, fill = "Παρατηρούμενο"),
1000 |     alpha = 0.55) +
1001 |   geom_ribbon(aes(ymin = pred_low, ymax = pred_high, fill = "Προβλεπόμενο (CRM)"),
1002 |     alpha = 0.5) +
1003 |   scale_fill_manual(values = c("Παρατηρούμενο" = "grey60",
1004 |     "Προβλεπόμενο (CRM)" = "#0072B2")) +
1005 |   labs(title = "B2.1 – Παρατηρούμενα vs Προβλεπόμενα διαστήματα DIA (πρώτες 100 ημέρες)",
1006 |     x = "Ημέρα (χρονικός δείκτης)",
1007 |     y = "Διάστημα απόδοσης [mid – rad, mid + rad]", fill = NULL) +
1008 |   theme_paper() +
1009 |   theme(legend.position = "top")
1010 | ```
1011 |

```

```

1012 | ### Ακρίβεια Πρόβλεψης Διαστημάτων (RMSE κάτω/άνω ορίου)
1013 |
1014 | Η ποιότητα της μεθόδου CRM δεν αποτυπώνεται μόνο από τα  $R^2$  των δύο εξισώσεων,
1015 | αλλά κυρίως από το πόσο καλά ανακατασκευάζεται το ίδιο το διάστημα  $[\hat{L}, \hat{U}]$ .
1016 | Ακολουθώντας τους @limaneto2008, αξιολογούμε χωριστά το κάτω όριο
1017 |  $\hat{L} = \hat{Y}_{mid} - \hat{Y}_{rad}$  και το άνω όριο  $\hat{U} = \hat{Y}_{mid} + \hat{Y}_{rad}$ ,
1018 | καθώς και το ποσοστό προβλέψεων με έγκυρη διάταξη ( $\hat{U} \geq \hat{L}$ ).
1019 |
1020 | ```{r b2-interval-accuracy}
1021 | # Παρατηρούμενα και προβλεπόμενα όρια διαστήματος (πλήρες δείγμα)
1022 | obs_L <- Y_mid - Y_rad;      obs_U <- Y_mid + Y_rad
1023 | pred_L <- yhat_mid - yhat_rad; pred_U <- yhat_mid + yhat_rad
1024 |
1025 | rmse <- function(a, b) sqrt(mean((a - b)^2))
1026 | b2_rmse_L <- rmse(obs_L, pred_L)      # RMSE κάτω ορίου
1027 | b2_rmse_U <- rmse(obs_U, pred_U)      # RMSE άνω ορίου
1028 | b2_valid <- mean(pred_U >= pred_L) * 100 # % έγκυρων (μη-ανάστροφων) διαστημάτων
1029 | # Σύγκριση με «αφελή» πρόβλεψη (σταθερό μέσο διάστημα) -> βελτίωση RMSE
1030 | naive_L <- mean(obs_L); naive_U <- mean(obs_U)
1031 | b2_skill_L <- (1 - b2_rmse_L / rmse(obs_L, rep(naive_L, length(obs_L)))) * 100
1032 | b2_skill_U <- (1 - b2_rmse_U / rmse(obs_U, rep(naive_U, length(obs_U)))) * 100
1033 |
1034 | b2_acc_tab <- data.frame(
1035 |   `Όριο`           = c("Κάτω (L)", "Άνω (U)"),
1036 |   `RMSE`           = signif(c(b2_rmse_L, b2_rmse_U), 3),
1037 |   `Βελτίωση έναντι αφελούς (%)` = round(c(b2_skill_L, b2_skill_U), 1),
1038 |   check.names = FALSE)
1039 | ktab(b2_acc_tab, digits = 3, row.names = FALSE,
1040 |   caption = "Πίνακας B2.1 – Ακρίβεια πρόβλεψης ορίων διαστήματος (CRM).")
1041 | ```
1042 |
1043 | ##### Σχολιασμός B2
1044 |
1045 | * mid model: Το  $R^2$  του μοντέλου των κέντρων είναι r round(b2_r2_mid, 3), παραπλήσιο
1046 | με αυτό της κλασικής παλινδρόμησης (A5). Αυτό είναι θεωρητικά αναμενόμενο: τα κέντρα
1047 | διατηρούν σχεδόν όλη την πληροφορία τάσης που εμπεριέχει η απόδοση Close-to-Close.
1048 | Στατιστικά σημαντικές ( $p < 0.05$ ) είναι r length(b2_sig_mid) μεταβλητές:
1049 | r paste(b2_sig_mid, collapse = ", ").
1050 | * rad model: Η διακύμανση του  $Y_{rad}$  (αστάθεια του DIA) δεν είναι μηδενική
1051 | ($\approx r signif(var_Y_rad, 3)) – ακριβώς επειδή ως  $Y$  επιλέχθηκε ο ETF DIA (και όχι
1052 | ο ίδιος ο δείκτης Dow Jones, που λόγω τρόπου υπολογισμού θα έδινε σχεδόν μηδενικό  $rad$ ). Το
1053 |  $R^2$  του  $rad$  μοντέλου είναι r round(b2_r2_rad, 3), αλλά πρέπει να ερμηνευτεί με προσοχή:
1054 | - Είναι σε μεγάλο βαθμό μηχανικό (φαινόμενο άθροισης): μια απλή παλινδρόμηση του  $Y_{rad}$ 
1055 | στον μέσο όρο των 15 επιμέρους  $rad$  δίνει ήδη  $R^2 = r round(b2_r2_rad\_mean, 3)$ . Δηλαδή
1056 | το εύρημα είναι κατά βάση η ταυτότητα «το εύρος του δείκτη  $\approx$  μέσο εύρος των συστατικών»,
1057 | όχι μια ανακαλυφθείσα δομική σχέση.
1058 | - Η συμπερασματολογία OLS είναι άκυρη: τα κατάλοιπα του  $rad$  μοντέλου είναι έντονα
1059 | αυτοσυσχετισμένα (Ljung-Box p r if (b2_rad_lb < 0.001) "< 0.001" else paste("=", signif(b2_rad_lb, 2)), volatility
clustering),
1060 | οπότε τα μη-διορθωμένα p-values υπερεκτιμούν τη σημαντικότητα. Υπό εύρωστους (HAC)
1061 | εκτιμητές οι στατιστικά σημαντικές μεταβλητές πέφτουν από r length(b2_sig_rad) σε
1062 | r b2_nsig_rad_hac.
1063 | Το ορθό συμπέρασμα είναι ότι η ενδομερήσια αστάθεια του DIA αντανakλά έναν ισχυρό κοινό
1064 | παράγοντα αστάθειας (market-wide volatility) – όχι ότι είναι «γραμμικά προβλέψιμη». Η σωστή
1065 | μοντελοποίησή της απαιτεί δυναμικά υποδείγματα τύπου GARCH (βλ. Γ3, Δ6).
1066 | * Ακρίβεια διαστημάτων (Πίνακας B2.1): Τα RMSE των δύο ορίων είναι μικρά
1067 | (κάτω: r signif(b2_rmse_L, 3), άνω: r signif(b2_rmse_U, 3)) και η μέθοδος βελτιώνει
1068 | την αφελή πρόβλεψη σταθερού διαστήματος κατά r round(b2_skill_L, 1) (κάτω όριο) και
1069 | r round(b2_skill_U, 1) (άνω όριο). Επιπλέον, r round(b2_valid, 1) των
1070 | προβλεπόμενων διαστημάτων έχουν έγκυρη διάταξη ( $\hat{U} \geq \hat{L}$ ), δηλαδή η μη-περιορισμένη
1071 | CRM εδώ δεν παράγει ανάστροφα διαστήματα – γι' αυτό και δεν χρειάζεται η περιοριστική
1072 | παραλλαγή Constrained CRM [@limaneto2010].
1073 | * Εξάρτηση από την περίοδο: Όπως προειδοποιεί η εκφώνηση (FAQ), σε ηρεμότερες περιόδους η
1074 | διακύμανση του  $Y_{rad}$  μπορεί να γίνει πολύ μικρή και το  $R^2$  του  $rad$  μοντέλου να καταρρεύσει
1075 | (ή να γίνει NaN). Στη δική μας πενταετία η αυξημένη μακροοικονομική μεταβλητότητα (πανδημία,
1076 | πληθωρισμός, AI-cycle) διατήρησε ισχυρό σήμα και άρα αξιοσημείωτη ερμηνευτική ισχύ.
1077 |
1078 | ---
1079 |
1080 | ## B3. Ανάλυση Κύριων Συνιστωσών στα `mid` (Σύγκριση με την A4) {#b3}
1081 |
1082 | ```{r b3-pca-mid}
1083 | pca_mid <- prcomp(X_mid, center = TRUE, scale. = TRUE)
1084 | summary(pca_mid)

```

```

1085 | ```
1086 |
1087 | ### Scree Plot και Σύγκριση Φορτίσεων
1088 |
1089 | ```{r b3-scrree-compare, fig.height=3.8, fig.cap="Επικαλυπτόμενα scree plots: κλασική PCA (αποδόσεις) vs PCA στα mid."}
1090 | ev_cl <- pca_classical$sdev^2
1091 | ev_md <- pca_mid$sdev^2
1092 | scree_cmp <- rbind(
1093 |   data.frame(PC = seq_along(ev_cl), eig = ev_cl, Ανάλυση = "Κλασική (αποδόσεις)"),
1094 |   data.frame(PC = seq_along(ev_md), eig = ev_md, Ανάλυση = "PCA στα mid"))
1095 | ggplot(scree_cmp, aes(PC, eig, colour = Ανάλυση)) +
1096 |   geom_hline(yintercept = 1, linetype = 2, colour = "grey50") +
1097 |   geom_line(linewidth = 0.7) + geom_point(size = 1.8) +
1098 |   scale_colour_manual(values = c("Κλασική (αποδόσεις)" = "#0072B2",
1099 |     "PCA στα mid" = "#D55E00")) +
1100 |   scale_x_continuous(breaks = seq(1, length(ev_cl), 2)) +
1101 |   labs(title = "B3.1 – Σύγκριση scree: κλασική PCA vs PCA στα mid",
1102 |     x = "Κύρια συνιστώσα (PC)", y = "Ιδιότητα (eigenvalue)", colour = NULL) +
1103 |   theme_paper() +
1104 |   theme(legend.position = "top")
1105 | ```
1106 |
1107 | ```{r b3-loading-correlation}
1108 | # Πόσο όμοιες είναι οι πρώτες συνιστώσες; Συγκρίνουμε τα loadings.
1109 | common_pcs <- min(3, ncol(pca_mid$rotation), ncol(pca_classical$rotation))
1110 | cor_loadings_pc <- sapply(seq_len(common_pcs), function(k) {
1111 |   abs(cor(pca_mid$rotation[, k], pca_classical$rotation[, k]))
1112 | })
1113 |
1114 | ktab(data.frame(PC = paste0("PC", seq_len(common_pcs)),
1115 |   AbsCor = round(cor_loadings_pc, 3)),
1116 |   caption = "Πίνακας B3.1 – Απόλυτη συσχέτιση loadings κλασικής PCA και PCA στα mid.",
1117 |   row.names = FALSE)
1118 | ```
1119 |
1120 | #### Σχολιασμός B3
1121 |
1122 | * Τα ποσοστά εξηγημένης διακύμανσης από την PCA-στα-`mid` είναι **σχεδόν ταυτόσημα** με αυτά
1123 | της κλασικής PCA: η πρώτη συνιστώσα εξηγεί **`r round(summary(pca_mid)$importance[2,1]*100,1)`%**
1124 | (έναντι `r round(summary(pca_classical)$importance[2,1]*100,1)`% στην κλασική) και οι τρεις
1125 | πρώτες **`r round(sum((pca_mid$sdev^2)[1:3]) / sum(pca_mid$sdev^2) * 100, 1)`%**
1126 | * Η **απόλυτη συσχέτιση των loadings** μεταξύ των δύο αναλύσεων είναι
1127 | `r paste(sprintf("PC%d: %.3f", seq_along(cor_loadings_pc), cor_loadings_pc), collapse = ", ")`.
1128 | Οι τιμές (σχεδόν μονάδα) δείχνουν ότι:
1129 |
1130 | > Η οικονομική δομή που μετράμε δεν εξαρτάται από το αν χρησιμοποιούμε close-to-close ή
1131 | > mid αποδόσεις – είναι η ίδια **κοινή δομή κινήσεων αγοράς και κλάδων**.
1132 |
1133 | * Το εύρημα δικαιολογεί εκ των υστέρων τη σύσταση της εκφώνησης: η κλασική PCA στα `mid` είναι
1134 | έγκυρη και ερμηνεύσιμη, χωρίς ανάγκη περίπλοκης Interval PCA.
1135 |
1136 | ---
1137 |
1138 | ## B4. Διαστηματική Παραγοντική Ανάλυση – Βιβλιογραφική Συζήτηση {#b4}
1139 |
1140 | Η ενότητα αυτή είναι, σύμφωνα με τις οδηγίες της εκφώνησης, **καθαρά βιβλιογραφική
1141 | και θεωρητική** – δεν παρουσιάζεται υλοποίηση.
1142 |
1143 | ### Γιατί δεν υπάρχει «εύκολη» Interval Factor Analysis;
1144 |
1145 | Η κλασική παραγοντική ανάλυση (PAF, ML-FA, αλγόριθμος EM) βασίζεται **εξ ολοκλήρου
1146 | στον πίνακα συσχετίσεων** $R$. Όταν οι μεταβλητές είναι διαστήματα και όχι σημεία,
1147 | η κατασκευή ενός **μοναδικά καθορισμένου** πίνακα συσχετίσεων είναι μη τετριμμένη:
1148 |
1149 | 1. **Πολλαπλοί ορισμοί συνδιακύμανσης για διαστήματα.** Στη βιβλιογραφία
1150 | (Bertrand & Goupil, 2000· Billard & Diday, 2003) έχουν προταθεί διαφορετικοί
1151 | ορισμοί συνδιακύμανσης (centers method, vertices method, symbolic covariance,
1152 | span-based covariance). Διαφορετική επιλογή → διαφορετικός $R$ → διαφορετικά
1153 | loadings → **μη μοναδική λύση**.
1154 |
1155 | 2. **Πρόβλημα ταυτοποίησης (identifiability).** Στο κλασικό μοντέλο FA, εάν
1156 | $\lambda$ είναι ένας πίνακας φορτίσεων, τότε για κάθε ορθογώνιο $Q$ είναι
1157 | $\lambda Q$ επίσης λύση. Για διαστηματικές μεταβλητές, στην ταυτοποίηση
1158 | προστίθεται και η **ασάφεια ορισμού του πεδίου ορισμού** (η μεταβλητή
1159 | «τύπου διαστήματος» δεν είναι ένα σημείο, αλλά ένα **πεδίο τιμών** – άρα η

```

```

1159 | παραγοντική δομή πρέπει να σέβεται και την τάξη/ένταξη των ορίων του
1160 | διαστήματος).
1161 | 3. **Δεν υπάρχει σταθερή μετρική.** Σε αντίθεση με την κλασική PCA που έχει
1162 | μοναδική γεωμετρική ερμηνεία (μέγιστη διακύμανση), η Interval FA δεν διαθέτει
1163 | γενικά αποδεκτή μετρική «καλής εφαρμογής» που να έχει επικρατήσει.
1164 |
1165 | ### Οι προτάσεις των Douzal-Chouakria & Diday (2007· 2011)
1166 |
1167 | Στη σχετική βιβλιογραφία για συμβολική/διαστηματική πολυμεταβλητή ανάλυση
1168 | [@douzal2007; @douzal2011] οι συγγραφείς:
1169 |
1170 | * Προτείνουν να αντικατασταθεί κάθε διάστημα από ζεύγος **(mid, rad)** και να
1171 | εφαρμοστεί FA σε ένα **διπλάσιας διάστασης** πίνακα – αλλά υποδεικνύουν ότι
1172 | αυτό **δεν είναι ισοδύναμο** με την παραγοντοποίηση του αρχικού symbolic
1173 | πίνακα.
1174 | * Συζητούν την έννοια της **interval correlation** η οποία δεν είναι πάντα στο
1175 |  $[-1,1]$  και μπορεί να δίνει ασύμμετρα αποτελέσματα.
1176 | * Παρουσιάζουν αλγόριθμους που απαιτούν εξειδικευμένο λογισμικό· δεν υπάρχει
1177 | τυποποιημένο πακέτο R/Python που να εφαρμόζει τη μέθοδό τους με σταθερά,
1178 | αναπαραγώγιμα αποτελέσματα. Το παλαιότερο πακέτο `RSDA` παρουσιάζει
1179 | γνωστές αστάθειες υλοποίησης.
1180 |
1181 | ### Γιατί η Interval PCA είναι ευκολότερη από την Interval FA;
1182 |
1183 | Η Interval PCA, ακόμη και με τις εναλλακτικές μετρικές, βασίζεται σε
1184 | **γεωμετρική παραγοντοποίηση πίνακα** η οποία έχει αναλυτική λύση (SVD-like).
1185 | Η Interval FA, αντίθετα, βασίζεται σε **πιθανοθεωρητικό μοντέλο** με latent
1186 | parameters που πρέπει να εκτιμηθούν με αλγόριθμο EM ή ML – αλγόριθμοι που
1187 | απαιτούν τη μοναδικότητα του covariance και υποθέσεις για την κατανομή των
1188 | σφαλμάτων. Για διαστηματικά δεδομένα, **δεν υπάρχουν αντίστοιχα αποδεκτά
1189 | πιθανοθεωρητικά μοντέλα** (π.χ. multivariate interval-normal κατανομές δεν
1190 | είναι καθιερωμένες).
1191 |
1192 | ### Πορισματικός Σχολιασμός
1193 |
1194 | Στην παρούσα εργασία, σύμφωνα και με την οδηγία της εκφώνησης, **δεν επιχειρούμε**
1195 | υλοποίηση Interval FA. Αντί αυτής, στην ενότητα **Α3 εφαρμόσαμε κλασική FA** στις
1196 | αποδόσεις και στην **Β3 κλασική PCA στα mids**, που αποτελεί την επιστημονικά
1197 | αποδεκτή πρακτική προσέγγιση.
1198 |
1199 | ---
1200 |
1201 | ## B5. Δομικά Μοντέλα Εξισώσεων (SEM) – Bonus {#b5}
1202 |
1203 | Στο πλαίσιο του bonus, εκτιμούμε ένα μοντέλο Δομικών Εξισώσεων **με μία λανθάνουσα
1204 | μεταβλητή «TechFactor»** που μετράται από τα κέντρα των τριών τεχνολογικών μετοχών
1205 | (NVDA, AAPL, MSFT). Η εξίσωση δομής συνδέει την απόδοση του DIA (στο `mid`) με
1206 | αυτόν τον τεχνολογικό παράγοντα:
1207 |
1208 | 
$$Y_{mid} = \text{TechFactor} + NVDA_{mid} + AAPL_{mid} + MSFT_{mid}$$

1209 |
1210 |
1211 | ```{r b5-sem}
1212 | # Προετοιμασία δεδομένων για το lavaan
1213 | sem_data <- data.frame(
1214 |   Y_mid = Y_mid,
1215 |   NVDA_mid = X_mid$NVDA,
1216 |   AAPL_mid = X_mid$AAPL,
1217 |   MSFT_mid = X_mid$MSFT
1218 | )
1219 |
1220 | # Ορισμός του μοντέλου SEM
1221 | # =~ : μετρητικό μοντέλο (latent =~ indicators)
1222 | # ~ : δομικό μοντέλο (outcome ~ predictors)
1223 | sem_model <- '
1224 |   TechFactor =~ NVDA_mid + AAPL_mid + MSFT_mid
1225 |   Y_mid ~ TechFactor
1226 | '
1227 |
1228 | fit_sem <- lavaan::sem(model = sem_model, data = sem_data)
1229 | lavaan::summary(fit_sem, fit.measures = TRUE, standardized = TRUE)
1230 | ```
1231 |
1232 | ```{r b5-sem-fit}

```

```

1233 # Εξαγωγή των βασικών μέτρων προσαρμογής
1234 fm <- lavaan::fitMeasures(fit_sem,
1235                             c("cfi", "tli", "rmsea", "srmr", "chisq", "df", "pvalue"))
1236 ktab(data.frame(Measure = names(fm), Value = round(as.numeric(fm), 3)),
1237       caption = "Πίνακας B5.1 – Συγκεντρωτικά μέτρα προσαρμογής SEM.", row.names = FALSE)
1238 ```
1239
1240 ```{r b5-facts, include=FALSE}
1241 b5_cfi <- fm[["cfi"]]; b5_tli <- fm[["tli"]]
1242 b5_rmsea <- fm[["rmsea"]]; b5_srmr <- fm[["srmr"]]; b5_df <- fm[["df"]]
1243 pe <- lavaan::parameterEstimates(fit_sem)
1244 b5_reg <- pe[pe$op == "~" & pe$lhs == "Y_mid", ]
1245 b5_beta_est <- b5_reg$est[1]; b5_beta_p <- b5_reg$pvalue[1]
1246 std <- lavaan::standardizedSolution(fit_sem)
1247 b5_load_min <- min(std$est.std[std$op == "=~"])
1248 b5_n <- nrow(sem_data)
1249 ```
1250
1251 ##### Σχολιασμός B5 (SEM)
1252
1253 * **Latent loadings:** Και οι τρεις τεχνολογικές μετοχές φορτώνουν θετικά και σημαντικά στον
1254 λανθάνοντα παράγοντα «TechFactor». η ελάχιστη τυποποιημένη φόρτιση είναι
1255 **`r round(b5_load_min, 2)`**, ένδειξη ισχυρής και ομοιόμορφης μέτρησης του παράγοντα (τα
1256 NVDA/AAPL/MSFT οδηγούνται από κοινούς παράγοντες – AI cycle, semiconductors, επιτόκια).
1257 * **Δομικός συντελεστής (Y_mid ~ TechFactor):** Εκτίμηση **`r round(b5_beta_est, 3)`** με
1258 p-value **`r if (b5_beta_p < 0.001) "< 0.001" else signif(b5_beta_p, 3)`** – θετικός και ισχυρά
1259 σημαντικός: ο τεχνολογικός παράγοντας επιδρά θετικά στο κέντρο της απόδοσης του DIA.
1260 * **Δείκτες προσαρμογής** (df = **`r b5_df`, n = **`r b5_n`):
1261   - **CFI = `r round(b5_cfi, 3)`**, **TLI = `r round(b5_tli, 3)`** (κατώφλι «καλής» 0.95).
1262   - **RMSEA = `r round(b5_rmsea, 3)`** (κατώφλι «καλής» 0.06· 0.08–0.10 οριακό).
1263   - **SRMR = `r round(b5_srmr, 3)`** (κατώφλι 0.08).
1264
1265 Η εικόνα προσαρμογής είναι **μεικτή και πρέπει να ερμηνευτεί προσεκτικά**: το SRMR
1266 (**`r round(b5_srmr, 3)`**) είναι άριστο και το CFI υψηλό, αλλά το **RMSEA = `r round(b5_rmsea, 3)`**
1267 υποδηλώνει πραγματική δομική απόκλιση** (ένας μόνο λανθάνων παράγοντας δεν συλλαμβάνει τέλεια
1268 τη συν-διακύμανση NVDA/AAPL/MSFT) και το TLI είναι κάτω από το 0.95. Δύο επιμέρους παράγοντες:
1269 (α) με df = **`r b5_df` (πολύ λίγοι βαθμοί ελευθερίας) ο RMSEA είναι γνωστό ότι **υπερεκτιμάται**.
1270 (β) το μεγάλο n κάνει το **χ2-test** να απορρίπτει ακόμη και μικρές αποκλίσεις (αυτό αφορά μόνο
1271 το χ2, όχι τον RMSEA). Σημειώνεται επίσης ότι ο εκτιμητής εκπέμπει προειδοποίηση οριακής
1272 ταυτοποίησης (μη θετικά ορισμένος πίνακας συνδιακύμανσης παραμέτρων), συμβατή με τη
1273 σχεδόν-τέλεια συγγραμμικότητα των τριών δεικτών.
1274 * **Επεκτάσεις:** Ένα πιο σύνθετο SEM θα μπορούσε να ενσωματώσει και άλλους λανθάνοντες
1275 παράγοντες (FinFactor, HealthFactor, CommFactor) και να ελέγξει την υπόθεση ενός
1276 γενικευμένου «MarketFactor». Εδώ διατηρούμε τη μινιμαλιστική μορφή που ορίζει η εκφώνηση.
1277
1278 ---
1279
1280 # Μέρος C – Σύγκριση και Συμπεράσματα
1281
1282 ## C1. Συγκεντρωτικός Πίνακας Σύγκρισης {#c1}
1283
1284 ```{r c1-compare}
1285 # Βασικά συνοπτικά μέτρα από κάθε προσέγγιση
1286 r2_classical <- summary(lm_step)$r.squared
1287 adj_classical <- summary(lm_step)$adj.r.squared
1288 n_sig_classical <- sum(summary(lm_step)$coefficients[-1, "Pr(>|t|)"] < 0.05)
1289
1290 r2_mid <- summary(model_mid)$r.squared
1291 adj_mid <- summary(model_mid)$adj.r.squared
1292 n_sig_mid <- sum(summary(model_mid)$coefficients[-1, "Pr(>|t|)"] < 0.05)
1293
1294 if (!is.null(model_rad)) {
1295   r2_rad <- summary(model_rad)$r.squared
1296   adj_rad <- summary(model_rad)$adj.r.squared
1297   n_sig_rad <- sum(summary(model_rad)$coefficients[-1, "Pr(>|t|)"] < 0.05)
1298 } else {
1299   r2_rad <- NA; adj_rad <- NA; n_sig_rad <- NA
1300 }
1301
1302 comp <- data.frame(
1303   Προσέγγιση = c("Κλασική (A5, stepwise)", "Διαστηματική mid (B2)", "Διαστηματική rad (B2)"),
1304   R2 = round(c(r2_classical, r2_mid, r2_rad), 4),
1305   Adj_R2 = round(c(adj_classical, adj_mid, adj_rad), 4),
1306   N_significant_Vars = c(n_sig_classical, n_sig_mid, n_sig_rad),

```

```

1307 | Ερμηνευσιμότητα = c("Υψηλή", "Υψηλή",
1308 |                       ifelse(is.na(r2_rad) || r2_rad < 0.05, "Χαμηλή", "Μέτρια-υψηλή"))
1309 | )
1310 | ktab(comp, digits = 4, caption = "Πίνακας C1.1 – Συγκριτικός πίνακας τριών προσεγγίσεων.",
1311 |       row.names = FALSE)
1312 | ```
1313 |
1314 | ## C2. Ερμηνεία Αποτελεσμάτων {#c2}
1315 |
1316 | * **Ποιοι τομείς/μετοχές είναι σημαντικοί στην κλασική παλινδρόμηση;**
1317 | Το stepwise μοντέλο (A5) διατηρεί τις: `r paste(a5_sel, collapse = ", ")`. Πρόκειται κατά
1318 | κύριο λόγο για μετοχές που είναι συστατικά του δείκτη, σύμφωνα με την κατασκευή του DJIA ως
1319 | **price-weighted average** 30 μετοχών. Οι μετοχές εκτός δείκτη
1320 | (`r paste(non_dow, collapse = ", ")`) τείνουν να εμφανίζουν μικρότερους ή μη-σημαντικούς
1321 | συντελεστές.
1322 |
1323 | * **Αλλάζει η εικόνα όταν δουλεύουμε με τα `mid`;**
1324 | Σχεδόν καθόλου. Το `mid` αποτελεί ακριβώς το μέσο όρο του ενδοημερήσιου
1325 | διαστήματος και είναι **σχεδόν ταυτόσημο** με την Close-to-Close απόδοση
1326 | όταν η ημερήσια κίνηση είναι περίπου συμμετρική. Συνεπώς, τα ίδια ζεύγη
1327 | μετοχών παραμένουν σημαντικά και οι συντελεστές έχουν παρόμοιο μέγεθος και
1328 | πρόσημο.
1329 |
1330 | * **Τι μας λέει η ανάλυση `rad` για την αστάθεια;**
1331 | Στο συγκεκριμένο δείγμα (2021-2025) το R2 του rad μοντέλου είναι **`r round(b2_r2_rad, 3)`**,
1332 | που υποδηλώνει έναν **ισχυρό κοινό παράγοντα αστάθειας** (market-wide volatility) στο
1333 | cross-section. **Δεν** πρέπει όμως να ερμηνευτεί ως «γραμμική προβλεψιμότητα»: όπως δείξαμε
1334 | στη B2, το R2 είναι κατά κύριο λόγο **μηχανικό** (R2 ≈ `r round(b2_r2_rad_mean, 3)` προκύπτει
1335 | ήδη από τον απλό μέσο όρο των επιμέρους rad – ταυτότητα άθροισης), και η OLS συμπερασματολογία
1336 | είναι άκυρη λόγω αυτοσυσχέτισης (υπό HAC οι σημαντικές μεταβλητές πέφτουν σε
1337 | `r b2_nsig_rad_hac`). Η ορθή μοντελοποίηση της αστάθειας απαιτεί δυναμικά υποδείγματα (GARCH).
1338 |
1339 | Παρ' όλα αυτά, η ίδια η **ύπαρξη** ενός μετρήσιμου κοινού παράγοντα αστάθειας είναι κάτι
1340 | **που η κλασική Close-to-Close ανάλυση δεν μπορεί να αποκαλύψει** (δεν μετράει αστάθεια),
1341 | οπότε η συνεισφορά της διαστηματικής μεθοδολογίας παραμένει σαφής.
1342 |
1343 | Αξίζει να σημειωθεί ότι, σε διαφορετική περίοδο (π.χ. ήρεμη bull market),
1344 | η διακύμανση του $Y_{rad}$ ίσως είναι ακόμη μικρότερη και η ερμηνευτική
1345 | ισχύς του μοντέλου να εξαφανιστεί – όπως προειδοποιεί η εκφώνηση. Στη δική
1346 | μας περίπτωση, η μεγάλη μακροοικονομική αστάθεια της πενταετίας (πανδημία,
1347 | inflation cycle, geopolitical shocks, AI rally) διατήρησε αρκετό σήμα ώστε
1348 | η σχέση να είναι ανιχνεύσιμη.
1349 |
1350 | ## C3. Κριτική και Περιορισμοί {#c3}
1351 |
1352 | * **Υπόθεση γραμμικότητας:** Όλα τα μοντέλα που εφαρμόστηκαν είναι γραμμικά. Στην
1353 | πραγματικότητα, η σχέση μεταξύ μεμονωμένων μετοχών και του δείκτη DIA μπορεί
1354 | να μην είναι αυστηρά γραμμική, ειδικά σε ακραίες ημέρες (μη-γραμμικά
1355 | διαμετάφραστα, jump-diffusion processes, regime-switching).
1356 | * **Μη-κανονικότητα και ετεροσκεδαστικότητα:** Όπως δείξαμε στις ενότητες A1 και
1357 | A5, οι αποδόσεις δεν είναι κανονικές και τα residuals παρουσιάζουν
1358 | ετεροσκεδαστικότητα. Σε μια πληρέστερη μελέτη θα έπρεπε:
1359 | - Είτε να εφαρμοστούν **robust standard errors** (HC3 sandwich estimator).
1360 | - Είτε να προσαρμοστούν **GARCH(1,1)** στις σειρές για ρητή μοντελοποίηση
1361 | της δομής αστάθειας.
1362 | * **Στατικός χρονικός ορίζοντας:** Χρησιμοποιήσαμε όλη την πενταετία 2021-2025.
1363 | Οι σχέσεις μεταξύ μετοχών δεν είναι σταθερές στο χρόνο. Μια rolling-window
1364 | ή Bayesian dynamic linear model θα αποκάλυπτε χρονικές αλλαγές.
1365 | * **Μη-εκτεταμένη επεξεργασία outliers:** Δεν αφαιρέθηκαν ακραίες παρατηρήσεις.
1366 | Στην πράξη θα ήταν δόκιμη η χρήση **robust regression** (M-estimators) για
1367 | να μη δεσπόζουν λίγες ακραίες παρατηρήσεις.
1368 | * **Περιορισμοί της Interval προσέγγισης:**
1369 | - Η αναπαράσταση (mid, rad) χάνει την πληροφωρία **της κατανομής εντός του
1370 | διαστήματος** (π.χ. αν η μετοχή πέρασε περισσότερο χρόνο κοντά στο High
1371 | ή στο Low).
1372 | - Η Center Method των Billard & Diday προϋποθέτει **ανεξάρτητη εκτίμηση**
1373 | των δύο εξισώσεων (mid και rad). Σύγχρονες παραλλαγές (Constrained
1374 | Interval Regression, MinMax method) επιβάλλουν περιορισμούς ώστε το
1375 | προβλεπόμενο διάστημα να μη γίνεται ανάστροφο.
1376 | - Δεν υπάρχει καθιερωμένη Interval FA με αναπαραγώγιμη υλοποίηση
1377 | (βλ. ενότητα B4).
1378 | * **Τι θα κάναμε διαφορετικά:**
1379 | 1. Θα ενσωματώναμε **GARCH** για ρητή μοντελοποίηση `Y_rad`
1380 | *(υλοποιείται στο Παράρτημα Δ9)*.

```

```

1381 | 2. Θα δοκιμάζαμε **MinMax** ή **Constrained Center & Range Method**
1382 | [@limaneto2010] για interval regression που σέβεται την περιοριστική
1383 | σχέση  $\text{`rad} \geq 0`$  *(η CCRM υλοποιείται στο Παράρτημα Δ5)*.
1384 | 3. Θα προσθέταμε **μακρο-ελεγχόμενες** μεταβλητές (επιτόκια, VIX, oil
1385 | prices) για βελτιωμένη ερμηνεία.
1386 | 4. Θα εφαρμόζαμε **SEM με πολλαπλούς λανθάνοντες παράγοντες** ανά τομέα
1387 | *(υλοποιείται στο Παράρτημα Δ8, όπου αναδεικνύεται και ο περιορισμός
1388 | ταυτοποίησης)*.
1389 |
1390 | ---
1391 |
1392 | # Σύνοψη – Συμπεράσματα
1393 |
1394 | Η εργασία αυτή υλοποίησε ένα ολοκληρωμένο πειραματικό πλαίσιο σύγκρισης κλασικής
1395 | και διαστηματικής στατιστικής μοντελοποίησης για τη σχέση του δείκτη DIA με 15
1396 | βασικές αμερικανικές μετοχές. Τα κύρια ευρήματα είναι:
1397 |
1398 | 1. Η **παραγοντική δομή** των μετοχών αναδεικνύει 3 παράγοντες – έναν ευρύ
1399 | mega-cap growth (τεχνολογία/επικοινωνίες/καταναλωτικά), έναν στενό τραπεζικό
1400 | (BAC, JPM) και έναν αμυντικό/υγείας – με τη συν-κίνηση των αποδόσεων να **μην
1401 | ταυτίζεται πάντα με τον ονομαστικό κλάδο** (π.χ. η V κινείται με το growth, η HD
1402 | με τις αμυντικές). Η δομή παραμένει σταθερή σε κλασική και διαστηματική (mid) προσέγγιση.
1403 | 2. Η **κλασική γραμμική παλινδρόμηση** εξηγεί άριστα τη συμπεριφορά του DIA
1404 | χρησιμοποιώντας τις μετοχές που πραγματικά συμμετέχουν στον δείκτη.
1405 | 3. Η **διαστηματική παλινδρόμηση στα κέντρα** (μέθοδος Center-and-Range, Lima Neto &
1406 | de Carvalho 2008, γενίκευση της Billard & Diday 2000) δίνει ουσιαστικά ίδια
1407 | αποτελέσματα στο `mid`, επιβεβαιώνοντάς την ως αξιόπιστη και ερμηνεύσιμη.
1408 | 4. Η **παλινδρόμηση στα `rad`** αποκαλύπτει έναν **ισχυρό κοινό παράγοντα ενδοημερήσιας
1409 | αστάθειας** (market-wide volatility) – κάτι που η κλασική Close-to-Close ανάλυση δεν
1410 | μπορεί να μετρήσει. Το υψηλό  $R^2$  (= `r round(b2_r2_rad, 3)`) είναι ωστόσο **κυρίως μηχανικό**
1411 | (= `r round(b2_r2_rad_mean, 3)`) προκύπτει από τον μέσο όρο των συστατικών – ταυτότητα
1412 | άθροισης) και η OLS συμπερασματολογία είναι άκυρη λόγω αυτοσυσχέτισης· επομένως **δεν**
1413 | πρόκειται για γνήσια «προβλεψιμότητα» της αστάθειας, η οποία απαιτεί δυναμικά υποδείγματα
1414 | (GARCH).
1415 | 5. Το **SEM (bonus B5)** πιστοποιεί την ύπαρξη ενός λανθάνοντος «τεχνολογικού
1416 | παράγοντα» που επηρεάζει σημαντικά την κεντρική απόδοση του DIA.
1417 |
1418 | ---
1419 |
1420 | # Παράρτημα – Επεκτάσεις πέραν της εκφώνησης
1421 |
1422 | Οι παρακάτω αναλύσεις **δεν απαιτούνται** από την εκφώνηση (η βαθμολογούμενη δομή A-C είναι
1423 | ήδη πλήρης)· προστίθενται επειδή εφαρμόζονται στο **υλικό του μαθήματος** (Διάλεξη 13 και 14,
1424 | υποδειγματική εργασία) και εμπλουτίζουν την ανάλυση με μη-γραμμική και οπτική οπτική γωνία.
1425 |
1426 | ## Δ1. Δέντρο Παλινδρόμησης – Σημαντικότητα Μεταβλητών για τον DIA {#d1}
1427 |
1428 | Στη **Διάλεξη 13** (§«Εύρεση υποδείγματος») χρησιμοποιείται δέντρο παλινδρόμησης (`rpart`) για
1429 | **μη-γραμμική** διερεύνηση και κατάταξη της σημαντικότητας των μεταβλητών – εργαλείο που
1430 | συμπληρώνει τη γραμμική stepwise επιλογή της A5. Εφαρμόζουμε την ίδια μεθοδολογία στον DIA:
1431 | προσαρμόζουμε δέντρο, το **κλαδεύουμε** στο `cp` με το ελάχιστο σφάλμα διασταύρωσης
1432 | (cross-validation), και αναφέρουμε τη σχετική σημαντικότητα κάθε μετοχής.
1433 |
1434 | ```{r ext-tree, fig.height=5, fig.cap="Κλαδεμένο δέντρο παλινδρόμησης για τον DIA (μέθοδος anova)."}
1435 | set.seed(1125886)
1436 | tree_data <- data.frame(DIA = Y_classical, X_classical)
1437 | tree_full <- rpart(DIA ~ ., data = tree_data, method = "anova")
1438 | best_cp <- tree_full$cptable[which.min(tree_full$cptable[, "xerror"]), "CP"]
1439 | tree <- prune(tree_full, cp = best_cp)
1440 | rpart.plot(tree, type = 4, fallen.leaves = FALSE, box.palette = "Blues",
1441 |             main = "Δ1.1 – Δέντρο παλινδρόμησης για τον DIA")
1442 | ```
1443 |
1444 | ```{r ext-tree-importance}
1445 | vi <- round(100 * prop.table(tree$variable.importance), 2)
1446 | ktab(data.frame(Μετοχή = names(vi), `Σημαντικότητα (%)` = as.numeric(vi),
1447 |                 check.names = FALSE),
1448 |       caption = "Πίνακας Δ1.1 – Σχετική σημαντικότητα μεταβλητών (δέντρο παλινδρόμησης).",
1449 |       row.names = FALSE)
1450 | ```
1451 |
1452 | ```{r ext-tree-facts, include=FALSE}
1453 | d1_top <- names(sort(tree$variable.importance, decreasing = TRUE))[1:3]
1454 | d1_inA5 <- intersect(d1_top, a5_sel)

```



```

1455 | ```
1456 |
1457 | ##### Σχολιασμός Δ1
1458 |
1459 | * Οι τρεις μετοχές με τη μεγαλύτερη σημαντικότητα στο δέντρο είναι **r paste(d1_top, collapse="," )`**.
1460 | `r if (length(d1_inA5) == length(d1_top)) "Και οι τρεις" else paste(length(d1_inA5), "από τις 3")`
1461 | ανήκουν επίσης στο stepwise γραμμικό μοντέλο (A5), γεγονός που **διασταυρώνει** τα δύο
1462 | ανεξάρτητα εργαλεία: η γραμμική (A5) και η μη-γραμμική (δέντρο) προσέγγιση συμφωνούν στις
1463 | βαρύτερες μετοχές του δείκτη.
1464 | * Το δέντρο, σε αντίθεση με την παλινδρόμηση, αποτυπώνει **κατώφλια και αλληλεπιδράσεις** (π.χ.
1465 | διαφορετική συμπεριφορά σε ημέρες μεγάλων κινήσεων) – απαντώντας εν μέρει στον περιορισμό
1466 | μη-γραμμικότητας που επισημάναμε στη Γ3.
1467 |
1468 | ## Δ2. PCA Biplot {#d2}
1469 |
1470 | Στη **Διάλεξη 14** το biplot αποτελεί τυποποιημένη οπτικοποίηση της PCA (ταυτόχρονη προβολή
1471 | παρατηρήσεων και φορτίσεων). Το κατασκευάζουμε απευθείας από το αντικείμενο `prcomp` (χωρίς
1472 | εξωτερικό πακέτο), προβάλλοντας τις φορτίσεις των μετοχών ως διανύσματα πάνω στο νέφος των
1473 | ημερήσιων παρατηρήσεων στο επίπεδο PC1-PC2.
1474 |
1475 | ```{r ext-biplot, fig.height=5.2, fig.cap="PCA biplot (PC1-PC2): νέφος ημερών + διανύσματα φορτίσεων των μετοχών."}
1476 | scores <- as.data.frame(pca_classical$x[, 1:2])
1477 | load_arrows <- as.data.frame(pca_classical$rotation[, 1:2])
1478 | load_arrows$var <- rownames(load_arrows)
1479 | arrow_scale <- 0.9 * max(abs(scores[, 1:2])) / max(abs(load_arrows[, 1:2]))
1480 | v1 <- 100 * eig_vals[1] / sum(eig_vals)
1481 | v2 <- 100 * eig_vals[2] / sum(eig_vals)
1482 | ggplot() +
1483 |   geom_point(data = scores, aes(PC1, PC2),
1484 |             alpha = 0.10, colour = "#56B4E9", size = 0.7) +
1485 |   geom_segment(data = load_arrows,
1486 |               aes(x = 0, y = 0, xend = PC1 * arrow_scale, yend = PC2 * arrow_scale),
1487 |               arrow = arrow(length = grid::unit(0.18, "cm")),
1488 |               colour = "#D55E00", linewidth = 0.5) +
1489 |   geom_text(data = load_arrows,
1490 |             aes(x = PC1 * arrow_scale * 1.08, y = PC2 * arrow_scale * 1.08, label = var),
1491 |             colour = "#D55E00", size = 3, check_overlap = TRUE) +
1492 |   labs(title = "Δ2.1 – PCA biplot (κλασικές αποδόσεις)",
1493 |        x = sprintf("PC1 (%.1f%%)", v1), y = sprintf("PC2 (%.1f%%)", v2)) +
1494 |   theme_paper()
1495 | ```
1496 |
1497 | ##### Σχολιασμός Δ2
1498 |
1499 | * Σχεδόν **όλα τα διανύσματα δείχνουν προς την ίδια κατεύθυνση στον άξονα PC1**, οπτικοποιώντας
1500 | τον κοινό **market factor** (PC1, `r round(v1, 1)`%): οι μετοχές κινούνται μαζί.
1501 | * Ο άξονας **PC2** (`r round(v2, 1)`%) διαχωρίζει τις growth/tech μετοχές από τις αμυντικές, σε
1502 | πλήρη συμφωνία με την ερμηνεία της A4 και τη δομή παραγόντων της A3.
1503 |
1504 | ---
1505 |
1506 | ## Δ3. Διμεταβλητή Ανάλυση DIA-Μετοχής {#d3}
1507 |
1508 | Ο υποχρεωτικός κατάλογος προ-μοντελοποίησης (Διάλεξη 13, «Μέρος 2») προβλέπει **διμεταβλητή
1509 | διερεύνηση **κάθε σχέσης Y-X *πριν* από την πολυμεταβλητή ανάλυση: scatter plot με loess (για
1510 | μη-γραμμικότητα) και συντελεστές **Pearson** (γραμμική) & **Spearman** (μονότονη) συσχέτισης.
1511 |
1512 | ```{r ext-bivar, fig.height=7.5, fig.cap="DIA vs κάθε μετοχή: loess (μπλε) και γραμμική (κόκκινη) προσαρμογή."}
1513 | biv <- do.call(rbind, lapply(colnames(X_classical), function(nm)
1514 |   data.frame(X = X_classical[[nm]], DIA = Y_classical, Ticker = nm)))
1515 | biv$Ticker <- factor(biv$Ticker, levels = colnames(X_classical))
1516 | ggplot(biv, aes(X, DIA)) +
1517 |   geom_point(alpha = 0.06, colour = "#56B4E9", size = 0.5) +
1518 |   geom_smooth(method = "loess", se = FALSE, colour = "#0072B2", linewidth = 0.5) +
1519 |   geom_smooth(method = "lm", se = FALSE, colour = "#D55E00", linewidth = 0.5) +
1520 |   facet_wrap(~ Ticker, scales = "free_x", ncol = 4) +
1521 |   labs(title = "Δ3.1 – DIA vs κάθε μετοχή (loess μπλε, γραμμικό κόκκινο)",
1522 |        x = "Ημερήσια απόδοση μετοχής", y = "Ημερήσια απόδοση DIA") +
1523 |   theme_paper()
1524 | ```
1525 |
1526 | ```{r ext-bivar-cor}
1527 | biv_cor <- data.frame(
1528 |   Μετοχή = colnames(X_classical),

```

```

1529 | Pearson = sapply(X_classical, function(x) cor(x, Y_classical)),
1530 | Spearman = sapply(X_classical, function(x) cor(x, Y_classical, method = "spearman")),
1531 | check.names = FALSE)
1532 | biv_cor <- biv_cor[order(-biv_cor$Pearson), ]
1533 | ktab(biv_cor, digits = 3, row.names = FALSE,
1534 |       caption = "Πίνακας Δ3.1 – Συσχέτιση DIA-μετοχής (Pearson και Spearman).")
1535 | ```
1536 |
1537 | ```{r ext-bivar-facts, include=FALSE}
1538 | d3_dmax <- max(abs(biv_cor$Pearson - biv_cor$Spearman))
1539 | d3_top <- biv_cor$Μετοχή[1]
1540 | ```
1541 |
1542 | ##### Σχολιασμός Δ3
1543 |
1544 | * Οι γραμμές loess (μπλε) είναι σχεδόν ευθείες και σχεδόν ταυτίζονται με τη γραμμική προσαρμογή
1545 |   (κόκκινη): **οι σχέσεις DIA-μετοχής είναι κατά βάση γραμμικές**, γεγονός που δικαιολογεί εκ των
1546 |   προτέρων τη χρήση γραμμικών υποδειγμάτων στη A5/B2.
1547 | * Pearson και Spearman **σχεδόν συμπίπτουν** (μέγιστη απόκλιση `r round(d3_dmax, 3)`), επιβεβαιώνοντας
1548 |   την απουσία ισχυρής μονότονης-μη-γραμμικής δομής. Η ισχυρότερη συσχέτιση με τον DIA είναι της
1549 |   **`r d3_top`**.
1550 |
1551 | ## Δ4. Παραγοντική Ανάλυση σε Βάθος: Πλάγια Περιστροφή, Αξιοπιστία, Παλινδρόμηση Σκορ {#d4}
1552 |
1553 | ### Πλάγια (oblique) περιστροφή και συσχέτιση παραγόντων
1554 |
1555 | ```{r ext-fa-oblique}
1556 | fa_obl <- psych::fa(X_classical, nfactors = 3, fm = "pa",
1557 |                     rotate = "oblimin", scores = "regression")
1558 | cat("Πίνακας συσχέτισης παραγόντων (oblimin – επιτρέπει συσχετισμένους παράγοντες):\n")
1559 | print(round(fa_obl$Phi, 3))
1560 | ```
1561 |
1562 | ### Αξιοπιστία (Cronbach's α) ανά παράγοντα
1563 |
1564 | ```{r ext-reliability}
1565 | # Ομαδοποίηση από τη μέγιστη φόρτιση varimax (A3): fa_groups από το chunk a3-facts
1566 | alpha_by_factor <- sapply(fa_groups, function(grp) {
1567 |   if (length(grp) < 2) return(NA_real_)
1568 |   suppressWarnings(suppressMessages(
1569 |     psych::alpha(X_classical[, grp], check.keys = TRUE)$total$raw_alpha))
1570 | })
1571 | ktab(data.frame(Παράγοντας = paste0("F", seq_along(alpha_by_factor)),
1572 |                 Μετοχές = vapply(fa_groups, paste, character(1), collapse = ", "),
1573 |                 `Cronbach α` = round(alpha_by_factor, 3), check.names = FALSE),
1574 |       caption = "Πίνακας Δ4.1 – Εσωτερική συνέπεια (Cronbach's α) ανά παράγοντα.",
1575 |       row.names = FALSE)
1576 | ```
1577 |
1578 | ### Παλινδρόμηση στα factor scores
1579 |
1580 | ```{r ext-fa-scores}
1581 | fa_sc <- as.data.frame(fa_model$scores)
1582 | names(fa_sc) <- paste0("F", seq_len(ncol(fa_sc)))
1583 | fs_model <- lm(Y_classical ~ ., data = fa_sc)
1584 | summary(fs_model)
1585 | ```
1586 |
1587 | ```{r ext-fa-facts, include=FALSE}
1588 | d4_phimax <- max(abs(fa_obl$Phi[upper.tri(fa_obl$Phi)]))
1589 | d4_fsr2 <- summary(fs_model)$r.squared
1590 | ```
1591 |
1592 | ##### Σχολιασμός Δ4
1593 |
1594 | * **Πλάγια περιστροφή:** Η μέγιστη συσχέτιση μεταξύ παραγόντων (oblimin) είναι
1595 |   `r round(d4_phimax, 2)`. `r if (d4_phimax < 0.32)` "Είναι μικρή (< 0.32), οπότε η ορθογώνια varimax της A3 είναι απολύτως δ
1596 |   ικαιολογημένη – οι παράγοντες είναι σχεδόν ασυσχέτιστοι." else "Είναι μη-αμελητέα, ένδειξη ότι οι παράγοντες δεν είναι πλήρω
1597 |   ς ανεξάρτητοι (η oblimin δίνει πιο ρεαλιστική εικόνα από τη varimax)."
```

* **Αξιοπιστία (Cronbach's α):** Εδώ το α δεν έχει την κλασική ψυχομετρική έννοια – μετρά τη
 μέση εντός-ομάδας συν-κίνηση των αποδόσεων (είναι μονότονη συνάρτηση της μέσης συσχέτισης
 των μελών). Οι τιμές **διαφέρουν ουσιαστικά**: ο ευρύς growth παράγοντας έχει υψηλό α, αλλά ο
 αμυντικός/υγείας παράγοντας έχει χαμηλό α = `r round(min(alpha\_by\_factor, na.rm = TRUE), 3)` –
 επιβεβαιώνοντας (όπως και η A3) ότι πρόκειται για **ετερογενή ομάδα** (HD + τρεις διαφορετικές

```

1601 | μετοχές υγείας) με ασθενή κοινή κίνηση. Επιπλέον, το  $\alpha$  ενός **διμελούς** παράγοντα (BAC, JPM)
1602 | είναι εγγενώς ασταθές και πρέπει να ερμηνεύεται με επιφύλαξη.
1603 | * **Παλινδρόμηση σκορ:** Με μόλις 3 ορθογώνια factor scores ως παλινδρομητές, το  $R^2$  είναι
1604 | **`r round(d4_fsr2, 3)`** (έναντι `r round(summary(lm_step)$r.squared, 3)` του πλήρους stepwise
1605 | μοντέλου A5) – αξιολογείται συμπίκνωση: τρεις παράγοντες συλλαμβάνουν το μεγαλύτερο μέρος της
1606 | ερμηνευτικής ισχύος των 15 μετοχών.
1607 |
1608 | ## Δ5. Περιορισμένη Μέθοδος Κέντρου-και-Εύρους (CCRM) {#d5}
1609 |
1610 | Η μη-περιορισμένη CRM (B2) μπορεί θεωρητικά να παράγει **αρνητικό** προβλεπόμενο ημι-εύρος. Η
1611 | **Constrained CRM** [lmaneto2010] επαναπροσαρμόζει την εξίσωση του εύρους με
1612 | **μη-αρνητικά ελάχιστα τετράγωνα** (NNLS), εγγυώμενη  $\hat{\text{rad}} \geq 0$ .
1613 |
1614 | ```{r ext-ccrm}
1615 | Xr_mat <- as.matrix(cbind(Intercept = 1, X_rad))
1616 | nn <- nnls::nnls(Xr_mat, Y_rad) # συντελεστές >= 0
1617 | yhat_mid_h <- as.numeric(predict(model_mid))
1618 | yhat_rad_crm <- if (!is.null(model_rad)) as.numeric(predict(model_rad)) else rep(mean(Y_rad), length(Y_rad))
1619 | yhat_rad_ccrm <- as.numeric(Xr_mat %*% nn$x)
1620 |
1621 | obs_L <- Y_mid - Y_rad; obs_U <- Y_mid + Y_rad; w_obs <- obs_U - obs_L
1622 | ival_metrics <- function(yhat_rad) {
1623 |   pL <- yhat_mid_h - yhat_rad; pU <- yhat_mid_h + yhat_rad
1624 |   overlap <- pmax(0, pmin(obs_U, pU) - pmax(obs_L, pL))
1625 |   c(RMSE_L = sqrt(mean((obs_L - pL)^2)),
1626 |     RMSE_U = sqrt(mean((obs_U - pU)^2)),
1627 |     Κάλυψη = mean(overlap / w_obs),
1628 |     Efficiency = mean((pU - pL) / w_obs),
1629 |     `Έγκυρα %` = 100 * mean(pU >= pL))
1630 | }
1631 | tab_ccrm <- rbind(CRM = ival_metrics(yhat_rad_crm), CCRM = ival_metrics(yhat_rad_ccrm))
1632 | ktab(tab_ccrm, digits = 4,
1633 |       caption = "Πίνακας Δ5.1 – Σύγκριση CRM (μη περιορισμένη) vs CCRM (rad ≥ 0).")
1634 | ...
1635 |
1636 | ```{r ext-ccrm-facts, include=FALSE}
1637 | d5_negcoef <- sum(coef(model_rad) < 0)
1638 | d5_negpred <- sum(yhat_rad_crm < 0)
1639 | ...
1640 |
1641 | ##### Σχολιασμός Δ5
1642 |
1643 | * Στο μοντέλο εύρους της CRM, **`r d5_negcoef`** συντελεστές είναι αρνητικοί, αλλά οι
1644 | προβλεπόμενες τιμές rad είναι αρνητικές σε **`r d5_negpred`** μόνο ημέρες – δηλαδή η μη
1645 | περιορισμένη CRM παράγει ήδη `r if (d5_negpred == 0) "100%" else ""` έγκυρα διαστήματα εδώ.
1646 | * Συνεπώς οι μετρικές CRM και CCRM είναι **σχεδόν ταυτόσημες** (Πίνακας Δ5.1): ο περιορισμός
1647 |  $\hat{\text{rad}} \geq 0$  είναι **μη-δεσμευτικός** για το συγκεκριμένο dataset. Αυτό είναι ένα
1648 | ουσιαστικό, αναφέρομαι εύρημα – η CCRM προσφέρει εγγύηση εγκυρότητας χωρίς κόστος ακρίβειας, ενώ
1649 | σε πιο «ήσυχα»/ασταθή δείγματα όπου η CRM παραβιάζει το  $\text{rad} \geq 0$  η διαφορά θα ήταν ουσιώδης.
1650 |
1651 | ## Δ6. Εύρωση Συμπερασματολογία & Διαγνωστικοί Έλεγχοι Χρονοσειράς {#d6}
1652 |
1653 | Επειδή η A5 εντόπισε **ετεροσκεδαστικότητα** (Breusch-Pagan  $\$p \approx 10^{-6}$ ), επαναυπολογίζουμε
1654 | τα p-values με **εύρωστους** εκτιμητές διακύμανσης: HC3 (White) για ετεροσκεδαστικότητα και
1655 | Newey-West (HAC) για ετεροσκεδαστικότητα + αυτοσυσχέτιση.
1656 |
1657 | ```{r ext-robust}
1658 | ct_ols <- summary(lm_step)$coefficients
1659 | ct_hc3 <- lmtest::coeftest(lm_step, vcov. = sandwich::vcovHC(lm_step, type = "HC3"))
1660 | ct_hac <- lmtest::coeftest(lm_step, vcov. = sandwich::NeweyWest(lm_step, lag = 5, prewhite = FALSE))
1661 | rob <- data.frame(
1662 |   Μεταβλητή = sub("\\(Intercept\\)", "Σταθερά", rownames(ct_ols)),
1663 |   Συντελεστής = round(ct_ols[, "Estimate"], 4),
1664 |   `p_OLS` = signif(ct_ols[, "Pr(>|t|)"], 2),
1665 |   `p_HC3` = signif(ct_hc3[, "Pr(>|t|)"], 2),
1666 |   `p_HAC` = signif(ct_hac[, "Pr(>|t|)"], 2),
1667 |   check.names = FALSE)
1668 | ktab(rob, digits = 4, row.names = FALSE,
1669 |       caption = "Πίνακας Δ6.1 – Εύρωση συμπερασματολογία: p-values OLS vs HC3 vs Newey-West HAC.")
1670 | ...
1671 |
1672 | ```{r ext-diagnostics}
1673 | res <- as.numeric(resid(lm_step))
1674 | cat("Ljung-Box (αυτοσυσχέτιση καταλοίπων, lag 10):\n")

```

```

1675 | print(Box.test(res, lag = 10, type = "Ljung-Box"))
1676 |
1677 | # ARCH-LM (δεσμευμένη ετεροσκεδαστικότητα - ARCH effects), χειροκίνητα:
1678 | p_arch <- 5; emb <- embed(res^2, p_arch + 1)
1679 | arch_fit <- lm(emb[, 1] ~ emb[, -1])
1680 | arch_LM <- nrow(emb) * summary(arch_fit)$r.squared
1681 | cat(sprintf("\nARCH-LM (lag %d): LM = %.1f, df = %d, p = %.3g\n",
1682 |           p_arch, arch_LM, p_arch, pchisq(arch_LM, p_arch, lower.tail = FALSE)))
1683 |
1684 | cat("\nADF test (H0: μοναδιαία ρίζα / μη στασιμότητα):\n")
1685 | print(suppressWarnings(tseries::adf.test(Y_classical)))
1686 | cat("\nKPSS test (H0: στασιμότητα):\n")
1687 | print(suppressWarnings(tseries::kpss.test(Y_classical)))
1688 | ```
1689 |
1690 | ```{r ext-diag-facts, include=FALSE}
1691 | d6_lb <- Box.test(res, lag = 10, type = "Ljung-Box")$p.value
1692 | d6_arch <- pchisq(nrow(embed(res^2, 6)) * summary(lm(embed(res^2,6)[,1] ~ embed(res^2,6)[,-1]))$r.squared, 5, lower.tail = F
1693 | ALSE)
1694 | d6_adf <- suppressWarnings(tseries::adf.test(Y_classical)$p.value)
1695 | d6_nrob <- sum(ct_ols[-1, "Pr(>|t|)"] < 0.05) - sum(ct_hac[-1, "Pr(>|t|)"] < 0.05)
1696 | ```
1697 | ##### Σχολιασμός Δ6
1698 |
1699 | * **Εύρωστα p-values:** Παρά την ετεροσκεδαστικότητα/αυτοσυσχέτιση, τα συμπεράσματα είναι **σταθερά**:
1700 |   η αλλαγή από OLS σε HAC μεταβάλλει το πλήθος σημαντικών συντελεστών ( $\alpha=0.05$ ) κατά
1701 |   `r abs(d6_nrob)` – οι βαρύτερες μετοχές παραμένουν ισχυρά σημαντικές με εύρωστους εκτιμητές.
1702 | * **Ljung-Box** (p = `r signif(d6_lb, 3)`): `r if (d6_lb < 0.05) "υπάρχει στατιστικά σημαντική αυτοσυσχέτιση καταλοίπων (ανα
1703 | μενόμενη σε ημερήσιες σειρές· δικαιολογεί τους HAC εκτιμητές)" else "δεν εντοπίζεται σημαντική αυτοσυσχέτιση καταλοίπων"`.
1704 | * **ARCH-LM** (p = `r signif(d6_arch, 3)`): `r if (d6_arch < 0.05) "ισχυρές ARCH επιδράσεις – δεσμευμένη ετεροσκεδαστικότητα
1705 | (volatility clustering), που δικαιολογεί μοντέλα τύπου GARCH ως μελλοντική επέκταση" else "δεν εντοπίζονται ARCH επιδράσεις
1706 | "`.
1707 | * **Στασιμότητα:** Το ADF απορρίπτει τη μοναδιαία ρίζα (p `r if (d6_adf <= 0.01) "< 0.01" else paste("=", signif(d6_adf, 3))
1708 | `),
1709 |   στο όριο αναφοράς του ελέγχου) και το KPSS δεν απορρίπτει τη στασιμότητα (p > 0.10) – οι
1710 |   αποδόσεις είναι **στασιμες**, προϋπόθεση εγκυρότητας της παλινδρόμησης (σε αντίθεση με τις
1711 |   μη-στασιμες τιμές).
1712 | ## Δ7. Σταθερότητα Εκτός Δείγματος (Out-of-Sample) {#d7}
1713 |
1714 | * **Σημαντική διευκρίνιση:** Η παλινδρόμηση είναι **σύγχρονη** – η απόδοση του DIA την ημέρα  $t$ 
1715 |   ερμηνεύεται από τις αποδόσεις των μετοχών την **ίδια** ημέρα  $t$ . Επειδή ο DIA είναι (κατά
1716 |   κατασκευή) σχεδόν ένα σταθμισμένο καλάθι αυτών των μετοχών, αυτό αποτελεί **ανακατασκευή του
1717 |   καλαθιού, ΟΧΙ πρόβλεψη**. Το out-of-sample  $R^2$  εδώ ελέγχει τη **σταθερότητα της ερμηνευτικής
1718 |   σχέσης** (απουσία overfitting) σε χρονολογικά μεταγενέστερα δεδομένα – δεν αποτελεί ισχυρισμό
1719 |   προβλεψιμότητας. Χωρίζουμε χρονολογικά (χωρίς ανακάτεμα) σε **80% train / 20% test**.
1720 | ```{r ext-oos}
1721 | n_obs2 <- length(Y_classical); cut <- floor(0.8 * n_obs2)
1722 | tr <- seq_len(cut); te <- (cut + 1):n_obs2
1723 | oos_one <- function(Y, X) {
1724 |   d <- data.frame(Y = Y, X = X)
1725 |   m <- lm(Y ~ ., data = d[tr, ]); ph <- predict(m, newdata = d[te, ])
1726 |   sse <- sum((Y[te] - ph)^2); sst <- sum((Y[te] - mean(Y[tr]))^2)
1727 |   c(R2 = 1 - sse / sst, RMSE = sqrt(mean((Y[te] - ph)^2)), MAE = mean(abs(Y[te] - ph)))
1728 | }
1729 | oos <- rbind(`Κλασική` = oos_one(Y_classical, X_classical),
1730 |             `Διάστημα mid` = oos_one(Y_mid, X_mid),
1731 |             `Διάστημα rad` = oos_one(Y_rad, X_rad))
1732 | ktab(oos, digits = 4,
1733 |      caption = "Πίνακας Δ7.1 – Επίδοση εκτός δείγματος (χρονολογικό 80/20 split).")
1734 | ```
1735 |
1736 | ```{r ext-oos-plot, fig.height=4, fig.cap="Σύγχρονη ανακατασκευή του DIA εκτός δείγματος (expanding window): προβλεπόμενες v
1737 | s πραγματικές τιμές."}
1738 | dcl <- data.frame(Y = Y_classical, X_classical)
1739 | pred_ew <- vapply(cut:(n_obs2 - 1), function(i) {
1740 |   m <- lm(Y ~ ., data = dcl[seq_len(i), ])
1741 |   as.numeric(predict(m, newdata = dcl[i + 1, , drop = FALSE]))
1742 | }, numeric(1))
1743 | ew_idx <- (cut + 1):n_obs2
1744 | ew_df <- data.frame(Actual = Y_classical[ew_idx], Predicted = pred_ew)
1745 | ew_rmse <- sqrt(mean((ew_df$Actual - ew_df$Predicted)^2))

```

```

1743 | ggplot(ew_df, aes(Actual, Predicted)) +
1744 |   geom_point(alpha = 0.30, colour = "#0072B2", size = 0.8) +
1745 |   geom_abline(slope = 1, intercept = 0, colour = "#D55E00", linetype = 2) +
1746 |   labs(title = sprintf("Δ7.1 – Σύγχρονη ανακατασκευή εκτός δείγματος: RMSE = %.4f", ew_rmse),
1747 |         x = "Πραγματική απόδοση DIA", y = "Ανακατασκευασμένη απόδοση DIA") +
1748 |   theme_paper()
1749 |   ```
1750 |
1751 |   ```{r ext-lagged}
1752 |   # το ίδιο σχήμα, αλλά με πραγματική υστέρηση 1 ημέρας (X_{t-1} -> Y_t): γνήσια πρόβλεψη
1753 |   dlag <- data.frame(Y = Y_classical[-1], X_classical[-nrow(X_classical), ])
1754 |   nL <- nrow(dlag); cutL <- floor(0.8 * nL) # δικό του 80/20 split (n-1 γραμμές)
1755 |   trL <- seq_len(cutL); teL <- (cutL + 1):nL
1756 |   m_lag <- lm(Y ~ ., data = dlag[trL, ])
1757 |   ph_lag <- predict(m_lag, newdata = dlag[teL, ])
1758 |   oos_r2_lag <- 1 - sum((dlag$Y[teL] - ph_lag)^2) / sum((dlag$Y[teL] - mean(dlag$Y[trL]))^2)
1759 |   cat("OOS R^2 με ΓΝΗΣΙΑ υστέρηση 1 ημέρας (πραγματική πρόβλεψη):", round(oos_r2_lag, 3), "\n")
1760 |   ```
1761 |
1762 |   ```{r ext-oos-facts, include=FALSE}
1763 |   d7_r2 <- oos["Κλασική", "R2"]
1764 |   d7_r2_lag <- oos_r2_lag
1765 |   ```
1766 |
1767 |   ##### Σχολιασμός Δ7
1768 |
1769 |   * **Σταθερότητα (σύγχρονη):** Το κλασικό μοντέλο διατηρεί υψηλό out-of-sample  $R^2$  =
1770 |      $\text{r\_round}(d7\_r2, 3)$  στο μεταγενέστερο 20% – η ερμηνευτική σχέση είναι **σταθερή και δεν
1771 |     οφείλεται σε overfitting**. Τα μοντέλα `mid` δίνουν σχεδόν ταυτόσημη επίδοση. Όμως, όπως
1772 |     τονίστηκε, αυτό είναι **ανακατασκευή του καλαθιού** (σύγχρονοι παλινδρομητές), **όχι πρόβλεψη**.
1773 |   * **Γνήσια προβλεψιμότητα (έλεγχος υστέρησης):** Όταν επαναλάβουμε το ίδιο σχήμα με **πραγματική
1774 |     υστέρηση μίας ημέρας** ( $X_{t-1}$  to  $Y_t$ ), το out-of-sample  $R^2$  καταρρέει σε
1775 |      $\text{r\_round}(d7\_r2\_lag, 3)$  (πρακτικά μηδέν / αρνητικό) – οι ημερήσιες αποδόσεις του DIA **δεν
1776 |     είναι προβλέψιμες** από τις χθεσινές αποδόσεις των μετοχών, σύμφωνα με την υπόθεση
1777 |     αποτελεσματικής αγοράς. Το υψηλό σύγχρονο  $R^2$  αντανακλά αποκλειστικά τη λογιστική ταυτότητα
1778 |     «δείκτης = καλάθι συστατικών», όχι προβλεπτική ικανότητα.
1779 |
1780 |   ## Δ8. Πολυπαραγοντικό Δομικό Υπόδειγμα (SEM) {#d8}
1781 |
1782 |   Επεκτείνουμε το μινιμαλιστικό SEM της B5 σε **τέσσερις λανθάνοντες κλαδικούς παράγοντες**
1783 |   (Tech, Fin, Comm, Health), καθένas με 3 δείκτες, που μαζί ερμηνεύουν το κέντρο της απόδοσης του
1784 |   DIA. Χρησιμοποιούμε τον **εύρωστο εκτιμητή MLR**.
1785 |
1786 |   ```{r ext-sem-multi}
1787 |   # Σε ποσοστιαίες αποδόσεις (x100) για αριθμητική ευστάθεια του εκτιμητή.
1788 |   sem_data2 <- data.frame(Y_mid = Y_mid, X_mid) * 100
1789 |   model2 <- '
1790 |     Tech   ~ NVDA + AAPL + MSFT
1791 |     Fin    ~ BAC + JPM + V
1792 |     Comm   ~ GOOGL + META + NFLX
1793 |     Health ~ LLY + JNJ + UNH
1794 |     Y_mid ~ Tech + Fin + Comm + Health
1795 |   '
1796 |   fit2 <- tryCatch(suppressWarnings(lavaan::sem(model2, data = sem_data2, estimator = "MLR")),
1797 |     error = function(e) NULL)
1798 |   conv2 <- !is.null(fit2) && isTRUE(lavaan::lavInspect(fit2, "converged"))
1799 |   # έλεγχος παραδεκτότητας (όχι μόνο σύγκλισης): Heywood case (αρνητική εκτιμώμενη
1800 |   # διακύμανση) ή τυποποιημένος συντελεστής > 1 (αδύνατος) -> μη παραδεκτή λύση.
1801 |   neg_var2 <- NA; max_std2 <- NA; adm2 <- FALSE
1802 |   if (conv2) {
1803 |     pev <- lavaan::parameterEstimates(fit2)
1804 |     neg_var2 <- any(pev$op == "~" & pev$lhs == pev$rhs & pev$est < 0)
1805 |     ss2 <- lavaan::standardizedSolution(fit2)
1806 |     max_std2 <- max(abs(ss2$est.std[ss2$op == "~"]))
1807 |     adm2 <- !neg_var2 && max_std2 <= 1.0001
1808 |   }
1809 |   if (conv2) {
1810 |     fm2 <- lavaan::fitMeasures(fit2, c("cfi", "tli", "rmsea", "srmr", "chisq", "df"))
1811 |     ktab(data.frame(Δείκτης = names(fm2), Τιμή = round(as.numeric(fm2), 3), check.names = FALSE),
1812 |       caption = "Πίνακας Δ8.1 – Μέτρα προσαρμογής πολυπαραγοντικού SEM (MLR).", row.names = FALSE)
1813 |     if (!adm2) cat("\nΠΡΟΣΟΧΗ – ΜΗ ΠΑΡΑΔΕΚΤΗ ΛΥΣΗ (Heywood case):",
1814 |       if (isTRUE(neg_var2)) "αρνητική εκτιμώμενη διακύμανση." else "",
1815 |       sprintf("μέγιστος τυποπ. δομικός συντελεστής = %.2f (> 1).\n", max_std2))
1816 |   } else {

```

```

1817 fm2 <- NULL
1818 cat("Το πολυπαραγοντικό SEM ΔΕΝ συνέκλινε: πρόβλημα ταυτοποίησης – βλ. σχολιασμό.\n")
1819 }
1820 ...
1821
1822 ```{r ext-sem-struct}
1823 if (conv2) {
1824   pe2 <- lavaan::standardizedSolution(fit2)
1825   struct <- pe2[pe2$op == "~", c("rhs", "est.std", "pvalue")]
1826   names(struct) <- c("Παράγοντας", "Τυποπ. συντελεστής", "p-value")
1827   ktab(struct, digits = 3, row.names = FALSE,
1828     caption = "Πίνακας Δ8.2 – Δομικοί συντελεστές: κέντρο ΔΙΑ ανά κλαδικό παράγοντα.")
1829 } else {
1830   cat("(Δεν εμφανίζονται δομικοί συντελεστές – το μοντέλο δεν συνέκλινε.)\n")
1831 }
1832 ...
1833
1834 ```{r ext-sem-facts, include=FALSE}
1835 d8_conv <- conv2
1836 d8_cfi <- if (conv2) fm2[["cfi"]] else NA_real_
1837 ...
1838
1839 ##### Σχολιασμός Δ8
1840
1841 * **Παραδεκτότητα της λύσης:** `r if (!isTRUE(conv2)) "Το μοντέλο **δεν συγκλίνει**." else if (!isTRUE(adm2)) paste0("Αν και
ο εκτιμητής επιστρέφει αριθμητική σύγκλιση (CFI = ", round(d8_cfi, 3), "), η λύση είναι **μη παραδεκτή – Heywood case**:",
if (isTRUE(neg_var2)) "εμφανίζεται **αρνητική εκτιμώμενη διακύμανση** και " else "", "ο τυποποιημένος δομικός συντελεστής φ
τάνει το **", round(max_std2, 2), " (> 1, μαθηματικά αδύνατο)**." Επομένως οι επιμέρους δομικοί συντελεστές του Πίνακα Δ8.2 *
*ΔΕΝ είναι ερμηνεύσιμοι** – δεν μπορούμε να πούμε «ποιος κλάδος επηρεάζει περισσότερο».)" else paste0("Η λύση είναι παραδεκ
τή, με CFI = ", round(d8_cfi, 3), ".")`
1842 * **Αιτία – ταυτοποίηση & πολυσυγγραμμικότητα:** Οι κλαδικοί παράγοντες είναι **έντονα
συσχετισμένοι** (κοινός παράγοντας αγοράς), γεγονός που – όπως προειδοποιεί η Διάλεξη 16 –
οδηγεί ακριβώς σε τέτοιες μη παραδεκτές/ασταθείς λύσεις (το συνολικό «μήνυμα αγοράς» μοιράζεται
ασταθώς μεταξύ συσχετισμένων παραγόντων, παράγοντας συντελεστές > 1 και αρνητικές διακυμάνσεις).
Πρόκειται για **γνήσιο μεθοδολογικό περιορισμό** του πολυπαραγοντικού SEM σε ισχυρά συσχετισμένα
χρηματιστηριακά δεδομένα – και είναι ο λόγος που το **μινιμαλιστικό SEM της B5 (ένας παράγοντας)
είναι η σταθερά ερμηνεύσιμη επιλογή**.
1843
1844 ## Δ9. Το rad ως Εκτιμητής Αστάθειας: Parkinson και GARCH {#d9}
1845
1846 Το Μέρος Β μεταχειρίζεται το `rad` ως «τη διαστηματική πλευρά» των δεδομένων. Εδώ το
συνδέουμε ρητά με τη χρηματοοικονομική βιβλιογραφία: το κανονικοποιημένο ημι-εύρος είναι
ένος **range-based εκτιμητής αστάθειας** της οικογένειας του @parkinson1980, και η δυναμική
του συγκρίνεται με τη δεσμευμένη αστάθεια ενός GARCH(1,1) [@engle1982; @bollerslev1986].
1847
1848 ##### Δ9.1 Σύγκριση με τον εκτιμητή του Parkinson
1849
1850 Ο @parkinson1980 έδειξε ότι η ημερήσια διακύμανση εκτιμάται αποδοτικά από το εύρος:

$$\hat{\sigma}^2_{P,t} = \ln^2(H_t/L_t) / (4 \ln 2)$$

Για μικρές ημερήσιες κινήσεις

$$\ln(H/L) \approx (H-L)/L$$
,
οπότε το  $\text{rad}_t = (H_t - L_t) / (2C_{t-1})$  είναι, ως προς
κλίμακα, το ίδιο μέγεθος – το επιβεβαιώνουμε εμπειρικά.
1851
1852 ```{r ext-parkinson, fig.height=3.8, fig.cap="Το rad του ΔΙΑ έναντι του εκτιμητή Parkinson: πρακτικά ταυτόσημα (ως προς κλίμ
ακα)."}
1853 dia_ohlc <- prices_list$DIA
1854 sig_park <- sqrt(log(as.numeric(Hi(dia_ohlc)) / as.numeric(Lo(dia_ohlc)))^2 / (4 * log(2)))
1855 # ευθυγράμμιση με το panel (το panel χάνει την 1η μέρα λόγω lag)
1856 park_df <- data.frame(Date = index(dia_ohlc), sig_park = sig_park)
1857 park_df <- park_df[match(as.Date(row.names(df_classical)), park_df$Date), ]
1858 d9_cor_park <- cor(park_df$sig_park, Y_rad)
1859
1860 ggplot(data.frame(park = park_df$sig_park, rad = Y_rad), aes(park, rad)) +
1861   geom_point(alpha = 0.15, colour = "#0072B2", size = 0.7) +
1862   geom_smooth(method = "lm", se = FALSE, colour = "#D55E00", linewidth = 0.5) +
1863   labs(title = sprintf("Δ9.1 – rad vs Parkinson: r = %.3f", d9_cor_park),
1864     x = "Εκτιμητής Parkinson (ημερήσιο σ)", y = "rad (κανονικοποιημένο ημι-εύρος)") +
1865   theme_paper()
1866 ...
1867
1868 ##### Σχολιασμός Δ9.1
1869
1870 * Η συσχέτιση rad-Parkinson είναι  $r = \text{round}(d9\_cor\_park, 3)$  – πρακτικά ταύτιση. Το
`rad` της διαστηματικής αναπαράστασης **είναι** ο εκτιμητής αστάθειας του Parkinson (με
διαφορετική κανονικοποίηση:  $C_{t-1}$  αντί για  $L_t$  στον παρονομαστή). Η διαστηματική

```

```

1885 | προσέγγιση του Μέρους Β αποκτά έτσι άμεση θεωρητική θεμελίωση στη βιβλιογραφία
1886 | range-based volatility. ο εκτιμητής των @garmanklass1980 αποτελεί το OHLC-βελτιωμένο
1887 | ανάλογο και φυσική μελλοντική επέκταση.
1888 |
1889 | ### Δ9.2 GARCH(1,1) και σύγκριση με το rad
1890 |
1891 | Η Δ6 τεκμηρίωσε ισχυρές ARCH επιδράσεις (LM  $p < 0.001$ ) και τόσο η Γ3 όσο και η Β2
1892 | παραπέμπουν σε GARCH ως το ορθό δυναμικό μοντέλο αστάθειας. Το προσαρμόζουμε εδώ.
1893 |
1894 | ```{r ext-garch, fig.height=3.8, fig.cap="Δεσμευμένη αστάθεια GARCH(1,1) του DIA και κανονικοποιημένο ημι-εύρος rad."}
1895 | # GARCH(1,1) στις ποσοστιαίες αποδόσεις (x100 για αριθμητική ευστάθεια του optimizer)
1896 | r_pct <- Y_classical * 100
1897 | g_fit <- tryCatch(suppressWarnings(tseries::garch(r_pct, order = c(1, 1), trace = FALSE)),
1898 |                   error = function(e) NULL)
1899 | if (!is.null(g_fit)) {
1900 |   co <- coef(g_fit) # a0 (omega), a1 (ARCH), b1 (GARCH)
1901 |   sig_g <- as.numeric(fitted(g_fit)[, 1]) / 100 # conditional sigma, πίσω σε απλές μονάδες
1902 |   d9_persist <- unname(co["a1"] + co["b1"])
1903 |   d9_cor_garch <- cor(sig_g, Y_rad, use = "complete.obs")
1904 |   # Ljung-Box στα τυποποιημένα τετραγωνισμένα κατάλοιπα: απορρόφησε το ARCH;
1905 |   z <- na.omit(residuals(g_fit))
1906 |   d9_lb_g <- Box.test(z^2, lag = 10, type = "Ljung-Box")$p.value
1907 |   cat(sprintf("GARCH(1,1): omega=%.4f alpha=%.3f beta=%.3f (a+b=%.3f)\n",
1908 |               co["a0"], co["a1"], co["b1"], d9_persist))
1909 |   cat(sprintf("cor(sigma_t, rad_t) = %.3f Ljung-Box z^2 (lag 10): p = %.3f\n",
1910 |               d9_cor_garch, d9_lb_g))
1911 |   gd <- data.frame(Date = as.Date(rownames(df_classical)),
1912 |                     `GARCH σ` = sig_g, rad = Y_rad, check.names = FALSE)
1913 |   gd_long <- rbind(data.frame(Date = gd$Date, value = gd$`GARCH σ`, Σειρά = "GARCH σ_t"),
1914 |                    data.frame(Date = gd$Date, value = gd$rad, Σειρά = "rad_t"))
1915 |   print(
1916 |     ggplot(gd_long, aes(Date, value, colour = Σειρά)) +
1917 |       geom_line(linewidth = 0.3, alpha = 0.85, na.rm = TRUE) +
1918 |       scale_colour_manual(values = c("GARCH σ_t" = "#D55E00", "rad_t" = "#56B4E9")) +
1919 |       labs(title = "Δ9.2 – Δεσμευμένη αστάθεια GARCH vs rad (DIA)",
1920 |            x = NULL, y = "Ημερήσια αστάθεια", colour = NULL) +
1921 |       theme_paper() + theme(legend.position = "top")
1922 |   )
1923 | } else {
1924 |   d9_persist <- NA; d9_cor_garch <- NA; d9_lb_g <- NA
1925 |   cat("To GARCH(1,1) δεν συνέκλινε στο δείγμα - αναφέρεται ως περιορισμός.\n")
1926 | }
1927 | ```
1928 |
1929 | ##### Σχολιασμός Δ9.2
1930 |
1931 | * `r if (!is.null(g_fit)) paste0("To GARCH(1,1) εκτιμά **επιμονή αστάθειας  $\alpha + \beta =$ ", round(d9_persist, 3), "** – τυπική τιμή
για ημερήσιες αποδόσεις δεικτών (ισχυρό volatility clustering, κοντά στη μονάδα αλλά στάσιμο). Τα τυποποιημένα κατάλοιπα δεν
εμφανίζουν πλέον ARCH δομή (Ljung-Box στα  $z^2$   $p =$ ", signif(d9_lb_g, 2), ") – το μοντέλο απορρόφησε την ετεροσκεδαστικότητα
που τεκμηρίωσε η Δ6.") else "To μοντέλο δεν συνέκλινε – αναφέρεται ως περιορισμός."`
1932 | * **Σύνδεση με το rad:** η συσχέτιση της δεσμευμένης αστάθειας  $\sigma_t$  με το
1933 |  $\text{rad}_t$  είναι *`r if (!is.null(g_fit)) round(d9_cor_garch, 3) else NA`*. Οι δύο
1934 | σειρές παρακολουθούν τον ίδιο κοινό κύκλο αστάθειας (2022, Αύγ 2024, Απρ 2025), με το
1935 | GARCH να δίνει την **εξομαλυσμένη/επίμονη** συνιστώσα και το rad την **ημερήσια
πραγματοποιημένη** – δύο συμπληρωματικές όψεις: το rad είναι θορυβώδης αλλά άμεσος
1936 | (range-based) εκτιμητής, το GARCH φιλτραρισμένη δυναμική πρόβλεψη. Σημειώνεται ότι
1937 | πρόκειται για **σύγχρονη συν-κίνηση**, όχι αξιολόγηση προβλεπτικής ικανότητας.
1938 |
1939 |
1940 | ## Δ10. Χρονική Σταθερότητα: Rolling Window και Υποπερίοδοι {#d10}
1941 |
1942 | Η Γ3 αναγνώρισε ως περιορισμό τον **στατικό χρονικό ορίζοντα**. Εδώ ποσοτικοποιούμε τη
1943 | χρονική μεταβλητότητα της σχέσης: κυλιόμενο παράθυρο 250 ημερών ( $\approx 1$  έτος συναλλαγών)
1944 | για το  $R^2$  και τους συντελεστές, και σύγκριση των δύο μεγάλων υποπεριοδών.
1945 |
1946 | ```{r ext-rolling, fig.height=4.6, fig.cap="Κυλιόμενο (250 ημερών)  $R^2$  του κλασικού μοντέλου και κυλιόμενοι συντελεστές των J
PM, V, HD."}
1947 | dates_cl <- as.Date(rownames(df_classical))
1948 | dat_cl <- data.frame(Y = Y_classical, X_classical)
1949 | win <- 250
1950 | idx_end <- win:nrow(dat_cl)
1951 | # ένα lm ανά παράθυρο (~1000 προσαρμογές, δευτερόλεπτα)
1952 | roll <- vapply(idx_end, function(i) {
1953 |   m <- lm(Y ~ ., data = dat_cl[(i - win + 1):i, ])
1954 |   c(r2 = summary(m)$r.squared, coef(m)[c("JPM", "V", "HD")])

```

```

1955 | }, numeric(4))
1956 | roll_df <- data.frame(Date = dates_cl[idx_end], t(roll))
1957 | names(roll_df) <- c("Date", "R2", "JPM", "V", "HD")
1958 | roll_long <- reshape(roll_df, direction = "long", varying = c("R2", "JPM", "V", "HD"),
1959 |                       v.names = "value", times = c("R2", "JPM", "V", "HD"),
1960 |                       timevar = "Μέγεθος")
1961 | roll_long$Μέγεθος <- factor(roll_long$Μέγεθος,
1962 |                             levels = c("R2", "JPM", "V", "HD"),
1963 |                             labels = c("Κυλιόμενο R2", "β JPM", "β V", "β HD"))
1964 | ggplot(roll_long, aes(Date, value)) +
1965 |   geom_line(colour = "#0072B2", linewidth = 0.4) +
1966 |   facet_wrap(~ Μέγεθος, ncol = 2, scales = "free_y") +
1967 |   labs(title = "Δ10.1 – Κυλιόμενη (250 ημ.) εκτίμηση: R2 και συντελεστές",
1968 |         x = NULL, y = NULL) +
1969 |   theme_paper()
1970 | ```
1971 |
1972 | ```{r ext-subperiods}
1973 | # υποπερίοδοι: 2021-2022 (πληθωρισμός/bear) vs 2023-2025 (AI rally κ.ε.)
1974 | cutd <- as.Date("2023-01-01")
1975 | sp <- function(rows) {
1976 |   m1 <- lm(Y ~ ., data = data.frame(Y = Y_classical, X_classical)[rows, ])
1977 |   m2 <- lm(Y ~ ., data = data.frame(Y = Y_rad, X_rad)[rows, ])
1978 |   c(`n ημέρες` = sum(rows),
1979 |     `R2 κλασικό` = summary(m1)$r.squared,
1980 |     `R2 rad` = summary(m2)$r.squared,
1981 |     `β JPM` = unname(coef(m1)["JPM"]))
1982 | }
1983 | sub_tab <- rbind(`2021-2022 (bear/πληθωρισμός)` = sp(dates_cl < cutd),
1984 |                 `2023-2025 (AI rally κ.ε.)` = sp(dates_cl >= cutd))
1985 | ktab(sub_tab, digits = 3,
1986 |       caption = "Πίνακας Δ10.1 – Υποπερίοδοι: μέγεθος, R2 (κλασικό και rad), συντελεστής JPM.")
1987 | ```
1988 |
1989 | ```{r ext-rolling-facts, include=FALSE}
1990 | d10_r2_rng <- range(roll_df$R2)
1991 | d10_rad_gap <- abs(sub_tab[1, "R2 rad"] - sub_tab[2, "R2 rad"])
1992 | ```
1993 |
1994 | ##### Σχολιασμός Δ10
1995 |
1996 | * Το κυλιόμενο R2 κινείται μεταξύ round(d10_r2_rng[1], 2) και
1997 |   round(d10_r2_rng[2], 2): η ερμηνευτική ισχύς του καλαθιού είναι διαχρονικά υψηλή
1998 |   αλλά όχι σταθερή – οι συντελεστές (π.χ. JPM) μετατοπίζονται αισθητά μεταξύ καθεστώτων,
1999 |   επιβεβαιώνοντας με στοιχεία τον περιορισμό της Γ3 περί στατικού ορίζοντα.
2000 | * Στις υποπερίοδοι (Πίνακας Δ10.1), το R2 του rad** διαφέρει μόλις κατά
2001 |   round(d10_rad_gap, 2) μεταξύ 2021-22 και 2023-25.
2002 |   if (d10_rad_gap < 0.05) "Η σταθερότητα αυτή είναι αξιοσημείωτη: ο κοινός παράγοντας ενδοημερήσιας αστάθειας παρέμεινε ε
2003 |   ξίσου ισχυρός και στα δύο καθεστώτα του δείγματός μας – η εξάρτηση από την περίοδο για την οποία προειδοποιεί η εκφώνηση (FA
2004 |   Q) δεν εκδηλώνεται σε αυτή την κλίμακα υποδιαίρεσης. Πιθανή εξήγηση: και οι δύο υποπερίοδοι περιέχουν επεισόδια υψηλής αστάθ
2005 |   ειας (2022 bear· Αύγ 2024 / Απρ 2025), οπότε καμία δεν είναι πραγματικά «ήρεμη»." else "Η διαφορά αυτή αποτυπώνει την εξάρτη
2006 |   ση από την περίοδο για την οποία προειδοποιεί η εκφώνηση (FAQ): σε ημερότερες αγορές ο κοινός παράγοντας αστάθειας εξασθενεί
2007 |   ."
```

Δ11. Αβεβαιότητα Εκτιμήσεων: Block Bootstrap και Time-Series CV {#d11}

Τα R² των βασικών μοντέλων αναφέρονται ως σημειακές τιμές. Εδώ ποσοτικοποιούμε την αβεβαιότητά τους με `moving-block bootstrap` [Kunsch1989] – τα μπλοκ (μήκους 22 ημερών ≈ 1 μήνας συναλλαγών) διατηρούν την αυτοσυσχέτιση/volatility clustering εντός μπλοκ – και επεκτείνουμε τον έλεγχο του Δ7 σε `5` διαδοχικά χρονικά folds.

```

2011 | ```{r ext-bootstrap}
2012 | set.seed(1125886)
2013 | block_boot_r2 <- function(Y, X, B = 1000, l = 22) {
2014 |   n <- length(Y); nb <- ceiling(n / l)
2015 |   vapply(seq_len(B), function(b) {
2016 |     starts <- sample.int(n - l + 1, nb, replace = TRUE)
2017 |     idx <- as.vector(outer(0:(l - 1), starts, "+"))[1:n] # συρραφή μπλοκ
2018 |     d <- data.frame(Y = Y[idx], X[idx, ])
2019 |     summary(lm(Y ~ ., data = d))$r.squared
2020 |   }, numeric(1))
2021 | }
2022 | bb_cl <- block_boot_r2(Y_classical, X_classical)
2023 | bb_rad <- block_boot_r2(Y_rad, X_rad)
```



```

2024 | ci <- function(v) quantile(v, c(0.025, 0.975))
2025 | boot_tab <- rbind(
2026 |   `Κλασικό R²` = c(Eκτίμηση = summary(lm(Y ~ ., data.frame(Y = Y_classical, X_classical)))$r.squared,
2027 |     ci(bb_cl)),
2028 |   `rad R²`    = c(Eκτίμηση = summary(lm(Y ~ ., data.frame(Y = Y_rad, X_rad)))$r.squared,
2029 |     ci(bb_rad)))
2030 | colnames(boot_tab) <- c("Εκτίμηση", "2.5%", "97.5%")
2031 | ktab(boot_tab, digits = 3,
2032 |   caption = "Πίνακας Δ11.1 – Moving-block bootstrap: 95\\% διαστήματα εμπιστοσύνης (B = 1000, l = 22).")
2033 | ...
2034 |
2035 | ```{r ext-tscv}
2036 | # 5 expanding-origin folds: train έως 60..80%, test το επόμενο 5% (σύγχρονη ανακατασκευή,
2037 | # ίδια ειλικρινής ανάγνωση με το Δ7 - ΟΧΙ ισχυρισμός πρόβλεψης)
2038 | n <- length(Y_classical)
2039 | origins <- floor(n * seq(0.60, 0.80, by = 0.05))
2040 | cv_r2 <- vapply(origins, function(cutp) {
2041 |   test <- (cutp + 1):min(cutp + floor(0.05 * n), n)
2042 |   d <- data.frame(Y = Y_classical, X_classical)
2043 |   m <- lm(Y ~ ., data = d[seq_len(cutp), ])
2044 |   ph <- predict(m, newdata = d[test, ])
2045 |   1 - sum((Y_classical[test] - ph)^2) /
2046 |     sum((Y_classical[test] - mean(Y_classical[seq_len(cutp)]))^2)
2047 | }, numeric(1))
2048 | cv_tab <- data.frame(Fold = seq_along(origins),
2049 |   `Τέλος train` = format(as.Date(rownames(df_classical))[origins]),
2050 |   `OOS R²` = round(cv_r2, 3), check.names = FALSE)
2051 | ktab(cv_tab, digits = 3, row.names = FALSE,
2052 |   caption = "Πίνακας Δ11.2 – Expanding-origin CV (5 folds): σύγχρονη ανακατασκευή εκτός δείγματος.")
2053 | ...
2054 |
2055 | ```{r ext-boot-facts, include=FALSE}
2056 | d11_ci_cl <- ci(bb_cl); d11_ci_rad <- ci(bb_rad)
2057 | d11_cv_m <- mean(cv_r2); d11_cv_sd <- sd(cv_r2)
2058 | ...
2059 |
2060 | ##### Σχολιασμός Δ11
2061 |
2062 | * **Bootstrap:** Το 95% διάστημα για το κλασικό R² είναι
2063 |   [**`r round(d11_ci_cl[1], 3)`**, **`r round(d11_ci_cl[2], 3)`**] και για το rad R²
2064 |   [**`r round(d11_ci_rad[1], 3)`**, **`r round(d11_ci_rad[2], 3)`**] – στενά διαστήματα
2065 |   που δείχνουν ότι τα σημειακά R² δεν είναι προϊόν δειγματοληπτικού θορύβου, ακόμη και
2066 |   όταν σεβαστούμε την εξάρτηση της χρονοσειράς (μπλοκ αντί για ανεξάρτητες παρατηρήσεις).
2067 | * **Time-series CV:** Στα 5 διαδοχικά folds το εκτός-δείγματος R² (σύγχρονη ανακατασκευή)
2068 |   είναι **`r round(d11_cv_m, 3)` ± `r round(d11_cv_sd, 3)`** – η σταθερότητα του Δ7 δεν
2069 |   εξαρτάται από ένα συγκεκριμένο σημείο διαχωρισμού.
2070 |
2071 | ## Παράρτημα Αναπαραγωγιμότητας {#repro}
2072 |
2073 | Η μελέτη είναι πλήρως αναπαραγώγιμη: (α) σπόρος τυχαιότητας `set.seed(1125886)` (= AM
2074 | φοιτητή) σε όλα τα στοχαστικά βήματα· (β) τα δεδομένα (Yahoo Finance, 16 tickers OHLC,
2075 | 02/01/2021-30/12/2025) συνοδεύουν το `.Rmd` ως τοπικό στιγμιότυπο CSV στον φάκελο
2076 | `data/`, ώστε το knitr να μην εξαρτάται από το δίκτυο· (γ) οι εξαρτήσεις εγκαθίστανται
2077 | αυτόματα από το setup chunk. Το υπολογιστικό περιβάλλον:
2078 |
2079 | ```{r session-info, size="footnotesize"}
2080 | sessionInfo()
2081 | ...
2082 |
2083 | ---
2084 |
2085 | # Βιβλιογραφία {-}
2086 |
2087 | ::: {#refs}
2088 | :::

```

Παράρτημα Β: Αρχείο βιβλιογραφίας (BibTeX)

Alexandros Tsagkanos – AM: up1125886

Πλήρες περιεχόμενο του αρχείου refs.bib

```
1 | @incollection{billard2000,  
2 |   author   = {Billard, Lynne and Diday, Edwin},  
3 |   title    = {Regression Analysis for Interval-Valued Data},  
4 |   booktitle = {Data Analysis, Classification, and Related Methods},  
5 |   editor   = {Kiers, Henk A. L. and Rasson, Jean-Paul and Groenen, Patrick J. F. and Schader, Martin},  
6 |   publisher = {Springer},  
7 |   address  = {Heidelberg},  
8 |   year     = {2000},  
9 |   pages    = {369--374}  
10 | }  
11 |  
12 | @article{billard2003,  
13 |   author = {Billard, Lynne and Diday, Edwin},  
14 |   title  = {From the Statistics of Data to the Statistics of Knowledge: Symbolic Data Analysis},  
15 |   journal = {Journal of the American Statistical Association},  
16 |   year    = {2003},  
17 |   volume  = {98},  
18 |   number  = {462},  
19 |   pages   = {470--487}  
20 | }  
21 |  
22 | @incollection{bertrand2000,  
23 |   author   = {Bertrand, Patrice and Goupil, Fran{\c c}oise},  
24 |   title    = {Descriptive Statistics for Symbolic Data},  
25 |   booktitle = {Analysis of Symbolic Data},  
26 |   editor   = {Bock, Hans-Hermann and Diday, Edwin},  
27 |   publisher = {Springer},  
28 |   address  = {Berlin},  
29 |   year     = {2000},  
30 |   pages    = {106--124}  
31 | }  
32 |  
33 | @article{limaneto2008,  
34 |   author = {Lima Neto, Eufra{sio de A. and de Carvalho, Francisco de A. T.},  
35 |   title  = {Centre and Range Method for Fitting a Linear Regression Model to Symbolic Interval Data},  
36 |   journal = {Computational Statistics \& Data Analysis},  
37 |   year    = {2008},  
38 |   volume  = {52},  
39 |   number  = {3},  
40 |   pages   = {1500--1515}  
41 | }  
42 |  
43 | @article{limaneto2010,  
44 |   author = {Lima Neto, Eufra{sio de A. and de Carvalho, Francisco de A. T.},  
45 |   title  = {Constrained Linear Regression Models for Symbolic Interval-Valued Variables},  
46 |   journal = {Computational Statistics \& Data Analysis},  
47 |   year    = {2010},  
48 |   volume  = {54},  
49 |   number  = {2},  
50 |   pages   = {333--347}  
51 | }  
52 |  
53 | @article{douzal2007,  
54 |   author = {Douzal-Chouakria, Ahlame and Diday, Edwin},  
55 |   title  = {Principal Component Analysis for Interval-Valued Data},  
56 |   journal = {Computational Statistics},
```

```

57 |   year   = {2007},
58 |   volume = {22},
59 |   number = {4},
60 |   pages  = {607--627}
61 | }
62 |
63 | @article{douzal2011,
64 |   author = {Douzal-Chouakria, Ahlame and Billard, Lynne and Diday, Edwin},
65 |   title  = {Principal Component Analysis for Interval-Valued Observations},
66 |   journal = {Statistical Analysis and Data Mining},
67 |   year   = {2011},
68 |   volume = {4},
69 |   number = {2},
70 |   pages  = {229--246}
71 | }
72 |
73 | @book{kutner2005,
74 |   author = {Kutner, Michael H. and Nachtsheim, Christopher J. and Neter, John and Li, William},
75 |   title  = {Applied Linear Statistical Models},
76 |   edition = {5},
77 |   publisher = {McGraw-Hill},
78 |   address = {New York},
79 |   year    = {2005}
80 | }
81 |
82 | @article{rosseel2012,
83 |   author = {Rosseel, Yves},
84 |   title  = {lavaan: An {R} Package for Structural Equation Modeling},
85 |   journal = {Journal of Statistical Software},
86 |   year   = {2012},
87 |   volume = {48},
88 |   number = {2},
89 |   pages  = {1--36}
90 | }
91 |
92 | @article{cronbach1951,
93 |   author = {Cronbach, Lee J.},
94 |   title  = {Coefficient Alpha and the Internal Structure of Tests},
95 |   journal = {Psychometrika},
96 |   year   = {1951},
97 |   volume = {16},
98 |   number = {3},
99 |   pages  = {297--334}
100 | }
101 |
102 | @article{white1980,
103 |   author = {White, Halbert},
104 |   title  = {A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity},
105 |   journal = {Econometrica},
106 |   year   = {1980},
107 |   volume = {48},
108 |   number = {4},
109 |   pages  = {817--838}
110 | }
111 |
112 | @article{neweywest1987,
113 |   author = {Newey, Whitney K. and West, Kenneth D.},
114 |   title  = {A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix},
115 |   journal = {Econometrica},
116 |   year   = {1987},
117 |   volume = {55},
118 |   number = {3},
119 |   pages  = {703--708}
120 | }
121 |
122 | @article{parkinson1980,
123 |   author = {Parkinson, Michael},
124 |   title  = {The Extreme Value Method for Estimating the Variance of the Rate of Return},
125 |   journal = {Journal of Business},
126 |   year   = {1980},
127 |   volume = {53},
128 |   number = {1},
129 |   pages  = {61--65}
130 | }

```

```

131 |
132 | @article{garmanklass1980,
133 |   author = {Garman, Mark B. and Klass, Michael J.},
134 |   title  = {On the Estimation of Security Price Volatilities from Historical Data},
135 |   journal = {Journal of Business},
136 |   year   = {1980},
137 |   volume = {53},
138 |   number = {1},
139 |   pages  = {67--78}
140 | }
141 |
142 | @article{engle1982,
143 |   author = {Engle, Robert F.},
144 |   title  = {Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation},
145 |   journal = {Econometrica},
146 |   year   = {1982},
147 |   volume = {50},
148 |   number = {4},
149 |   pages  = {987--1007}
150 | }
151 |
152 | @article{bollerslev1986,
153 |   author = {Bollerslev, Tim},
154 |   title  = {Generalized Autoregressive Conditional Heteroskedasticity},
155 |   journal = {Journal of Econometrics},
156 |   year   = {1986},
157 |   volume = {31},
158 |   number = {3},
159 |   pages  = {307--327}
160 | }
161 |
162 | @article{kunsch1989,
163 |   author = {K{\u}nsch, Hans R.},
164 |   title  = {The Jackknife and the Bootstrap for General Stationary Observations},
165 |   journal = {The Annals of Statistics},
166 |   year   = {1989},
167 |   volume = {17},
168 |   number = {3},
169 |   pages  = {1217--1241}
170 | }
171 |
172 | @misc{androulakis2026,
173 |   author = {Ανδρουλάκης, Γεώργιος Σ. and Γράψα, Θεοδούλα Ν.},
174 |   title  = {Βοηθητικό υλικό για το Project 2025-2026: Αριθμητικές Μέθοδοι στην Επιστήμη των Δεδομένων},
175 |   year   = {2026},
176 |   howpublished = {Σημειώσεις μαθήματος, Πανεπιστήμιο Πατρών}
177 | }

```