

Αξιολόγηση Αλγορίθμων Παλινδρόμησης στο Σύνολο Δεδομένων Wine Quality

Ακαδημαϊκή Αναφορά — Ανάλυση Μηχανικής Μάθησης

Πλήρες Pipeline: Διερευνητική Ανάλυση, Προεπεξεργασία,
Μοντελοποίηση, Βελτιστοποίηση, Ερμηνευσιμότητα

Αλέξανδρος Τσαγκανός

1 Μαΐου 2026

Περιεχόμενα

1	Περίληψη	4
2	Εισαγωγή	4
2.1	Γενικό πλαίσιο	4
2.2	Βιβλιογραφική ανασκόπηση	4
2.3	Στόχοι της μελέτης	4
2.4	Δομή της αναφοράς	5
3	Περιγραφή Δεδομένων	5
3.1	Πηγή και χαρακτηριστικά	5
3.2	Μεταβλητές εισόδου (χαρακτηριστικά)	5
3.3	Μεταβλητή-στόχος	5
4	Διερευνητική Ανάλυση Δεδομένων (EDA)	6
4.1	Περιγραφικά στατιστικά	6
4.2	Ανάλυση συσχετίσεων	7
4.3	Κατανομές και θηκογράμματα	8
4.4	Ανάλυση ακραίων τιμών (IQR)	11
5	Προεπεξεργασία Δεδομένων	11
5.1	Διαχωρισμός εκπαίδευσης/ελέγχου	11
5.2	Κανονικοποίηση (StandardScaler)	12
5.3	Σχεδιασμός Pipeline και αποφυγή διαρροής	12
6	Μοντελοποίηση Βάσης (Baseline)	12
6.1	Περιγραφή αλγορίθμων	12
6.1.1	Γραμμική Παλινδρόμηση (Linear Regression)	12
6.1.2	Ridge, Lasso & ElasticNet	12
6.1.3	Τυχαίο Δάσος (Random Forest)	13
6.1.4	Ενίσχυση Κλίσης (Gradient Boosting)	13
6.1.5	Μηχανές Διανυσμάτων Υποστήριξης για Παλινδρόμηση (SVR)	13
6.1.6	K-Πλησιέστεροι Γείτονες (KNN)	14
6.2	Αποτελέσματα βάσης	14
6.3	Μετρικές αξιολόγησης	14
7	Διασταυρωμένη Επικύρωση (Cross-Validation)	15
7.1	Μεθοδολογία	15
7.2	Αποτελέσματα CV	15
7.3	Ανάλυση	15
8	Επιλογή Χαρακτηριστικών	16
8.1	Μέθοδοι φίλτρου	16
8.1.1	Συσχέτιση Pearson	16

8.1.2	Αμοιβαία Πληροφορία (Mutual Information)	16
8.2	Μέθοδος περιτυλίγματος (RFE)	16
8.3	Ενσωματωμένη μέθοδος (Lasso)	17
8.4	Συγκριτική αξιολόγηση	17
9	Βελτιστοποίηση Υπερπαραμέτρων	17
9.1	Μεθοδολογία	17
9.2	Αποτελέσματα βελτιστοποίησης	17
9.2.1	Random Forest	17
9.2.2	Gradient Boosting	17
9.3	Ανάλυση βελτίωσης	18
10	Ανάλυση Καταλοίπων	19
10.1	Κατάλοιπα ως προς τις προβλέψεις	19
10.2	Πραγματικές ως προς τις προβλεπόμενες τιμές	20
10.3	Κατανομή καταλοίπων	20
10.4	Γράφημα Q-Q	21
11	Ερμηνευσιμότητα Μοντέλων (SHAP)	21
11.1	Θεωρητικό υπόβαθρο	21
11.2	Σημαντικότητα χαρακτηριστικών (SHAP)	22
11.3	Γραφήματα SHAP	22
11.4	Σημαντικότητα μετάθεσης (Permutation Importance)	24
12	Συγκριτική Αξιολόγηση	25
12.1	Σύγκριση Baseline ως προς βελτιστοποιημένα	25
12.2	Γράφημα ραντάρ	25
12.3	Ισορροπία ακρίβειας–ερμηνευσιμότητας	26
13	Συμπεράσματα	26
13.1	Σύνοψη αποτελεσμάτων	26
13.2	Τελική σύσταση μοντέλου	27
13.3	Περιορισμοί	27
13.4	Μελλοντική εργασία	27
14	Βιβλιογραφία	27

Κατάλογος σχημάτων

1	Θερμικός χάρτης συσχετίσεων Pearson μεταξύ όλων των μεταβλητών.	7
2	Θηκογράμματα (boxplots) για όλα τα χαρακτηριστικά.	8
3	Κατανομή μεταβλητής-στόχου (ποιότητα κρασιού).	9
4	Γράφημα ζευγών (pairplot) για το σύνολο δεδομένων.	10
5	Πλήθος ακραίων τιμών (IQR) ανά μεταβλητή.	11
6	Κατάλοιπα ως προς τις προβλεπόμενες τιμές — Random Forest.	19
7	Πραγματικές ως προς τις προβλεπόμενες τιμές — Random Forest.	20
8	Κατανομή καταλοίπων — Random Forest.	20
9	Γράφημα Q-Q καταλοίπων — Random Forest.	21
10	Γράφημα σύννοησης SHAP (beeswarm plot) — Random Forest.	22
11	Γράφημα σημαντικότητας SHAP (μπάρες).	23
12	Γραφήματα εξάρτησης SHAP για τα 3 κορυφαία χαρακτηριστικά.	23
13	Σημαντικότητα μετάθεσης — Τελικό μοντέλο Random Forest.	24
14	Γράφημα ραντάρ — Κανονικοποιημένη σύγκριση μοντέλων βάσης.	25
15	Σύγκριση RMSE μοντέλων βάσης.	26

Κατάλογος πινάκων

1	Κατανομή μεταβλητής-στόχου (quality)	6
2	Περιγραφικά στατιστικά χαρακτηριστικών	6
3	Ακραίες τιμές ανά χαρακτηριστικό (μέθοδος IQR)	11
4	Διαχωρισμός δεδομένων	12
5	Μετρικές αλγορίθμων βάσης στο σύνολο ελέγχου	14
6	Αποτελέσματα 10-fold διασταυρωμένης επικύρωσης (μέσος $\pm$ τ.α.)	15
7	Κατάταξη χαρακτηριστικών — Απόλυτη συσχέτιση Pearson με quality	16
8	Κατάταξη χαρακτηριστικών — Αμοιβαία Πληροφορία	16
9	Βέλτιστα αποτελέσματα ανά μέθοδο επιλογής χαρακτηριστικών	17
10	Μετρικές βελτιστοποιημένων μοντέλων	18
11	Μέση απόλυτη τιμή SHAP ανά χαρακτηριστικό	22
12	Σημαντικότητα μετάθεσης — Τελικό μοντέλο Random Forest	24
13	Πλήρης σύγκριση μοντέλων — Baseline (B) & Βελτιστοποιημένα (T)	25
14	Ισορροπία ακρίβειας και ερμηνευσιμότητας	26

1 Περίληψη

Η παρούσα αναφορά παρουσιάζει μια ολοκληρωμένη και μεθοδολογικά αυστηρή ανάλυση παλινδρόμησης στο σύνολο δεδομένων Wine Quality (Red) του αποθετηρίου UCI Machine Learning Repository. Στόχος είναι η πρόβλεψη της ποιότητας κόκκινου κρασιού (κλίμακα 3–8) βάσει 11 φυσικοχημικών χαρακτηριστικών, αντιμετωπίζοντας το πρόβλημα ως εργασία παλινδρόμησης.

Υλοποιήθηκε πλήρες pipeline μηχανικής μάθησης δέκα φάσεων: (1) διερευνητική ανάλυση δεδομένων, (2) προεπεξεργασία με αποφυγή διαρροής δεδομένων, (3) εκπαίδευση έξι αλγορίθμων βάσης (Linear Regression, Random Forest, Gradient Boosting, SVR, ElasticNet, KNN), (4) 10-fold διασταυρωμένη επικύρωση, (5) επιλογή χαρακτηριστικών με μεθόδους φίλτρου, περιτυλίγματος και ενσωματωμένες, (6) βελτιστοποίηση υπερπαραμέτρων μέσω RandomizedSearchCV, (7) ανάλυση καταλοίπων, (8) ερμηνεία μοντέλων μέσω τιμών SHAP, (9) συγκριτική αξιολόγηση, και (10) τεκμηρίωση.

Τα αποτελέσματα έδειξαν ότι ο αλγόριθμος Random Forest επιτυγχάνει τη βέλτιστη απόδοση μετά τη βελτιστοποίηση, με $RMSE = 0,5406$, $MAE = 0,4140$ και $R^2 = 0,5528$ στο σύνολο ελέγχου. Η ανάλυση SHAP αποκάλυψε ότι τα τρία πλέον σημαντικά χαρακτηριστικά είναι η περιεκτικότητα σε αλκοόλ (alcohol), τα θειικά (sulphates) και η πτητική οξύτητα (volatile acidity). Η μελέτη αναδεικνύει τη σημασία αυστηρής μεθοδολογίας pipeline για αξιόπιστα και αναπαραγώγιμα αποτελέσματα.

2 Εισαγωγή

2.1 Γενικό πλαίσιο

Η πρόβλεψη ποιότητας κρασιού αποτελεί κλασικό πρόβλημα στον τομέα της εφαρμοσμένης μηχανικής μάθησης, καθώς συνδυάζει φυσικοχημικές μετρήσεις με υποκειμενική αισθητηριακή αξιολόγηση. Η αυτοματοποίηση της αξιολόγησης μέσω αλγορίθμων παλινδρόμησης προσφέρει σημαντικά πλεονεκτήματα: μείωση κόστους, αντικειμενικότητα, αναπαραγωγικότητα και δυνατότητα κλιμάκωσης.

2.2 Βιβλιογραφική ανασκόπηση

Οι Cortez et al. (2009) εισήγαγαν το σύνολο δεδομένων Wine Quality στο UCI Repository, εφαρμόζοντας τεχνικές SVM και νευρωνικών δικτύων. Έκτοτε, πλήθος ερευνητών έχουν εφαρμόσει μεθόδους ensemble (Random Forest, Gradient Boosting, XGBoost), κανονικοποίηση (Ridge, Lasso, ElasticNet) και τεχνικές βαθιάς μάθησης. Η επιλογή χαρακτηριστικών και η ερμηνευσιμότητα μοντέλων μέσω SHAP έχουν αναδειχθεί ως κρίσιμοι τομείς στη σύγχρονη βιβλιογραφία.

2.3 Στόχοι της μελέτης

Η παρούσα εργασία αποσκοπεί στα εξής:

1. Συστηματική σύγκριση έξι αλγορίθμων παλινδρόμησης για πρόβλεψη ποιότητας κρασιού.
2. Αξιολόγηση τεχνικών επιλογής χαρακτηριστικών (φίλτρα, περιτύλιγμα, ενσωματωμένες).
3. Βελτιστοποίηση υπερπαραμέτρων και ανάλυση καταλοίπων.

4. Ερμηνεία μοντέλων μέσω τιμών SHAP (Shapley Additive Explanations).
5. Τεκμηρίωση πλήρους αναπαραγωγίμου pipeline.

2.4 Δομή της αναφοράς

Η αναφορά οργανώνεται ως εξής: η Ενότητα 3 περιγράφει το σύνολο δεδομένων, η Ενότητα 4 παρουσιάζει τη διερευνητική ανάλυση, η Ενότητα 5 αναλύει την προεπεξεργασία, οι Ενότητες 6–9 αφορούν τη μοντελοποίηση και αξιολόγηση, η Ενότητα 10 την ανάλυση καταλοίπων, η Ενότητα 11 τις SHAP τιμές, η Ενότητα 12 τη συγκριτική αξιολόγηση, και η Ενότητα 13 τα συμπεράσματα.

3 Περιγραφή Δεδομένων

3.1 Πηγή και χαρακτηριστικά

Το σύνολο δεδομένων Wine Quality – Red Wine προέρχεται από το UCI Machine Learning Repository (ID: 186) και δημιουργήθηκε από τους Cortez et al. (2009). Περιέχει 1.599 δείγματα κόκκινου κρασιού Vinho Verde από τη βόρεια Πορτογαλία.

3.2 Μεταβλητές εισόδου (χαρακτηριστικά)

Τα 11 φυσικοχημικά χαρακτηριστικά είναι:

1. Fixed acidity (σταθερή οξύτητα) — $\text{g(τρυνγικό οξύ)}/\text{dm}^3$
2. Volatile acidity (πτητική οξύτητα) — $\text{g(οξικό οξύ)}/\text{dm}^3$
3. Citric acid (κιτρικό οξύ) — g/dm^3
4. Residual sugar (υπολειπόμενο σάκχαρο) — g/dm^3
5. Chlorides (χλωριούχα) — $\text{g(χλωριούχο νάτριο)}/\text{dm}^3$
6. Free sulfur dioxide (ελεύθερο διοξείδιο του θείου) — mg/dm^3
7. Total sulfur dioxide (ολικό διοξείδιο του θείου) — mg/dm^3
8. Density (πυκνότητα) — g/cm^3
9. pH
10. Sulphates (θειικά) — $\text{g(θειικό κάλιο)}/\text{dm}^3$
11. Alcohol (αλκοόλ) — % vol.

3.3 Μεταβλητή-στόχος

Η μεταβλητή-στόχος quality είναι αισθητηριακή βαθμολογία (διάμεσος τουλάχιστον 3 αξιολογητών) στην κλίμακα 0–10. Στο παρόν σύνολο, οι τιμές κυμαίνονται μεταξύ 3 και 8.

Πίνακας 1: Κατανομή μεταβλητής-στόχου (quality)

Ποιότητα	Πλήθος
3	10
4	53
5	681
6	638
7	199
8	18
Σύνολο	1.599

Η κατανομή είναι έντονα ασύμμετρη, με πλειοψηφία δειγμάτων συγκεντρωμένη στις τιμές 5 και 6 (82,5%), γεγονός που αποτελεί πρόκληση για τους αλγορίθμους παλινδρόμησης. Δεν εντοπίστηκαν ελλιπείς τιμές.

4 Διερευνητική Ανάλυση Δεδομένων (EDA)

4.1 Περιγραφικά στατιστικά

Ο Πίνακας 2 παρουσιάζει τα βασικά περιγραφικά στατιστικά.

Πίνακας 2: Περιγραφικά στατιστικά χαρακτηριστικών


Χαρακτηριστικό	M.O.	T.A.	Ελάχ.	Διάμεσος	Μέγ.	Ασυμμετρία	Κύρτωση
fixed acidity	8,320	1,741	4,60	7,90	15,90	0,983	1,132
volatile acidity	0,528	0,179	0,12	0,52	1,58	0,672	1,226
citric acid	0,271	0,195	0,00	0,26	1,00	0,318	-0,789
residual sugar	2,539	1,410	0,90	2,20	15,50	4,541	28,618
chlorides	0,087	0,047	0,01	0,08	0,61	5,680	41,716
free sulfur dioxide	15,87	10,46	1,00	14,00	72,00	1,251	2,024
total sulfur dioxide	46,47	32,90	6,00	38,00	289,0	1,516	3,810
density	0,997	0,002	0,990	0,997	1,004	0,071	0,934
pH	3,311	0,154	2,74	3,31	4,01	0,194	0,807
sulphates	0,658	0,170	0,33	0,62	2,00	2,429	11,720
alcohol	10,42	1,066	8,40	10,20	14,90	0,861	0,200
quality	5,636	0,808	3,00	6,00	8,00	0,218	0,297

Κρίσιμες παρατηρήσεις:

- Οι μεταβλητές residual sugar ($\gamma_1 = 4,54$), chlorides ($\gamma_1 = 5,68$) και sulphates ($\gamma_1 = 2,43$) εμφανίζουν ισχυρή θετική ασυμμετρία.
- Οι τιμές κύρτωσης για chlorides ($\kappa = 41,72$) και residual sugar ($\kappa = 28,62$) υποδεικνύουν βαριές ουρές (leptokurtic).
- Η citric acid παρουσιάζει αρνητική κύρτωση ($\kappa = -0,79$), υποδεικνύοντας πλατύκυρτη κατανομή.

- Δεν εντοπίστηκαν ελλείψεις τιμές σε καμία μεταβλητή.

4.2 Ανάλυση συσχετίσεων




Σχήμα 1: Θερμικός χάρτης συσχετίσεων Pearson μεταξύ όλων των μεταβλητών.

Ο θερμικός χάρτης (Σχήμα 1) αποκαλύπτει τα ακόλουθα ευρήματα:


- **Ισχυρότερη θετική συσχέτιση με quality:** alcohol ($r = 0,476$). Αυτό υποδεικνύει ότι υψηλότερη περιεκτικότητα σε αλκοόλ σχετίζεται με υψηλότερη αξιολόγηση ποιότητας.
- **Ισχυρότερη αρνητική συσχέτιση:** volatile acidity ($r = -0,391$). Η αυξημένη πτητική οξύτητα (οξικό οξύ) υποβαθμίζει την ποιότητα.
- **Ενδιαφέρουσες ζεύξεις μεταξύ χαρακτηριστικών:** fixed acidity–citric acid ($r = 0,672$), fixed acidity–density ($r = 0,668$), fixed acidity–pH ($r = -0,683$), free SO₂–total SO₂ ($r = 0,668$).
- Η πολυσυγγραμμικότητα μεταξύ ορισμένων χαρακτηριστικών (π.χ. fixed acidity και pH) δικαιολογεί τη χρήση τεχνικών κανονικοποίησης.

4.3 Κατανομές και θηκογράμματα




Σχήμα 2: Θηκογράμματα (boxplots) για όλα τα χαρακτηριστικά.

Τα θηκογράμματα (Σχήμα 2) αναδεικνύουν σημαντικό αριθμό ακραίων τιμών στις μεταβλητές residual sugar, chlorides και total sulfur dioxide.



Σχήμα 3: Κατανομή μεταβλητής-στόχου (ποιότητα κρασιού).

Η κατανομή του στόχου (Σχήμα 3) επιβεβαιώνει τη συγκέντρωση στις μεσαίες τιμές (5 και 6), καθιστώντας δυσχερή την πρόβλεψη ακραίων τιμών ποιότητας.




Σχήμα 4: Γράφημα ζευγών (pairplot) για το σύνολο δεδομένων.

Το γράφημα ζευγών (Σχήμα 4) παρέχει εποπτεία των διμεταβλητών σχέσεων, αναδεικνύοντας μη γραμμικά πρότυπα σε ορισμένα ζεύγη.

4.4 Ανάλυση ακραίων τιμών (IQR)

Πίνακας 3: Ακραίες τιμές ανά χαρακτηριστικό (μέθοδος IQR)

Χαρακτηριστικό	Q1	Q3	IQR	Κάτω όριο	Άνω όριο	Πλήθος (%)
residual sugar	1,90	2,60	0,70	0,85	3,65	155 (9,7%)
chlorides	0,07	0,09	0,02	0,04	0,12	112 (7,0%)
sulphates	0,55	0,73	0,18	0,28	1,00	59 (3,7%)
total sulfur dioxide	22,0	62,0	40,0	−38	122	55 (3,4%)
fixed acidity	7,10	9,20	2,10	3,95	12,35	49 (3,1%)
density	0,996	0,998	0,002	0,992	1,001	45 (2,8%)
pH	3,21	3,40	0,19	2,93	3,69	35 (2,2%)
free sulfur dioxide	7,00	21,0	14,0	−14	42,0	30 (1,9%)
volatile acidity	0,39	0,64	0,25	0,02	1,02	19 (1,2%)
alcohol	9,50	11,10	1,60	7,10	13,50	13 (0,8%)
citric acid	0,09	0,42	0,33	−0,41	0,92	1 (0,1%)



Σχήμα 5: Πλήθος ακραίων τιμών (IQR) ανά μεταβλητή.

Οι ακραίες τιμές δεν αφαιρέθηκαν, καθώς αντιπροσωπεύουν νόμιμες φυσικοχημικές μετρήσεις. Η απόφαση βασίζεται στη μεθοδολογική αρχή ότι η αφαίρεσή τους θα αλλοίωνε τη φυσική κατανομή του δείγματος. Αντ' αυτού, χρησιμοποιήθηκαν ανθεκτικοί αλγόριθμοι (Random Forest, Gradient Boosting).

5 Προεπεξεργασία Δεδομένων

5.1 Διαχωρισμός εκπαίδευσης/ελέγχου

Τα δεδομένα διαχωρίστηκαν σε σύνολο εκπαίδευσης (80%) και ελέγχου (20%) με στρωματοποιημένη τυχαιοποίηση (random_state= 42):

Πίνακας 4: Διαχωρισμός δεδομένων

Σύνολο	Εγγραφές	Ποσοστό (%)
Πλήρες	1.599	100,0
Εκπαίδευση	1.279	80,0
Έλεγχος	320	20,0

5.2 Κανονικοποίηση (StandardScaler)

Για τους αλγορίθμους ευαίσθητους στην κλίμακα (Linear Regression, SVR, ElasticNet, KNN), εφαρμόστηκε κανονικοποίηση StandardScaler μέσα σε scikit-learn Pipeline, ώστε να αποφευχθεί διαρροή δεδομένων (data leakage):

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

όπου μ ο μέσος και σ η τυπική απόκλιση, υπολογισμένα αποκλειστικά από το σύνολο εκπαίδευσης.

5.3 Σχεδιασμός Pipeline και αποφυγή διαρροής

Η χρήση sklearn.pipeline.Pipeline εξασφαλίζει ότι:

1. Ο StandardScaler εκπαιδεύεται μόνο στα δεδομένα εκπαίδευσης (fit_transform).
2. Στα δεδομένα ελέγχου εφαρμόζεται μόνο μετασχηματισμός (transform).
3. Κατά τη διασταυρωμένη επικύρωση, η κανονικοποίηση επαναλαμβάνεται σε κάθε fold.

Τα δενδρικά μοντέλα (Random Forest, Gradient Boosting) δεν χρειάζονται κανονικοποίηση λόγω αναλλοίωτων διαχωρισμών, αλλά ενσωματώθηκαν σε Pipeline για μεθοδολογική συνέπεια.

6 Μοντελοποίηση Βάσης (Baseline)

6.1 Περιγραφή αλγορίθμων

6.1.1 Γραμμική Παλινδρόμηση (Linear Regression)

Η γραμμική παλινδρόμηση ελαχιστοποιεί το άθροισμα τετραγώνων σφαλμάτων:

$$\hat{y} = X\beta, \quad \beta = (X^T X)^{-1} X^T \mathbf{y} \quad (2)$$

Η μέθοδος ελαχίστων τετραγώνων (OLS) προϋποθέτει γραμμικότητα, ανεξαρτησία σφαλμάτων, ομοσκεδαστικότητα και κανονικότητα καταλοίπων.

6.1.2 Ridge, Lasso & ElasticNet

Οι κανονικοποιημένες μέθοδοι προσθέτουν ποινή στη συνάρτηση κόστους:

Ridge (L2):

$$\mathcal{L}_{\text{Ridge}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad (3)$$

Lasso (L1):

$$\mathcal{L}_{\text{Lasso}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (4)$$

ElasticNet — συνδυασμός L1 και L2:

$$\mathcal{L}_{\text{ElasticNet}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2 \quad (5)$$

6.1.3 Τυχαίο Δάσος (Random Forest)

Ο αλγόριθμος Random Forest βασίζεται στο bagging (Bootstrap Aggregating):

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (6)$$

όπου T_b το b -οστό δέντρο απόφασης εκπαιδευμένο σε τυχαίο δείγμα bootstrap. Η τυχαία επιλογή υποσυνόλου χαρακτηριστικών σε κάθε διαχωρισμό μειώνει τη συσχέτιση μεταξύ δέντρων.

6.1.4 Ενίσχυση Κλίσης (Gradient Boosting)

Η μέθοδος Gradient Boosting κατασκευάζει διαδοχικά μοντέλα:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (7)$$

όπου h_m εκπαιδεύεται στα αρνητικά κατάλοιπα (pseudo-residuals):

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (8)$$

και η ο ρυθμός μάθησης (learning rate).

6.1.5 Μηχανές Διανυσμάτων Υποστήριξης για Παλινδρόμηση (SVR)

Η SVR χρησιμοποιεί ε -ανεκτική συνάρτηση απώλειας:

$$L_\varepsilon(y, f(x)) = \max(0, |y - f(x)| - \varepsilon) \quad (9)$$

Σφάλματα εντός του σωλήνα ε αγνοούνται. Η πρωτεύουσα συνάρτηση βελτιστοποίησης:

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad \text{υπό} \quad |y_i - (w^T x_i + b)| \leq \varepsilon + \xi_i + \xi_i^* \quad (10)$$

6.1.6 Κ-Πλησιέστεροι Γείτονες (KNN)

Η πρόβλεψη βασίζεται στον μέσο όρο των K πλησιέστερων γειτόνων:

$$\hat{y}(x) = \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} y_i \quad (11)$$

6.2 Αποτελέσματα βάσης

Πίνακας 5: Μετρικές αλγορίθμων βάσης στο σύνολο ελέγχου

Μοντέλο	MAE	MSE	RMSE	R^2
Random Forest	0,4224	0,3012	0,5489	0,5390
SVR	0,4535	0,3514	0,5928	0,4623
Gradient Boosting	0,4849	0,3623	0,6019	0,4456
Linear Regression	0,5035	0,3900	0,6245	0,4032
KNN	0,5056	0,4349	0,6595	0,3346
ElasticNet	0,6853	0,6572	0,8107	-0,0056

6.3 Μετρικές αξιολόγησης

Ορίζονται οι ακόλουθες μετρικές:

Μέσο Απόλυτο Σφάλμα (MAE):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (12)$$

Μέσο Τετραγωνικό Σφάλμα (MSE):

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (13)$$

Ρίζα Μέσου Τετραγωνικού Σφάλματος (RMSE):

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

Συντελεστής Προσδιορισμού (R^2):

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (15)$$

Ο Random Forest κυριαρχεί σε όλες τις μετρικές, ακολουθούμενος από τον SVR. Ο ElasticNet εμφανίζει αρνητικό R^2 , υποδεικνύοντας ότι η προεπιλεγμένη παραμετροποίηση υπολείπεται ακόμα και του τετριμμένου μέσου.

7 Διασταυρωμένη Επικύρωση (Cross-Validation)

7.1 Μεθοδολογία

Εφαρμόστηκε 10-fold διασταυρωμένη επικύρωση (10-fold CV) με ανακάτεμα (`shuffle=True`, `random_state=42`) στο σύνολο εκπαίδευσης. Σε κάθε fold, ο μετασχηματισμός κανονικοποίησης εφαρμόζεται ξεχωριστά μέσω του Pipeline.

7.2 Αποτελέσματα CV

Πίνακας 6: Αποτελέσματα 10-fold διασταυρωμένης επικύρωσης (μέσος $\pm$ τ.α.)

Μοντέλο	CV MAE	CV RMSE	R^2 (CV)
Random Forest	$0,424 \pm 0,036$	$0,598 \pm 0,044$	$0,446 \pm 0,063$
Gradient Boosting	$0,477 \pm 0,040$	$0,627 \pm 0,047$	$0,391 \pm 0,065$
SVR	$0,464 \pm 0,038$	$0,637 \pm 0,047$	$0,370 \pm 0,071$
Linear Regression	$0,505 \pm 0,030$	$0,660 \pm 0,032$	$0,324 \pm 0,054$
KNN	$0,519 \pm 0,049$	$0,694 \pm 0,057$	$0,250 \pm 0,110$
ElasticNet	$0,684 \pm 0,021$	$0,806 \pm 0,035$	$-0,006 \pm 0,008$

7.3 Ανάλυση

Τα αποτελέσματα CV επιβεβαιώνουν τη σειρά κατάταξης του baseline. Ωστόσο, η διαφορά RMSE μεταξύ test και CV για τον Random Forest ($0,549$ έναντι $0,598$) υποδεικνύει ελαφρά υπερπροσαρμογή. Ο KNN εμφανίζει τη μεγαλύτερη διακύμανση ($\sigma_{R^2} = 0,110$), ενώ η Linear Regression είναι η πλέον σταθερή ($\sigma_{R^2} = 0,054$).

8 Επιλογή Χαρακτηριστικών

8.1 Μέθοδοι φίλτρου

8.1.1 Συσχέτιση Pearson

Πίνακας 7: Κατάταξη χαρακτηριστικών — Απόλυτη συσχέτιση Pearson με quality

Χαρακτηριστικό	$ r $
alcohol	0,473
volatile acidity	0,378
sulphates	0,243
citric acid	0,216
total sulfur dioxide	0,200
density	0,167
chlorides	0,127
fixed acidity	0,122
free sulfur dioxide	0,056
pH	0,045
residual sugar	0,005

8.1.2 Αμοιβαία Πληροφορία (Mutual Information)

Πίνακας 8: Κατάταξη χαρακτηριστικών — Αμοιβαία Πληροφορία

Χαρακτηριστικό	MI
alcohol	0,169
volatile acidity	0,104
sulphates	0,088
citric acid	0,080
density	0,067
chlorides	0,051
total sulfur dioxide	0,047
fixed acidity	0,039
free sulfur dioxide	0,022
pH	0,018
residual sugar	0,013

Και οι δύο μέθοδοι φίλτρου επιβεβαιώνουν τα alcohol, volatile acidity και sulphates ως τα τρία πιο σημαντικά χαρακτηριστικά. Η αμοιβαία πληροφορία, η οποία ανιχνεύει και μη γραμμικές σχέσεις, κατατάσσει τη density υψηλότερα από ό,τι η Pearson.

8.2 Μέθοδος περιτυλίγματος (RFE)

Χρησιμοποιήθηκε Recursive Feature Elimination (RFE) με εκτιμητή βάσης Linear Regression. Τα αποτελέσματα δείχνουν ότι η χρήση 6 χαρακτηριστικών (volatile acidity, chlorides, total sulfur dioxide, pH, sulphates, alcohol) επιτυγχάνει $R^2 = 0,403$, σχεδόν ισοδύναμο με την πλήρη σουίτα.

8.3 Ενσωματωμένη μέθοδος (Lasso)

Η ρύθμιση Lasso ($\alpha = 0,001$) διατηρεί και τα 11 χαρακτηριστικά, ενώ σε $\alpha = 0,1$ μένουν μόνο 3 (volatile acidity, sulphates, alcohol).

8.4 Συγκριτική αξιολόγηση

Πίνακας 9: Βέλτιστα αποτελέσματα ανά μέθοδο επιλογής χαρακτηριστικών

Μέθοδος	Ρύθμιση	n	RMSE	R^2
Mutual Information	top_11	11	0,6245	0,4032
RFE	top_11	11	0,6245	0,4032
Lasso Embedded	$\alpha = 0,001$	11	0,6245	0,4032
Pearson	top_11	11	0,6245	0,4032

Συμπέρασμα: Όλα τα χαρακτηριστικά συνεισφέρουν (έστω και οριακά) στη γραμμική μοντελοποίηση. Η μείωση διαστάσεων δεν βελτιώνει τη γραμμική παλινδρόμηση, αλλά η πληροφορία αξιοποιείται αποτελεσματικότερα από μη γραμμικά μοντέλα.

9 Βελτιστοποίηση Υπερπαραμέτρων

9.1 Μεθοδολογία

Βελτιστοποιήθηκαν οι δύο κορυφαίοι αλγόριθμοι (Random Forest, Gradient Boosting) μέσω RandomizedSearchCV (15 επαναλήψεις, 10-fold CV, μετρική βελτιστοποίησης: $-RMSE$).

9.2 Αποτελέσματα βελτιστοποίησης

9.2.1 Random Forest

Βέλτιστοι υπερπαραμέτροι:

- `n_estimators= 200`
- `max_depth= 30`
- `min_samples_split= 2`
- `min_samples_leaf= 1`
- `max_features=log2`

9.2.2 Gradient Boosting

Βέλτιστοι υπερπαραμέτροι:

- `n_estimators= 300`
- `learning_rate= 0,05`

- `max_depth= 5`
- `subsample= 0,85`
- `min_samples_split= 10`
- `min_samples_leaf= 4`

Πίνακας 10: Μετρικές βελτιστοποιημένων μοντέλων

Μοντέλο	CV RMSE	Test MAE	Test RMSE	R^2
Random Forest	0,5883	0,4140	0,5406	0,5528
Gradient Boosting	0,6073	0,4385	0,5745	0,4949

9.3 Ανάλυση βελτίωσης

Η βελτιστοποίηση βελτίωσε τον Random Forest:

- RMSE: $0,5489 \rightarrow 0,5406$ (βελτίωση $-1,5\%$)
- R^2 : $0,5390 \rightarrow 0,5528$ (βελτίωση $+2,6\%$)


Ο Gradient Boosting βελτιώθηκε σημαντικότερα:

- RMSE: $0,6019 \rightarrow 0,5745$ (βελτίωση $-4,6\%$)
- R^2 : $0,4456 \rightarrow 0,4949$ (βελτίωση $+11,1\%$)

Ο βελτιστοποιημένος Random Forest επιλέχθηκε ως τελικό μοντέλο.

10 Ανάλυση Καταλοίπων


10.1 Κατάλοιπα ως προς τις προβλέψεις



Σχήμα 6: Κατάλοιπα ως προς τις προβλεπόμενες τιμές — Random Forest.

Το Σχήμα 6 δείχνει ότι τα κατάλοιπα δεν εμφανίζουν σαφές μοτίβο γύρω από το μηδέν, αν και παρατηρείται μεγαλύτερη διασπορά στις ακραίες τιμές ποιότητας (3–4 και 7–8). Αυτό αντανακλά τη δυσκολία πρόβλεψης για σπάνιες κατηγορίες.


10.2 Πραγματικές ως προς τις προβλεπόμενες τιμές



Σχήμα 7: Πραγματικές ως προς τις προβλεπόμενες τιμές — Random Forest.

Το Σχήμα 7 δείχνει τη συγκέντρωση προβλέψεων στο εύρος 5–6,5, με συστηματική υπερεκτίμηση χαμηλών ποιοτήτων και υποεκτίμηση υψηλών. Αυτό αποτελεί χαρακτηριστική συμπεριφορά ensemble μοντέλων σε ασύμμετρες κατανομές.


10.3 Κατανομή καταλοίπων



Σχήμα 8: Κατανομή καταλοίπων — Random Forest.

Η κατανομή (Σχήμα 8) είναι περίπου συμμετρική αλλά με βαρύτερες ουρές από την κανονική, κάτι αναμενόμενο για διακριτούς ακέραιους στόχους.

10.4 Γράφημα Q-Q



Σχήμα 9: Γράφημα Q-Q καταλοίπων — Random Forest.

Το γράφημα Q-Q (Σχήμα 9) επιβεβαιώνει ελαφρές αποκλίσεις από την κανονικότητα στις ουρές, οι οποίες είναι αποδεκτές για μη παραμετρικά μοντέλα.

11 Ερμηνευσιμότητα Μοντέλων (SHAP)

11.1 Θεωρητικό υπόβαθρο

Η μέθοδος SHAP (SHapley Additive exPlanations) βασίζεται στις τιμές Shapley από τη θεωρία παιγνίων. Για κάθε χαρακτηριστικό i και πρόβλεψη, η τιμή Shapley ορίζεται:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)] \quad (16)$$

όπου N το σύνολο χαρακτηριστικών, S υποσύνολο χωρίς i , και $f(S)$ η πρόβλεψη με χαρακτηριστικά S . Η τιμή Shapley εκφράζει τη μέση οριακή συνεισφορά του χαρακτηριστικού σε όλους τους δυνατούς συνδυασμούς.


Ιδιότητες: Τοπική ακρίβεια ($f(x) = \phi_0 + \sum_i \phi_i$), συμμετρία, μηδενιστικότητα, προσθετικότητα.

11.2 Σημαντικότητα χαρακτηριστικών (SHAP)

Πίνακας 11: Μέση απόλυτη τιμή SHAP ανά χαρακτηριστικό

Χαρακτηριστικό	M.O. $ \phi_i $
alcohol	0,2080
sulphates	0,1858
volatile acidity	0,1071
density	0,0583
total sulfur dioxide	0,0530
citric acid	0,0338
chlorides	0,0287
pH	0,0230
fixed acidity	0,0219
free sulfur dioxide	0,0187
residual sugar	0,0147


11.3 Γραφήματα SHAP




Σχήμα 10: Γράφημα σύνοψης SHAP (beeswarm plot) — Random Forest.

Το γράφημα σύνοψης (Σχήμα 10) αποκαλύπτει:

- alcohol: Υψηλές τιμές (κόκκινο) ωθούν θετικά τη SHAP, δηλαδή αυξάνουν την πρόβλεψη ποιότητας.
- volatile acidity: Υψηλές τιμές ωθούν αρνητικά, μειώνοντας την ποιότητα.
- sulphates: Θετική σχέση — υψηλότερα θειικά, υψηλότερη ποιότητα.



Σχήμα 11: Γράφημα σημαντικότητας SHAP (μπάρες).



Σχήμα 12: Γραφήματα εξάρτησης SHAP για τα 3 κορυφαία χαρακτηριστικά.


Τα γραφήματα εξάρτησης (Σχήμα 12) αποκαλύπτουν μη γραμμικές σχέσεις:

- Η θετική επίδραση του alcohol ενισχύεται μετά τα 11% vol.
- Η αρνητική επίδραση της volatile acidity γίνεται εντονότερη πάνω από 0,6 g/dm³.
- Τα sulphates εμφανίζουν θετική επίδραση κυρίως μεταξύ 0,6–1,0 g/dm³.

11.4 Σημαντικότητα μετάθεσης (Permutation Importance)

Πίνακας 12: Σημαντικότητα μετάθεσης — Τελικό μοντέλο Random Forest

Χαρακτηριστικό	M.O.	T.A.
alcohol	0,1463	0,0133
sulphates	0,1159	0,0105
volatile acidity	0,0707	0,0062
total sulfur dioxide	0,0347	0,0057
density	0,0287	0,0036
citric acid	0,0247	0,0033
fixed acidity	0,0169	0,0022
chlorides	0,0155	0,0028
pH	0,0148	0,0026
free sulfur dioxide	0,0139	0,0030
residual sugar	0,0112	0,0022



Σχήμα 13: Σημαντικότητα μετάθεσης — Τελικό μοντέλο Random Forest.

Η σημαντικότητα μετάθεσης επιβεβαιώνει πλήρως τη σειρά κατάταξης SHAP, ενισχύοντας την αξιοπιστία των συμπερασμάτων.


12 Συγκριτική Αξιολόγηση

12.1 Σύγκριση Baseline ως προς βελτιστοποιημένα

Πίνακας 13: Πλήρης σύγκριση μοντέλων — Baseline (B) & Βελτιστοποιημένα (T)


Μοντέλο	Baseline (Test)				CV		Tuned (Test)	
	MAE	MSE	RMSE	R^2	RMSE	R^2	RMSE	R^2
Random Forest	0,422	0,301	0,549	0,539	0,598	0,446	0,541	0,553
SVR	0,454	0,351	0,593	0,462	0,637	0,370	—	—
Gradient Boosting	0,485	0,362	0,602	0,446	0,627	0,391	0,575	0,495
Linear Regression	0,504	0,390	0,625	0,403	0,660	0,324	—	—
KNN	0,506	0,435	0,659	0,335	0,694	0,250	—	—
ElasticNet	0,685	0,657	0,811	−0,006	0,806	−0,006	—	—

12.2 Γράφημα ραντάρ



Σχήμα 14: Γράφημα ραντάρ — Κανονικοποιημένη σύγκριση μοντέλων βάσης.

Το γράφημα ραντάρ (Σχήμα 14) αναδεικνύει τον Random Forest ως το μοντέλο με τη μεγαλύτερη επιφάνεια (καλύτερη απόδοση σε όλες τις μετρικές).



Σχήμα 15: Σύγκριση RMSE μοντέλων βάσης.

12.3 Ισορροπία ακρίβειας–ερμηνευσιμότητας

Πίνακας 14: Ισορροπία ακρίβειας και ερμηνευσιμότητας

Μοντέλο	RMSE	Ερμηνευσιμότητα
Linear Regression	0,625	Υψηλή (συντελεστές β)
ElasticNet	0,811	Υψηλή (αραιοί συντελεστές)
KNN	0,659	Χαμηλή (τοπικά μόνο)
SVR	0,593	Χαμηλή (πυρήνες)
Gradient Boosting	0,541*	Μέση (SHAP, feature importance)
Random Forest	0,541	Μέση (SHAP, feature importance)

*Βελτιστοποιημένο Gradient Boosting: 0,575

Ο βελτιστοποιημένος Random Forest προσφέρει τον καλύτερο συνδυασμό ακρίβειας και ερμηνευσιμότητας (μέσω SHAP).

13 Συμπεράσματα

13.1 Σύνοψη αποτελεσμάτων

Η παρούσα μελέτη κατέδειξε ότι:

1. Ο αλγόριθμος **Random Forest** υπερτερεί σε όλες τις μετρικές, επιτυγχάνοντας $RMSE = 0,5406$ και $R^2 = 0,5528$ μετά τη βελτιστοποίηση.
2. Τα τρία σημαντικότερα χαρακτηριστικά είναι: alcohol ($|\bar{\phi}| = 0,208$), sulphates ($|\bar{\phi}| = 0,186$) και volatile acidity ($|\bar{\phi}| = 0,107$).
3. Η βελτιστοποίηση υπερπαραμέτρων βελτίωσε τον Gradient Boosting κατά 11,1% σε R^2 , αλλά δεν κατάφερε να ξεπεράσει τον Random Forest.

4. Η γραμμική παλινδρόμηση αποδεικνύεται ανεπαρκής ($R^2 = 0,403$), υποδεικνύοντας σημαντικές μη γραμμικές σχέσεις.
5. Ο ElasticNet με προεπιλεγμένες παραμέτρους είναι ακατάλληλος ($R^2 < 0$).

13.2 Τελική σύσταση μοντέλου

Προτείνεται ο **βελτιστοποιημένος Random Forest** ($n_estimators=200$, $max_depth=30$, $max_features=log2$) ως τελικό μοντέλο πρόβλεψης. Η ερμηνευσιμότητα εξασφαλίζεται μέσω ανάλυσης SHAP και σημαντικότητας μετάθεσης.

13.3 Περιορισμοί

- **Μέγεθος δεδομένων:** Τα 1.599 δείγματα είναι σχετικά λίγα, ιδιαίτερα για τις ακραίες κατηγορίες (ποιότητα 3, 8).
- **Ανισορροπία κλάσεων:** Η συγκέντρωση στις κατηγορίες 5–6 δυσχεραίνει τις προβλέψεις ακραίων τιμών.
- **Υποκειμενικότητα στόχου:** Η αισθητηριακή αξιολόγηση εμπεριέχει θόρυβο μεταξύ αξιολογητών.
- **Μονοδιάστατη γεωγραφία:** Μόνο κρασιά Vinho Verde — περιορισμένη γενικευσιμότητα.
- $R^2 \approx 0,55$: Σημαντικό ποσοστό διακύμανσης παραμένει ανεξήγητο, πιθανώς λόγω αισθητηριακών παραγόντων που δεν καταγράφονται στα φυσικοχημικά δεδομένα.

14 Βιβλιογραφία

1. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4), 547–553.
2. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

3. Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.
4. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
5. Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
6. Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer.
7. Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
8. Zou, H. & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320.
9. Guyon, I. & Elisseeff, A. (2003). An Introduction to Variable and Feature Selection. *Journal of Machine Learning Research*, 3, 1157–1182.
10. Shapley, L. S. (1953). A Value for N-person Games. *Contributions to the Theory of Games*, 2(28), 307–317.
11. UCI Machine Learning Repository. Wine Quality Data Set. <https://archive.ics.uci.edu/ml/datasets/wine+quality>